M05 · REVISIONE R6

Campionamento, stima e incertezza

Disegni campionari, derivazioni e ricampionamento strutturato

105 slide · teoria, derivazioni, figure e applicazioni in R.
Provenienza dei dati e sorgenti nei materiali allegati.

M05

Percorso del modulo

3 Apertura

4 Estimandi e disegni

15 Selezione e distorsione

22 Distribuzioni campionarie

34 Errore standard

44 Intervalli

55 Bootstrap elementare

69 Disegno del ricampionamento

86 Precisione numerica

93 Esercizi

104 Riferimenti

I numeri indicano le pagine iniziali; i titoli sono cliccabili. Codice, figure e verifiche sono inclusi nel progetto.

Dati e convenzioni di lettura

Il file dei fossili contiene ottanta individui per ciascuno dei due morfotipi, con diametri espressi in micrometri. Il file dei provini comprende sei stazioni, appartenenti a due affioramenti, con quattro provini per stazione. Poiché entrambi i casi sono sintetici, i risultati illustrano il comportamento delle procedure entro scenari dichiarati e non costituiscono evidenze su popolazioni geologiche reali.

$$n_R = n_S = 80,$$
$$G = 6, \qquad m = 4, \qquad N = Gm = 24.$$

Sviluppo e interpretazione

R indica Rounded e S Spiky; G conta le stazioni, m i provini per stazione e N il totale. Le maiuscole indicano variabili casuali prima del campionamento; le minuscole le realizzazioni osservate. L'asterisco identifica il ricampionamento condizionato ai dati, mentre il pedice dello stimatore specifica l'unità o lo schema utilizzato.

Richiami I CSV originali sono conservati senza modifiche; le unità compaiono in figure, tabelle e conclusioni.

Parametro, stimatore e stima

Sia F la distribuzione della grandezza nella popolazione di riferimento e sia $\theta = T(F)$ la proprietà che si intende conoscere. Lo stimatore è una funzione del campione casuale, dalla quale si ottiene una stima numerica dopo l'osservazione. Questa distinzione consente di attribuire la variabilità alla procedura: campioni differenti producono realizzazioni differenti dello stesso stimatore, mentre il parametro rimane fissato nel modello frequentista.

$$\widehat{\theta} = T_n(X_1, \ldots, X_n),$$
$$\widehat{\theta}_{\text{oss}} = T_n(x_1, \ldots, x_n).$$

Implementazione in R

Nella simulazione esponenziale il parametro medio è noto e vale uno. La media dei quaranta valori estratti costituisce una singola realizzazione dello stimatore, che verrà confrontata con quelle ottenute ripetendo il procedimento.

```
parametro <- 1
set.seed(301); campione <- rexp(40,rate=1)
stima <- mean(campione)
```

Richiami La distribuzione dello stimatore si riferisce a campioni ripetuti sotto il medesimo modello.

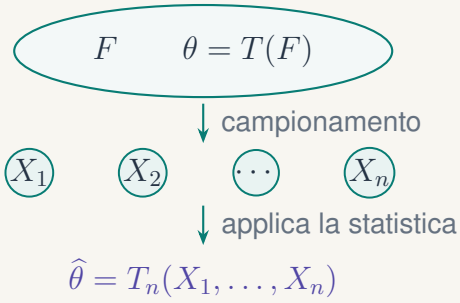
Il parametro e la stima appartengono a livelli diversi

Il parametro $\theta = T(F)$ è una proprietà della distribuzione F di popolazione, mentre lo stimatore T_n è una funzione delle n osservazioni che il campionamento rende casuali. Seguendo il diagramma dall'alto verso il basso, si passa quindi da una quantità fissata dal modello a una procedura il cui risultato varia fra campioni. Quando i dati sono osservati, la medesima funzione produce una stima numerica, della quale si può valutare l'incertezza soltanto specificando il meccanismo che avrebbe generato campioni alternativi.

$$\theta = T(F), \qquad \widehat{\theta} = T_n(X_1, \ldots, X_n).$$

Lettura del diagramma

Popolazione e parametro



Le frecce identificano operazioni diverse: generazione del campione e calcolo della statistica.

Richiami La distribuzione dello stimatore deriva congiuntamente dal modello e dalla funzione applicata ai dati.

Media, proporzione e contrasto

La scelta della statistica dipende dalla proprietà oggetto dell'indagine. Per una grandezza continua può interessare la media, mentre la frequenza di un evento richiede una proporzione. Quando si confrontano morfotipi, il contrasto deve mantenere un orientamento esplicito, affinché il segno del risultato conservi la propria interpretazione lungo tutti i calcoli.

$$\mu = \mathbb{E}(X), \qquad p = \Pr(X > c),$$
$$\Delta = \mu_S - \mu_R.$$

Sviluppo e interpretazione

Per la soglia c, l'indicatore vale uno quando il valore osservato la supera e zero altrimenti. Le stime sostituiscono alle quantità di popolazione le corrispondenti sintesi campionarie.

$$\overline{X} = \frac{1}{n}\sum_i X_i,$$
$$\widehat{p} = \frac{1}{n}\sum_i \mathbf{1}\{X_i > c\},$$
$$\widehat{\Delta} = \overline{X}_S - \overline{X}_R.$$

Richiami S e R indicano rispettivamente Spiky e Rounded; il contrasto adottato è sempre S meno R.

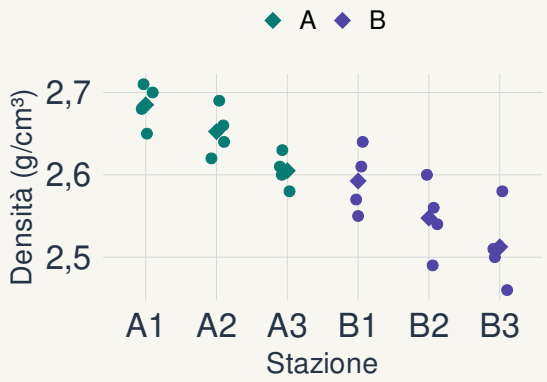
Gerarchia dei provini e delle stazioni

Indichiamo con ρ_{gi} la densità del provino i nella stazione g, ricavata dal rapporto fra massa e volume. La figura conserva sia le osservazioni individuali sia le medie di stazione, perché la dispersione entro sito e le differenze fra siti appartengono a livelli diversi. Qualora le condizioni locali inducano dipendenza, le ventiquattro righe del file non forniscono ventiquattro contributi indipendenti all'inferenza territoriale.

$$\rho_{gi} = \frac{m_{gi}}{V_{gi}}, \qquad V_{gi} > 0,$$

$$\bar{\rho}_g = \frac{1}{n_g} \sum_{i=1}^{n_g} \rho_{gi}.$$

Evidenza grafica



Punti: provini; rombi: medie locali. A e B: affioramenti. m_{gi} è la massa, V_{gi} il volume e n_g il numero di provini della stazione.

Richiami La densità è espressa in g/cm^3. La selezione dei siti delimita il dominio d'inferenza.

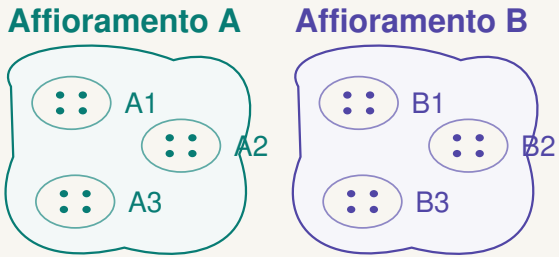
La struttura del campione precede il calcolo

Poiché ciascun provino appartiene a una stazione e ciascuna stazione a un affioramento, la misura X_{gi} del provino i nel sito g riflette la gerarchia del disegno. Il contorno esterno identifica l'affioramento, l'ellisse la stazione e il punto il provino. Quando si riferisce la conclusione alla popolazione delle stazioni, occorre stabilire come esse siano state selezionate e quale dipendenza possa sussistere fra i provini raccolti nello stesso sito.

$$X_{gi}, \quad g = 1, \dots, 6, \quad i = 1, \dots, 4,$$

$$\overline{X}_g = \frac{1}{4} \sum_{i=1}^{4} X_{gi}.$$

Lettura del diagramma



X_{gi}: misura del provino i, sito g

6 stazioni · 4 provini per stazione

La disposizione dei siti è schematica; il numero e il raggruppamento dei provini riproducono il dataset.

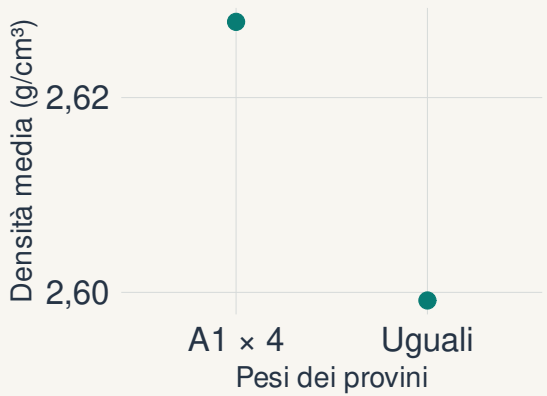
Richiami Contare le righe e identificare le unità indipendenti richiede due operazioni distinte.

Ponderazione e quantità d'interesse

La media complessiva assegna a ogni provino lo stesso peso, mentre la media delle stazioni attribuisce uguale rilevanza a ciascun sito. Nel disegno bilanciato le due sintesi coincidono. Se il contributo dei provini di A1 viene moltiplicato per quattro, la media ponderata diventa 2,628 g/cm^3, a fronte di 2,599 g/cm^3 con pesi uguali. Il cambiamento riguarda la quantità descritta dalla ponderazione.

$$\widehat{\theta}_w = \frac{\sum_i w_i \rho_i}{\sum_i w_i}, \qquad w_i > 0.$$

Evidenza grafica



Scenario didattico: ρ_i è la densità e w_i il peso del provino i. A1 riceve peso quadruplo, conservando le misure.

Richiami Un peso può rappresentare una quota, una probabilità di inclusione o una scelta descrittiva: va motivato.

Equivalenza delle medie nel disegno bilanciato

La relazione fra le due medie si ricava raggruppando la somma complessiva per stazione. Ogni somma interna equivale alla media locale moltiplicata per il numero di provini. Quando tale numero è costante, il fattore comune si semplifica e produce l'equiponderazione dei siti. In presenza di numerosità differenti, invece, la stessa identità rende esplicito il maggiore contributo delle stazioni più campionate.

$$\overline{\rho} = \frac{1}{N} \sum_{g=1}^{G} \sum_{i=1}^{n_g} \rho_{gi}$$

$$= \frac{1}{N} \sum_{g=1}^{G} n_g \overline{\rho}_g, \qquad N = \sum_{g} n_g.$$

Sviluppo e interpretazione

G è il numero di stazioni, n_g la numerosità del sito g e N il totale; ρ_{gi} è la densità del provino i. Se $n_g = m$ per ogni sito, la semplificazione è esatta. L'equivalenza delle medie osservate lascia aperta la scelta del modello necessario a quantificarne l'incertezza.

$$N = Gm,$$

$$\overline{\rho} = \frac{m}{Gm} \sum_{g} \overline{\rho}_g$$

$$= \frac{1}{G} \sum_{g} \overline{\rho}_g.$$

Richiami Una stessa stima numerica può essere associata a errori standard differenti quando cambia il disegno.

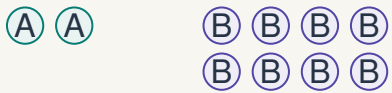
L’aggregazione rende esplicita l’unità di riferimento

Si considerino due stazioni con medie pari a 2,4 e 2,8 g/cm^3, dalle quali provengano rispettivamente due e otto provini. Se ogni provino riceve uguale peso, la seconda stazione contribuisce quattro volte quanto la prima. Qualora la quantità d’interesse sia invece la media di una stazione scelta con probabilità uniforme fra le due, i pesi diventano uguali, sebbene il numero delle osservazioni resti invariato.

$$\overline{x}_{\text{provini}} = \frac{2 \cdot 2{,}4 + 8 \cdot 2{,}8}{10},$$
$$\overline{x}_{\text{siti}} = \frac{2{,}4 + 2{,}8}{2}.$$

Lettura del diagramma

Pesi assegnati ai provini



$$\overline{x}_{\text{provini}} = 2{,}72$$

Pesi assegnati alle stazioni



$$\overline{x}_{\text{siti}} = 2{,}60$$

Caso illustrativo dell’esercizio sui pesi. Tutte le medie sono espresse in g/cm³.

Richiami La scelta dei pesi definisce la quantità descritta e deve precedere il calcolo dell’incertezza.

Campionamento casuale da una popolazione finita

In una popolazione finita di N_U unità, il campionamento casuale semplice senza reinserimento assegna la stessa probabilità a ogni sottoinsieme di dimensione n. L'indicatore I_i segnala l'inclusione dell'unità i. Poiché ciascuna unità ha probabilità n/N_U di entrare nel campione, la linearità del valore atteso dimostra che la media campionaria è non distorta rispetto alla media della popolazione finita.

$$\overline{Y}_s = \frac{1}{n}\sum_{i=1}^{N_U} I_i y_i,$$

$$\mathbb{E}_d(\overline{Y}_s) = \frac{1}{n}\sum_i \frac{n}{N_U} y_i = \overline{Y}_U.$$

Sviluppo e interpretazione

Il pedice d indica che la casualità proviene dal disegno di selezione: i valori y_i della popolazione sono fissati. Questa impostazione richiede una base di campionamento che includa tutte le unità del dominio dichiarato.

$$\Pr_d(I_i = 1) = \frac{n}{N_U},$$

$$\overline{Y}_U = \frac{1}{N_U}\sum_i y_i.$$

Richiami La non distorsione riguarda il disegno sulla base effettivamente disponibile, che può escludere parte del territorio.

Selezione senza reinserimento

Nel campionamento casuale semplice senza reinserimento, un'unità selezionata non può ricomparire nello stesso campione. La popolazione illustrata ammette dieci sottoinsiemi di due unità, ciascuno con la medesima probabilità. Poiché ogni unità appartiene a quattro di tali sottoinsiemi, la sua probabilità d'inclusione è due quinti. Questa simmetria giustifica la non distorsione della media campionaria rispetto alla media della popolazione finita.

$$\mathbb{E}_d(\overline{Y}_s) = \frac{1}{n}\sum_{i=1}^{N_U} \mathbb{E}_d(I_i) Y_i = \overline{Y}_U.$$

Lettura del diagramma

Cinque unità nella popolazione finita



$\overline{y}_s = (4+8)/2 = 6$

$\binom{5}{2} = 10$ campioni equiprobabili

$\Pr(I_i = 1) = 2/5$ per ciascuna unità

Popolazione di $N_U = 5$ valori fissati Y_i, campione di n = 2; I_i vale uno se i è incluso. È mostrato uno dei dieci campioni equiprobabili.

Richiami Il pedice d riferisce valore atteso e varianza alla selezione casuale sulla popolazione finita.

Stratificazione e pesi di popolazione

Quando il territorio viene suddiviso in strati, la media complessiva si ottiene combinando le medie interne mediante le quote di popolazione. Le quote campionarie possono differire da quelle territoriali, per esempio quando si sovracampiona una litologia rara. Affinché l'aggregazione descriva il dominio previsto, i pesi devono quindi essere definiti in relazione all'estimando e mantenuti espliciti durante il ricampionamento.

Sviluppo e interpretazione

H è il numero di strati; W_h la quota di popolazione e μ_h la media dello strato h, stimata da $\overline{X}_h$. Il generatore dei fossili fissa ottanta individui per morfotipo. L'obiettivo didattico assegna pesi $W_R = W_S = 1/2$, che non stimano la frequenza naturale dei morfotipi.

$$\mu = \sum_{h=1}^{H} W_h \mu_h, \qquad \sum_h W_h = 1,$$

$$\widehat{\mu}_{\mathrm{str}} = \sum_h W_h \overline{X}_h.$$

Richiami Strato, quota campionaria e peso di aggregazione devono essere distinti nella descrizione del metodo.

Selezione e popolazione osservabile

Sia A l'indicatore che un'unità sia accessibile e venga osservata. La media delle unità disponibili descrive la distribuzione condizionata a $A = 1$. Se l'accessibilità è associata alla grandezza misurata, questa media differisce da quella dell'intero dominio. L'identità a destra esplicita il ruolo della covarianza e mostra perché aumentare il numero di osservazioni nella medesima porzione accessibile possa lasciare invariata la distorsione di selezione.

$$\mu_A = \mathbb{E}(X \mid A = 1), \qquad \Pr(A = 1) > 0.$$

Sviluppo e interpretazione

Qui $\mu = \mathbb{E}(X)$ è la media dell'intero dominio. Poiché A è binario, XA si annulla sulle unità escluse. Sostituendo la definizione di covarianza si ottiene la differenza fra le due medie.

$$\begin{aligned} \mathbb{E}(XA) &= \Pr(A = 1)\mu_A, \\ \operatorname{Cov}(X, A) &= \Pr(A = 1)(\mu_A - \mu), \\ \mu_A - \mu &= \frac{\operatorname{Cov}(X, A)}{\Pr(A = 1)}. \end{aligned}$$

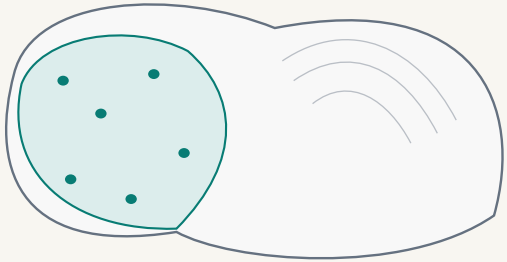
Richiami L'identità presuppone momenti finiti e una probabilità positiva di osservazione.

Il territorio accessibile e il parametro

Qualora l'accessibilità dipenda dalla grandezza studiata, le unità raggiungibili descrivono una distribuzione condizionata. Nel diagramma, i punti appartengono soltanto alla porzione accessibile del territorio, mentre il parametro d'interesse continua a riferirsi all'intero dominio. La relazione fra le due medie dipende dalla covarianza con l'indicatore di selezione, sicché l'aumento delle osservazioni nella medesima porzione non garantisce che la distorsione si riduca.

$$\mu_A - \mu = \frac{\operatorname{Cov}(X, A)}{\Pr(A = 1)},$$
$$\Pr(A = 1) > 0.$$

Lettura del diagramma



A vale uno sulle unità accessibili; $\mu = E(X)$ e $\mu_A = E(X \mid A = 1)$. Territorio illustrativo: le aree non rappresentano probabilità o pesi.

Richiami L'estensione geografica della conclusione deve essere giustificata dal disegno di selezione.

Perdita di campioni e registrazione del processo

Anche dopo la selezione iniziale, la disponibilità del dato può dipendere dalla proprietà studiata: provini friabili possono deteriorarsi, mentre misure fuori scala possono essere escluse. Indicando con R la disponibilità finale, l'analisi dei soli casi completi descrive X condizionata a $R = 1$. La registrazione separata di selezione, perdita e motivo dell'esclusione consente di valutare quali parti del processo abbiano alterato la popolazione osservabile.

$$\mathbb{E}(X \mid R = 1) = \mathbb{E}(X)$$
$$\text{se } R \perp X \text{ e } \Pr(R = 1) > 0.$$

Sviluppo e interpretazione

L'indipendenza è una condizione sufficiente, da giustificare mediante il protocollo e le informazioni disponibili. Una proporzione ridotta di dati mancanti, considerata isolatamente, non dimostra che la perdita sia indipendente dalla grandezza misurata.

Richiami Il registro delle esclusioni deve conservare identificativo, fase, motivo e numero di unità coinvolte.

Decomposizione dell’errore quadratico medio

Per valutare uno stimatore, la dispersione va considerata insieme allo scostamento sistematico dal parametro. Aggiungendo e sottraendo il suo valore atteso, l’errore si scompone in una componente centrata e in una costante. Il termine incrociato ha valore atteso nullo, da cui segue la decomposizione dell’errore quadratico medio. La derivazione richiede che lo stimatore possieda un secondo momento finito.

$$b = \mathbb{E}(\widehat{\theta}) - \theta,$$
$$\widehat{\theta} - \theta = \left[\widehat{\theta} - \mathbb{E}(\widehat{\theta})\right] + b.$$

Sviluppo e interpretazione

La componente centrata ha media zero. Sviluppando il quadrato e applicando il valore atteso, il contributo misto scompare.

$$\mathbb{E}[\widehat{\theta} - \mathbb{E}(\widehat{\theta})] = 0,$$
$$\mathrm{MSE}(\widehat{\theta}) = \mathrm{Var}(\widehat{\theta}) + b^2.$$

Richiami La precisione descrive la dispersione; l’errore quadratico medio incorpora anche la distorsione.

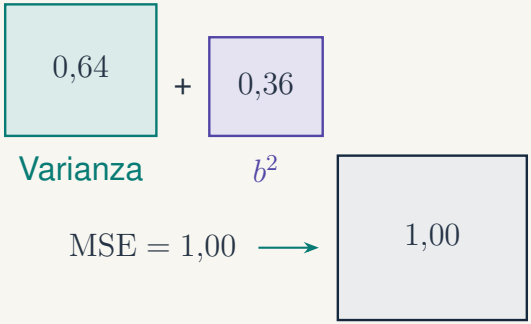
Le due componenti dell’errore quadratico

Quando lo stimatore possiede secondo momento finito, l’errore quadratico medio si decompone nella varianza e nel quadrato della distorsione. Le aree illustrano un caso nel quale la deviazione standard dello stimatore è 0,8 e la distorsione è 0,6: le rispettive aree rappresentano quindi 0,64 e 0,36. La somma vale uno, mostrando perché una procedura molto concentrata possa conservare un errore rilevante qualora il suo centro sia spostato rispetto al parametro.

$$\mathbb{E}[(\widehat{\theta} - \theta)^2] = \mathrm{Var}(\widehat{\theta}) + b^2,$$
$$b = \mathbb{E}(\widehat{\theta}) - \theta.$$

Lettura del diagramma

Un esempio della decomposizione



Le aree sono proporzionali ai contributi numerici; l’esempio non usa le misure geologiche del dataset.

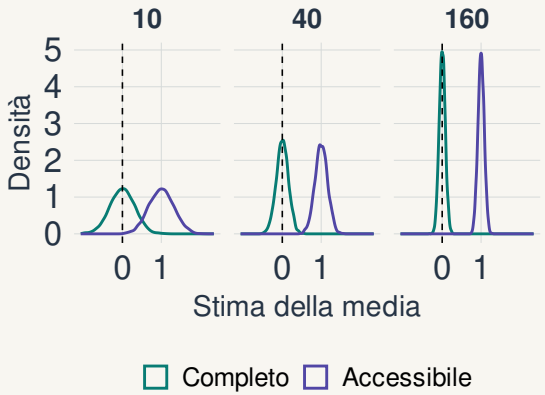
Richiami La concentrazione dello stimatore e la correttezza del suo centro sono proprietà differenti.

Aumento della numerosità e distorsione persistente

L'esperimento confronta una selezione centrata sul parametro zero con un settore accessibile la cui media è uno. In entrambi i casi la deviazione standard dello stimatore diminuisce come $1/\sqrt{n}$. Le distribuzioni diventano pertanto più concentrate, mentre la seconda mantiene lo scostamento dal parametro territoriale. La simulazione separa deliberatamente la precisione del procedimento dalla correttezza del dominio sul quale esso opera.

$$\widehat{\mu}_n \sim \mathcal{N}(\mu_A, 1/n),$$
$$\mathrm{MSE}_{\mu=0}(\widehat{\mu}_n) = 1/n + \mu_A^2.$$

Evidenza grafica



4.000 stime per scenario e n. Verde: $\mu_A = 0$; viola: $\mu_A = 1$. Tratteggio: parametro zero.

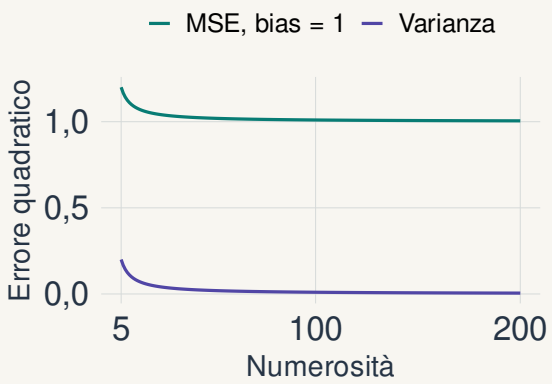
Richiami Il modello è illustrativo: l'aumento di n riduce la varianza, mentre il centro dipende dalla selezione.

Errore residuo e dominio della conclusione

Quando la media della popolazione accessibile è spostata di un'unità rispetto al parametro, l'errore quadratico medio tende a uno anche se la varianza della stima tende a zero. Il risultato delimita ciò che un aumento delle osservazioni può ottenere. Una conclusione scientificamente sostenibile deve quindi riferire la stima al dominio coperto oppure motivare, mediante ulteriori informazioni, l'estensione alle unità escluse.

$$\lim_{n\to\infty} \mathrm{Var}(\widehat{\mu}_n) = 0,$$
$$\lim_{n\to\infty} \mathrm{MSE}(\widehat{\mu}_n) = b^2.$$

Evidenza grafica



Scenario con distorsione $b = E(\widehat{\mu}_n) - \mu = 1$: la varianza decresce, mentre l'errore quadratico medio (MSE) tende a uno.

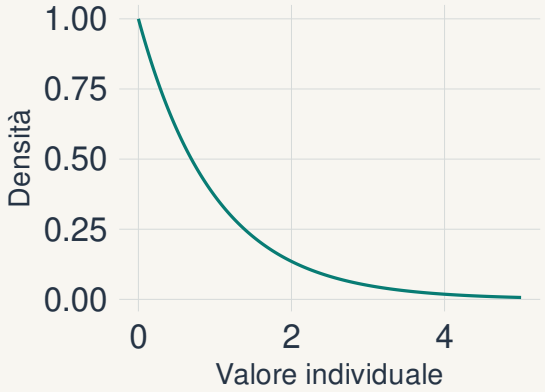
Richiami Le incertezze dovute a copertura territoriale e protocollo richiedono evidenze ulteriori rispetto all'errore standard.

Distribuzione di origine e campione osservato

Per studiare una procedura inferenziale occorre un esperimento nel quale il parametro sia noto. Si assume qui una distribuzione esponenziale di parametro uno, che produce valori positivi e asimmetrici. La figura descrive la variabilità delle singole osservazioni. Nei passaggi successivi ogni valore rappresentato sarà invece una media calcolata su un campione indipendente, cosicché cambierà l'oggetto della distribuzione esaminata.

$$X_i \overset{\text{iid}}{\sim} \text{Exp}(1),$$
$$\mathbb{E}(X_i) = 1, \qquad \text{Var}(X_i) = 1.$$

Evidenza grafica



Densità della distribuzione esponenziale usata come popolazione teorica.

Richiami IID significa indipendenti e identicamente distribuite; il parametro è noto soltanto perché il modello è simulato.

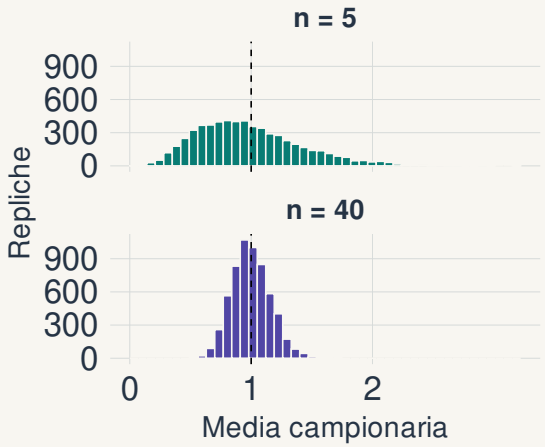
Distribuzione campionaria della media

Ripetendo seimila volte l'estrazione di un campione, si ottiene una distribuzione empirica delle medie. Il confronto fra cinque e quaranta osservazioni mantiene la medesima popolazione esponenziale, così che le differenze riguardano il comportamento dello stimatore. Per $n = 40$ la distribuzione risulta più concentrata e più simmetrica, mentre i singoli valori continuano a provenire da una distribuzione esponenziale di media uno.

$$\overline{X}_n^{(k)} = \frac{1}{n} \sum_{i=1}^{n} X_i^{(k)},$$

$$k = 1, \ldots, 6000.$$

Evidenza grafica



6.000 medie per numerosità; tratteggio: μ = 1.

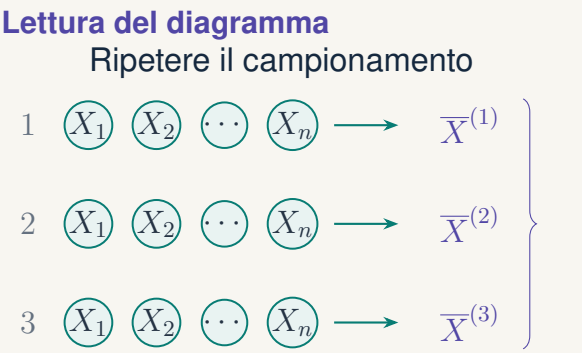
Richiami La distribuzione campionaria dipende dal modello, dalla statistica e dalla numerosità.

La distribuzione campionaria nasce dalla ripetizione

Per studiare la variabilità della media, si immagina di ripetere il medesimo esperimento di campionamento, mantenendo fissi popolazione, disegno e numerosità. Ogni riga del diagramma rappresenta un nuovo campione, dal quale si ricava una sola media. La distribuzione campionaria raccoglie tali medie, mentre la distribuzione dei dati descrive le osservazioni interne a ciascun campione. Le due rappresentazioni rispondono pertanto a domande diverse.

$$\overline{X}^{(k)} = \frac{1}{n}\sum_{i=1}^{n} X_i^{(k)}, \qquad k = 1, \ldots, K.$$

Lettura del diagramma



Ogni replica produce una media.

La distribuzione riguarda le medie dei campioni.

Tre repliche schematiche. Il laboratorio confronta 6.000 campioni simulati per ciascuna numerosità.

Richiami Prima di interpretare un istogramma, occorre identificare quale oggetto abbia prodotto ciascun valore.

Valore atteso della media campionaria

Se ciascuna osservazione ha valore atteso μ, la media campionaria possiede lo stesso valore atteso per linearità. Il risultato non richiede indipendenza, poiché l'operatore di aspettazione attraversa una somma finita di variabili integrabili. L'indipendenza interverrà nel calcolo della varianza, dove compaiono termini che descrivono la variazione congiunta delle osservazioni.

$$\mathbb{E}(\overline{X}_n) = \mathbb{E}\left(\frac{1}{n}\sum_i X_i\right)$$
$$= \frac{1}{n}\sum_i \mathbb{E}(X_i) = \frac{n\mu}{n} = \mu.$$

Sviluppo e interpretazione

Le condizioni utilizzate sono l'esistenza del valore atteso e l'uguaglianza delle medie individuali. Se le osservazioni provengono da distribuzioni con medie differenti, il valore atteso della media campionaria è la media di tali valori attesi.

$$\mathbb{E}(X_i) = \mu_i \quad \Longrightarrow$$
$$\mathbb{E}(\overline{X}_n) = \frac{1}{n}\sum_i \mu_i.$$

Richiami La non distorsione è una proprietà del procedimento rispetto a un parametro e a un modello definiti.

Varianza della media sotto indipendenza

La varianza di una somma di variabili indipendenti è la somma delle varianze. Poiché il fattore $1/n$ entra al quadrato, per osservazioni con la stessa varianza σ^2 si ottiene σ^2/n. Prendendo la radice quadrata si ricava l'errore standard teorico della media, che conserva l'unità di misura dei dati e quantifica la dispersione dello stimatore su campioni ripetuti.

$$\begin{aligned}\operatorname{Var}(\overline{X}_n) &= \frac{1}{n^2}\sum_{i}\operatorname{Var}(X_i)\\ &= \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}.\end{aligned}$$

Sviluppo e interpretazione

Nel modello esponenziale di varianza uno, gli errori standard teorici sono $1/\sqrt{5}$ e $1/\sqrt{40}$. Le deviazioni standard delle medie simulate sono rispettivamente 0,440 e 0,158, soggette a errore Monte Carlo.

$$\operatorname{SE}(\overline{X}_n) = \frac{\sigma}{\sqrt{n}}.$$

Richiami È sufficiente che le covarianze siano nulle; l'indipendenza costituisce una condizione più forte.

Varianza della media con covarianze

Quando le osservazioni condividono condizioni locali, il quadrato della somma contiene prodotti fra scarti di unità diverse. Il valore atteso di ciascun prodotto è la relativa covarianza. Sommando i termini diagonali e quelli fuori diagonale si ricava la varianza generale della media. Le covarianze positive accrescono l'incertezza rispetto al calcolo che le omette, a parità di varianze marginali.

$$\mathrm{Var}(\overline{X}_n) = \frac{1}{n^2}\mathbb{E}\left[\left(\sum_i (X_i - \mu_i)\right)^2\right]$$
$$= \frac{1}{n^2}\left[\sum_i \sigma_i^2 + 2\sum_{i<j} \mathrm{Cov}(X_i, X_j)\right].$$

Sviluppo e interpretazione

Qui $\mu_i = E(X_i)$ e $\sigma_i^2 = \mathrm{Var}(X_i)$. Il fattore due conta entrambi i prodotti i,j e j,i. La forma matriciale usa la matrice di covarianza Σ e il vettore a, i cui n elementi valgono 1/n.

$$a = \frac{1}{n}\mathbf{1},$$
$$\mathrm{Var}(\overline{X}_n) = a^\top \Sigma a.$$

Richiami La matrice Σ raccoglie varianze sulla diagonale e covarianze nelle altre posizioni.

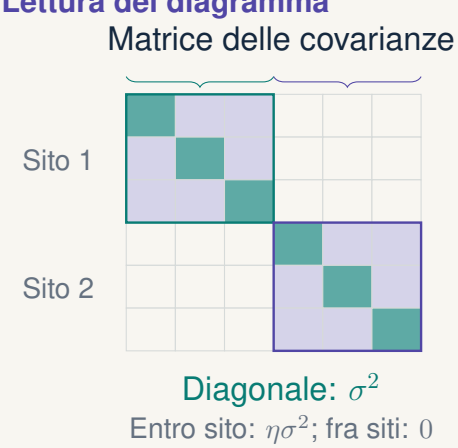
Le covarianze occupano blocchi riconoscibili

Se le osservazioni dello stesso sito condividono condizioni locali, la matrice delle covarianze assume una struttura a blocchi. Nel modello illustrato, due siti indipendenti comprendono tre osservazioni ciascuno: la diagonale contiene le varianze, mentre le celle colorate fuori diagonale rappresentano le covarianze interne. Poiché la media combina tutte le osservazioni, la sua varianza raccoglie anche questi contributi, con un incremento che dipende dalla correlazione e dalla numerosità interna.

$$\operatorname{Var}(\overline{X}) = \frac{\mathbf{1}^\top \Sigma \mathbf{1}}{n^2},$$

$$n = 6, \qquad \operatorname{Var}(\overline{X}) = \frac{\sigma^2}{6}(1 + 2\eta).$$

Lettura del diagramma



σ^2: varianza comune; η: correlazione entro sito; $\mathbf{1}$: vettore di sei uno. Le tinte distinguono tipi di contributo, senza codificarne l'intensità.

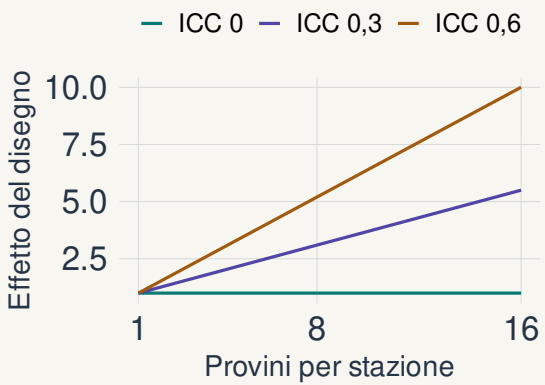
Richiami La formula assume varianze uguali, correlazione comune entro sito e indipendenza fra siti.

Dipendenza entro stazione ed effetto del disegno

Consideriamo G stazioni indipendenti, ciascuna con m provini aventi varianza σ^2 e correlazione comune η entro stazione. Le coppie interne non ordinate sono $Gm(m-1)/2$. Sostituendo questo conteggio nella formula generale, si ottiene un fattore moltiplicativo della varianza rispetto a Gm osservazioni indipendenti. Tale modello rende esplicita la ridondanza introdotta dal campionamento concentrato negli stessi siti.

$$\mathrm{Var}(\overline{X}) = \frac{Gm\sigma^2 + Gm(m-1)\eta\sigma^2}{(Gm)^2}$$
$$= \frac{\sigma^2}{Gm}\big[1 + (m-1)\eta\big].$$

Evidenza grafica



ICC = η: correlazione entro sito. DEFF = $1 + (m-1)\eta$: fattore di inflazione della varianza.

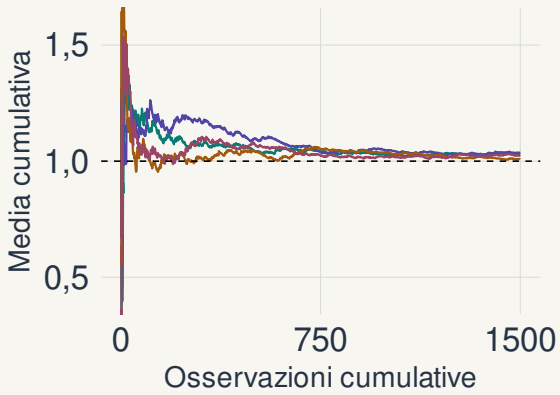
Richiami Con G = 6, m = 4 e η = 0,6, DEFF = 2,8 e n effettivo = 24/2,8 ≈ 8,57; è un modello illustrativo.

Legge dei grandi numeri: una derivazione sufficiente

Per osservazioni IID con media μ e varianza finita, la disuguaglianza di Chebyshev limita la probabilità che la media si discosti dal parametro oltre una tolleranza prefissata. Poiché la varianza della media è σ^2/n, tale limite tende a zero. Si ottiene così la convergenza in probabilità, pur senza richiedere che ogni nuova osservazione avvicini monotonicamente la media al parametro.

$$\Pr(|\overline{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \longrightarrow 0,$$
$$\varepsilon > 0, \qquad \overline{X}_n \xrightarrow{\Pr} \mu.$$

Evidenza grafica



Quattro traiettorie esponenziali; asse verticale limitato a 0,4–1,6 per leggere la convergenza.

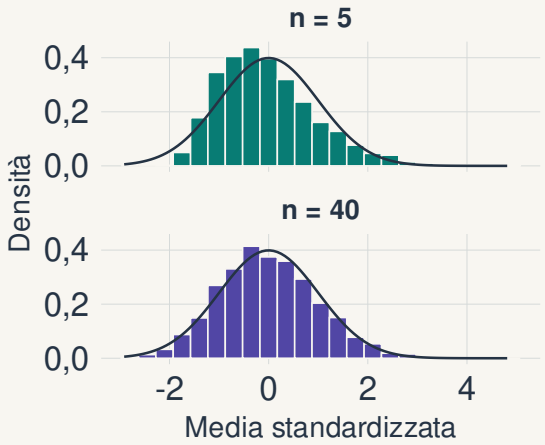
Richiami La varianza finita è sufficiente per questa dimostrazione; esistono versioni della legge con ipotesi più deboli.

Teorema del limite centrale e standardizzazione

Per variabili IID con varianza finita e positiva, il limite centrale descrive la distribuzione asintotica della media centrata e riscalata mediante il suo errore standard. La standardizzazione mantiene una dispersione non degenere mentre n aumenta. La figura confronta le medie esponenziali ($\mu = \sigma = 1$) standardizzate con la densità normale, mostrando che l'approssimazione dipende dalla numerosità e dalla forma della distribuzione di origine.

$$Z_n = \frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0,\, 1).$$

Evidenza grafica



Pannelli: n = 5 e n = 40. Curva: normale standard.

Richiami La freccia indica convergenza in distribuzione. Il risultato non stabilisce una soglia universale di numerosità.

Convergenza della media e forma dell'errore

Sotto ipotesi IID con varianza finita e positiva, la legge dei grandi numeri descrive la concentrazione della media attorno al parametro, mentre il limite centrale studia l'errore dopo una riscalatura. Il fattore radice di n compensa la diminuzione della dispersione, consentendo di ottenere una distribuzione limite non degenere. Le due colonne seguono pertanto il medesimo errore, al quale vengono rivolte domande differenti.

$$\overline{X}_n - \mu \xrightarrow{p} 0,$$
$$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0,\,1).$$

Lettura del diagramma

Grandi numeri	Limite centrale
$X_1, X_2, \ldots$	$\overline{X}_n - \mu$
↓	↓
$\overline{X}_n - \mu$	$\frac{\sqrt{n}(\overline{X}_n - \mu)}{\sigma}$
↓	↓
$\xrightarrow{p} 0$	$\xrightarrow{d} \mathcal{N}(0,1)$
Errore non scalato	Errore standardizzato

μ e σ sono media e deviazione standard comuni. Le frecce p e d indicano convergenza in probabilità e in distribuzione. Lettura verticale.

Richiami Il limite centrale riguarda la statistica standardizzata e non trasforma le singole osservazioni in dati normali.

Portata delle ipotesi asintotiche

Le conclusioni precedenti dipendono dal comportamento dei momenti e dalla struttura di dipendenza. Una distribuzione con code tanto pesanti da avere varianza infinita esce dalle ipotesi del limite centrale classico; una forte dipendenza può invece impedire che la varianza della media diminuisca come $1/n$. Nel caso stazionale, questa diminuzione è determinata dalla somma delle autocovarianze, che il bootstrap per righe non conserva.

$$\operatorname{Var}(\overline{X}_n) = \frac{1}{n^2}\left[n\gamma(0) + 2\sum_{h=1}^{n-1}(n-h)\gamma(h)\right].$$

Sviluppo e interpretazione

Qui $\gamma(h) = \operatorname{Cov}(X_t, X_{t+h})$ dipende soltanto dalla distanza temporale. Se tutte le osservazioni coincidessero con una stessa variabile Z, la loro media sarebbe ancora Z, indipendentemente dal numero di righe registrate.

$$X_1 = \cdots = X_n = Z$$
$$\Longrightarrow \operatorname{Var}(\overline{X}_n) = \operatorname{Var}(Z).$$

Richiami La relazione con le autocovarianze anticipa M09; il caso perfettamente dipendente è un controesempio limite.

Varianza campionaria e denominatore n meno uno

La dispersione dei dati si misura rispetto alla media stimata nello stesso campione. Per comprendere il denominatore $n-1$, si considera l'identità che collega gli scarti dalla media campionaria agli scarti dal parametro. Nel modello IID, il valore atteso della prima somma a destra è $n\sigma^2$, mentre quello del termine sottratto è $n\,\mathrm{Var}(\overline{X}) = \sigma^2$. La divisione per $n-1$ produce pertanto uno stimatore non distorto della varianza.

$$\sum_i (X_i - \overline{X})^2 = \sum_i (X_i - \mu)^2 - n(\overline{X} - \mu)^2.$$

Sviluppo e interpretazione

La correzione deriva dalla stima del centro. Il risultato riguarda la varianza S^2; prendendone la radice, in generale, la proprietà di non distorsione non si conserva esattamente.

$$S^2 = \frac{1}{n-1}\sum_i (X_i - \overline{X})^2,$$
$$\mathbb{E}(S^2) = \sigma^2.$$

Richiami L'identità algebrica è generale; il calcolo del valore atteso utilizza il modello IID con varianza finita.

Stima dell’errore standard della media

Sostituendo la deviazione standard ignota σ con la deviazione standard campionaria S, si ottiene la stima usuale dell’errore standard. Nel gruppo Rounded la dispersione dei diametri è 1,000 µm, mentre l’errore standard stimato della media è 0,112 µm. Le due quantità condividono l’unità di misura, ma descrivono oggetti diversi: rispettivamente osservazioni individuali e medie ottenute su campioni ripetuti.

$$\widehat{\mathrm{SE}}(\overline{X}) = \frac{S}{\sqrt{n}}, \qquad n = 80.$$

Implementazione in R

Il codice mantiene separati la numerosità, la dispersione e l’errore standard, affinché il significato di ciascun risultato sia verificabile. Il modello assunto per questo esempio considera gli individui Rounded indipendenti e provenienti dalla stessa distribuzione.

```
n <- length(x); xb <- mean(x); s <- sd(x);
    se <- s/sqrt(n)
```

Richiami La formula S/√n richiede una struttura compatibile con il campionamento indipendente.

La misura di variabilità dipende dall'oggetto

La deviazione standard campionaria descrive quanto differiscano le osservazioni del campione, mentre l'errore standard della media riguarda la variabilità che la media avrebbe su campioni ripetuti. Poiché i due oggetti conservano la stessa unità fisica, la distinzione deve essere esplicitata nel linguaggio e nelle figure. Sotto indipendenza e identica distribuzione, la numerosità collega le due scale attraverso la radice quadrata.

$$s^2 = \frac{1}{n-1}\sum_i (x_i - \bar{x})^2,$$

$$\widehat{\mathrm{SE}}(\overline{X}) = \frac{s}{\sqrt{n}}.$$

Lettura del diagramma

Entro un campione



s: dispersione delle osservazioni

Fra campioni ripetuti



$\mathrm{SE}(\overline{X})$: dispersione delle medie

I simboli rappresentano oggetti statistici. La loro posizione nella pagina non codifica valori misurati.

Richiami Aumentare n riduce l'incertezza della media, mentre la dispersione individuale resta una proprietà della popolazione.

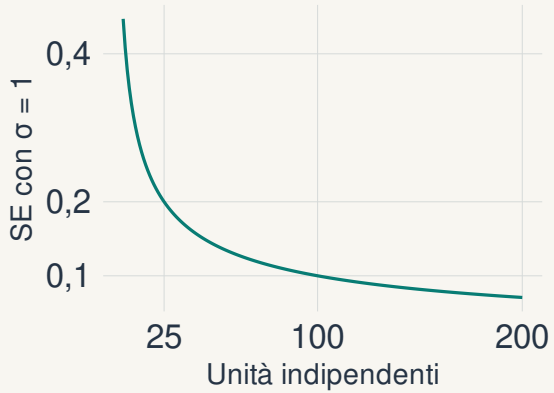
Numerosità e legge della radice quadrata

A parità di varianza della popolazione, la precisione della media cresce con la radice quadrata del numero di unità indipendenti. Per dimezzare l'errore standard occorre quindi quadruplicare la numerosità. La figura assume $\sigma = 1$ e permette di osservare che ogni ulteriore incremento di n produce una riduzione progressivamente più contenuta dell'errore standard in termini assoluti.

$$\frac{\mathrm{SE}(\overline{X}_{n_2})}{\mathrm{SE}(\overline{X}_{n_1})} = \sqrt{\frac{n_1}{n_2}},$$

$$n_2 = 4n_1 \quad \Longrightarrow \quad \mathrm{SE}_{n_2} = \tfrac{1}{2}\,\mathrm{SE}_{n_1}\,.$$

Evidenza grafica



Unità indipendenti con deviazione standard di popolazione pari a uno.

Richiami Con deviazione standard unitaria, n = 25 dà SE = 0,20 e n = 100 dà SE = 0,10.

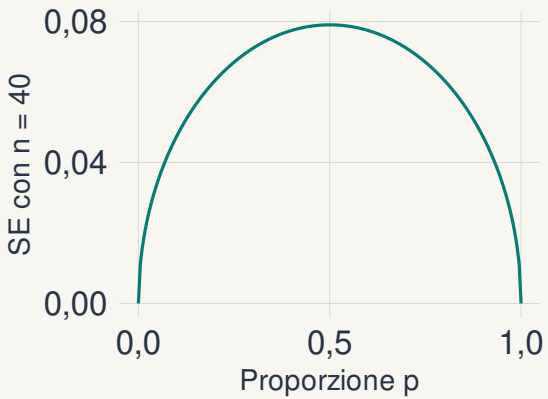
Errore standard di una proporzione

Per un evento dicotomico si introducono indicatori Bernoulli indipendenti, ciascuno con probabilità p di successo. La proporzione campionaria è la loro media, per cui la formula della varianza deriva direttamente dal risultato ottenuto per medie indipendenti. La sostituzione di p con la proporzione osservata fornisce una stima semplice, la cui degenerazione ai bordi richiede attenzione quando gli eventi sono rari.

$$Y_i \sim \text{Bernoulli}(p), \qquad \hat{p} = \frac{1}{n}\sum_i Y_i,$$

$$\text{SE}(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}.$$

Evidenza grafica



Errore standard teorico per n = 40. La variabilità è massima per p = 0,5.

Richiami Con zero successi la stima plug-in del SE è zero, ma p resta incerto: occorrono intervalli adatti ai bordi.

Correzione per popolazione finita

Nel campionamento senza reinserimento, l'estrazione di un'unità modifica le probabilità delle successive. Le covarianze fra estrazioni risultano negative, riducendo la varianza della media rispetto al modello con reinserimento. Quando si osserva l'intera popolazione, l'incertezza di campionamento si annulla. La formula usa la varianza finita S_U^2 con denominatore $N_U - 1$, che va distinta dalla varianza di una distribuzione teorica.

$$S_U^2 = \frac{1}{N_U - 1} \sum_i (y_i - \overline{Y}_U)^2,$$

$$\mathrm{Var}_d(\overline{Y}_s) = \left(1 - \frac{n}{N_U}\right) \frac{S_U^2}{n}.$$

Implementazione in R

Per la popolazione $\{2, 4, 6, 8, 10\}$ e campioni di due unità esistono dieci sottoinsiemi equiprobabili. L'enumerazione completa fornisce varianza delle medie pari a 3,000, coincidente con la formula.

```
pop <- c(2,4,6,8,10); nc <- 2L
combinazioni <- combn(pop,nc)
medie_srs <- colMeans(combinazioni)
var_design <- mean((medie_srs-mean(pop))^2)
var_fpc <- (1-nc/length(pop))*var(pop)/nc
```

Richiami La correzione si riferisce al disegno casuale semplice senza reinserimento su una popolazione finita nota.

Varianza della media stratificata

Con strati campionati indipendentemente e pesi di popolazione fissati, la varianza della media stratificata si ottiene sommando le varianze interne moltiplicate per il quadrato dei pesi. Il risultato segue dalla linearità dello stimatore e dall'annullamento delle covarianze fra strati. Nel caso fossile, l'equiponderazione dei due morfotipi definisce la quantità d'interesse, mentre le numerosità interne determinano la precisione di ciascun contributo.

$$\mathrm{Var}(\widehat{\mu}_{\mathrm{str}}) = \sum_h W_h^2 \frac{\sigma_h^2}{n_h},$$

$$\widehat{\mathrm{SE}}_{\mathrm{str}} = \sqrt{\sum_h W_h^2 \frac{S_h^2}{n_h}}.$$

Implementazione in R

Per lo strato h, W_h è il peso, n_h la numerosità, σ_h^2 la varianza e S_h^2 la sua stima. Con pesi 1/2 e ottanta individui per gruppo, il SE è 0,076 µm. Si assume indipendenza entro e fra gruppi; frazioni elevate di campionamento finito richiedono correzioni.

```
se_strat <- sqrt(.25*var(x)/80+.25*var(y)/
    80)
```

Richiami I pesi dell'estimando restano fissati mentre si valuta l'incertezza delle medie interne.

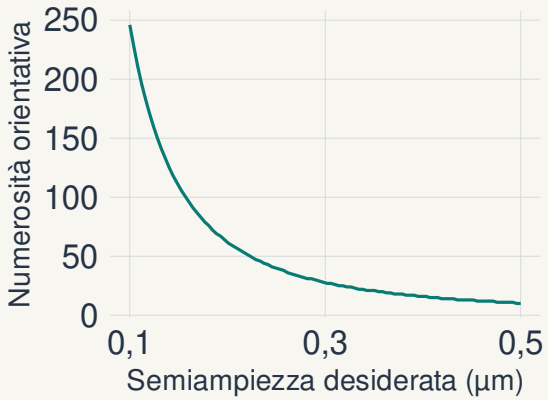
Pianificazione della precisione

Se si dispone di una deviazione standard pilota σ_0, la semiampiezza desiderata E di un intervallo normale permette di ricavare una numerosità orientativa. Risolvendo la disuguaglianza rispetto a n, si ottiene un limite inferiore da arrotondare all'intero superiore. Il calcolo presuppone unità indipendenti e una stima pilota pertinente al dominio che verrà campionato.

$$z_{1-\alpha/2}\frac{\sigma_0}{\sqrt{n}} \le E$$

$$\Longrightarrow \quad n \ge \left(\frac{z_{1-\alpha/2}\sigma_0}{E}\right)^2.$$

Evidenza grafica



$z_{1-\alpha/2}$ è il quantile della normale standard. Con $\sigma_0 = 0{,}8$ µm, E = 0,2 µm e livello $1-\alpha = 95\%$, servono almeno 62 unità.

Richiami Il valore pianificato richiede aggiustamenti per dipendenza, perdite, costi e incertezza della stima pilota.

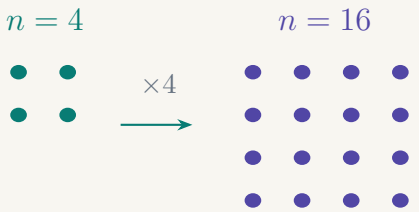
Dimezzare l’errore standard richiede quattro volte n

Quando la varianza della popolazione resta invariata e le osservazioni sono indipendenti, l’errore standard diminuisce con la radice della numerosità. Il passaggio da quattro a sedici unità rende visibile il costo di un dimezzamento dell’incertezza. Se invece le unità aggiuntive condividono condizioni già rappresentate nel campione, occorre introdurre i termini di covarianza prima di tradurre il loro numero in un guadagno di precisione.

$$\frac{\mathrm{SE}_2}{\mathrm{SE}_1} = \sqrt{\frac{n_1}{n_2}},$$

$$n_2 = 4n_1 \implies \mathrm{SE}_2 = \frac{1}{2}\mathrm{SE}_1.$$

Lettura del diagramma



Stessa varianza; osservazioni indipendenti.

Il numero dei punti rappresenta esattamente le due numerosità. Non sono misure del dataset geologico.

Richiami La pianificazione deve riferirsi alle unità che forniscono informazione indipendente.

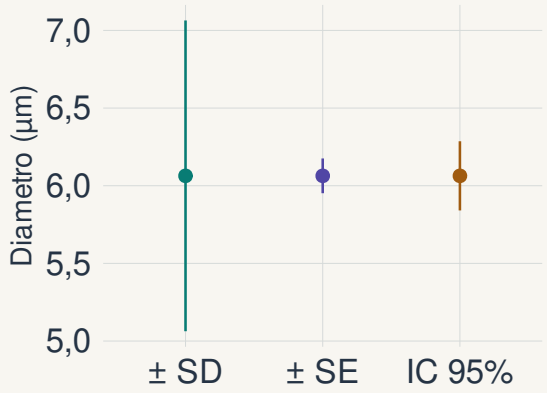
Barre di dispersione e barre d'incertezza

La stessa media può essere accompagnata dalla deviazione standard dei dati, dall'errore standard oppure da un intervallo di confidenza. Poiché le barre rappresentano quantità differenti, la loro ampiezza acquista significato soltanto quando la didascalia ne dichiara la costruzione. Nel gruppo Rounded la dispersione individuale supera nettamente quella stimata per la media, mentre il livello di confidenza introduce un moltiplicatore ulteriore.

$$\overline{x} \pm s, \qquad \overline{x} \pm \frac{s}{\sqrt{n}},$$

$$\overline{x} \pm t_{n-1;\,0{,}975}\frac{s}{\sqrt{n}}.$$

Evidenza grafica



Stesso campione Rounded e stesso centro. Le tre barre descrivono dispersione o incertezza diverse.

Richiami La barra ± SD è una sintesi della dispersione, non un intervallo con copertura individuale prefissata.

Il perno di Student

Per osservazioni IID normali, la media standardizzata con la deviazione standard ignota sostituita da S segue una distribuzione di Student. Il risultato è esatto perché la media normalizzata è normale standard, la varianza campionaria riscalata è chi-quadrato e le due quantità sono indipendenti. Il perno così costruito possiede una distribuzione che non dipende dai parametri ignoti μ e σ.

$$X_i \overset{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2), \qquad \sigma > 0,$$
$$T = \frac{\overline{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

Sviluppo e interpretazione

La normalità rende esatto il risultato. Con distribuzioni differenti, l'adeguatezza dell'approssimazione dipende da asimmetria, code, numerosità e dipendenza.

$$Z = \frac{\sqrt{n}(\overline{X} - \mu)}{\sigma},$$
$$U = \frac{(n-1)S^2}{\sigma^2},$$
$$Z \perp U, \qquad T = \frac{Z}{\sqrt{U/(n-1)}}.$$

Richiami Il termine perno indica una funzione di dati e parametro con distribuzione priva di parametri ignoti.

Inversione della disuguaglianza probabilistica

Indicando con q il quantile superiore di Student, l'evento centrale del perno ha probabilità $1-\alpha$. Poiché $S/\sqrt{n}$ è positivo, la moltiplicazione mantiene il verso delle disuguaglianze. Isolando successivamente μ, si ottengono due estremi casuali che definiscono l'intervallo di confidenza. La copertura deriva dall'equivalenza degli eventi, sotto le ipotesi che rendono valida la distribuzione del perno.

$$\Pr\left(-q \le \frac{\overline{X}-\mu}{S/\sqrt{n}} \le q\right) = 1-\alpha,$$

$$q = t_{n-1;\,1-\alpha/2}.$$

Sviluppo e interpretazione

Si assumono n osservazioni IID normali, con media μ e deviazione standard positiva. S è la deviazione standard campionaria. Isolare il parametro conserva la probabilità dell'evento.

$$-q\frac{S}{\sqrt{n}} \le \overline{X}-\mu \le q\frac{S}{\sqrt{n}},$$

$$\overline{X} - q\frac{S}{\sqrt{n}} \le \mu \le \overline{X} + q\frac{S}{\sqrt{n}}.$$

Richiami La probabilità riguarda la procedura prima di osservare il campione; μ è fissato.

Dal perno all'intervallo attraverso lo stesso evento

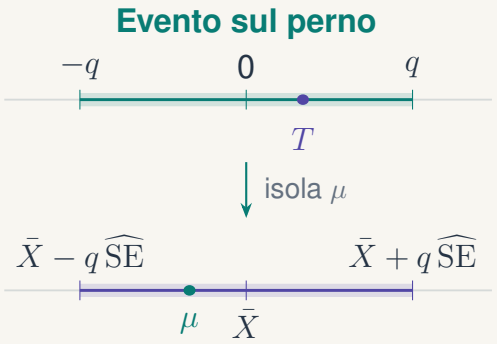
Sotto il modello normale IID, il perno di Student appartiene all'intervallo centrale con probabilità prestabilita. Poiché l'errore standard stimato è positivo, isolando il parametro si ottiene un evento equivalente. Le due scale mostrano che un perno positivo corrisponde a una media campionaria superiore al parametro, il quale compare quindi a sinistra del centro dell'intervallo.

$$T = \frac{\overline{X} - \mu}{\widehat{\mathrm{SE}}}, \qquad q = t_{n-1;1-\alpha/2},$$

$$\{-q \le T \le q\} \iff$$

$$\{\overline{X} - q\widehat{\mathrm{SE}} \le \mu \le \overline{X} + q\widehat{\mathrm{SE}}\}.$$

Lettura del diagramma



Le due rette esprimono la stessa inclusione. Nella ripetizione campionaria μ è fisso e gli estremi sono casuali.

Richiami La probabilità di copertura appartiene alla procedura prima dell'osservazione del campione.

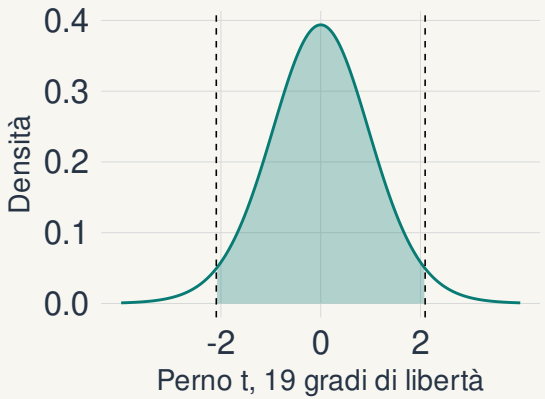
Livello di confidenza e quantile critico

Per un campione normale di venti osservazioni, il perno ha diciannove gradi di libertà. L'area centrale rappresentata in figura vale 0,95 e determina il quantile $q = t_{19;0,975} \simeq 2{,}093$, usato nei due estremi. Se si richiede una copertura nominale maggiore, l'area centrale deve aumentare, per cui il quantile e l'ampiezza dell'intervallo crescono a parità di dati.

$$C(\mathbf{X}) = \left[\overline{X} - q\frac{S}{\sqrt{n}},\ \overline{X} + q\frac{S}{\sqrt{n}}\right],$$

$$|C(\mathbf{X})| = 2q\frac{S}{\sqrt{n}}.$$

Evidenza grafica



S: deviazione standard campionaria. Area centrale 95%, con n = 20.

Richiami Il quantile dipende sia dal livello nominale sia dai gradi di libertà.

Calcolo dell’intervallo sui fossili Rounded

Nel gruppo Rounded si osservano media 6,064 µm e deviazione standard 1,000 µm su ottanta individui. Il quantile di Student a settantanove gradi di libertà è 1,990. Moltiplicando tale quantile per l’errore standard si ricava la semiampiezza, da cui seguono gli estremi 5,841 e 6,286 µm. Il codice confronta il calcolo esplicito con la funzione di R, mantenendo visibili gli elementi della costruzione.

$$\widehat{\mu} = \overline{x}, \qquad a = t_{79;\,0{,}975}\frac{s}{\sqrt{80}},$$

$$C_{0{,}95} = [5{,}841;\ 6{,}286]\ \mu\mathrm{m}.$$

Implementazione in R

La concordanza computazionale verifica l’implementazione della formula. La validità inferenziale richiede inoltre che il modello indipendente e l’approssimazione normale siano pertinenti al campionamento considerato.

```
critico <- qt(.975,n-1)
ic_t <- xb+c(-1,1)*critico*se
```

Richiami Il CSV documenta dati sintetici: il calcolo illustra una procedura, non una popolazione fossile reale.

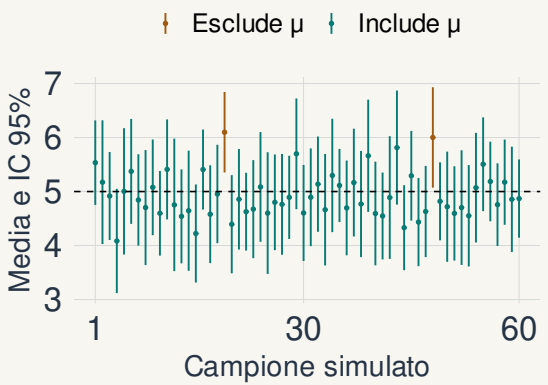
Copertura su campioni ripetuti

La simulazione genera duemila campioni normali di venti osservazioni, con media cinque e deviazione standard due. Ogni campione produce un intervallo t mediante la medesima regola. In questa esecuzione 1900 intervalli contengono il parametro, mentre la figura mostra soltanto i primi sessanta. La frequenza simulata è una stima della copertura della procedura ed è essa stessa soggetta a variabilità Monte Carlo.

$$\hat{c}_K = \frac{1}{K}\sum_{k=1}^{K} \mathbf{1}\{\mu \in C_k\},$$

$$\mathrm{SE}_{\mathrm{MC}}(\hat{c}_K) = \sqrt{\frac{c(1-c)}{K}}.$$

Evidenza grafica



C_k è l'intervallo della replica k e c la copertura teorica. Nei primi 60 intervalli, 58 includono $\mu = 5$; in ocra quelli che lo escludono.

Richiami Con c = 0,95 e K = 2000, il SE Monte Carlo è circa 0,0049; la frequenza non deve coincidere sempre con 0,95.

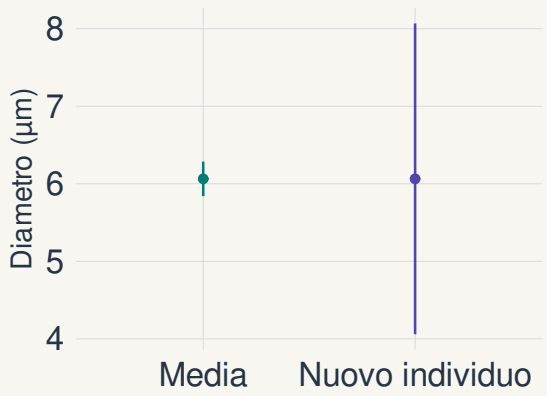
Confidenza sulla media e previsione individuale

La previsione di una nuova osservazione include la variabilità dell'individuo futuro oltre all'incertezza nella stima della media. Nel modello normale IID, la differenza $X_{\text{nuovo}} - \overline{X}$ ha varianza $\sigma^2(1 + 1/n)$, perché l'osservazione futura è indipendente dal campione. Il corrispondente intervallo predittivo risulta quindi più ampio dell'intervallo per la media, pur condividendo centro e livello nominale.

$$\operatorname{Var}(X_{\text{nuovo}} - \overline{X}) = \sigma^2 + \frac{\sigma^2}{n},$$

$$I_{\text{pred}} = \overline{X} \pm t_{n-1;\,0{,}975} S \sqrt{1 + 1/n}.$$

Evidenza grafica



Confronto sotto il modello normale IID. La previsione riguarda un nuovo individuo della stessa popolazione.

Richiami Un intervallo per μ non descrive la percentuale di osservazioni individuali comprese fra i suoi estremi.

Differenza fra due medie indipendenti

Per gruppi indipendenti, la varianza della differenza è la somma delle varianze delle due medie. La procedura di Welch consente varianze interne differenti, stimandole separatamente e approssimando i gradi di libertà. Nel caso fossile il contrasto Spiky meno Rounded vale 0,582 µm, con intervallo di Welch da 0,282 a 0,882 µm. L'orientamento del contrasto deve restare invariato anche nel bootstrap.

$$\widehat{\Delta} = \overline{X}_S - \overline{X}_R, \qquad a = \frac{S_S^2}{n_S}, \quad b = \frac{S_R^2}{n_R},$$
$$\widehat{\mathrm{SE}}(\widehat{\Delta}) = \sqrt{a+b}.$$

Sviluppo e interpretazione

S_R^2 e S_S^2 sono varianze campionarie; n_R, n_S sono numerosità. I gradi di libertà dipendono dai due contributi stimati. La funzione t.test di R usa Welch per impostazione predefinita nel confronto di due campioni indipendenti.

$$\nu = \frac{(a+b)^2}{a^2/(n_S-1) + b^2/(n_R-1)},$$
$$C = \widehat{\Delta} \pm t_{\nu;\,0{,}975}\sqrt{a+b}.$$

Richiami Il modulo M06 svilupperà l'interpretazione dei confronti e il rapporto fra intervalli, effetti e test.

Misure appaiate e covarianza interna

I diametri totale e interno appartengono allo stesso fossile e costituiscono una coppia. Definendo la differenza individuale D_i, l'inferenza si riconduce alla media di ottanta differenze indipendenti fra individui. La covarianza fra le misure dello stesso oggetto entra nella varianza di D_i e deve essere conservata, tanto nel calcolo analitico quanto nel ricampionamento.

$$D_i = X_{i,\mathrm{tot}} - X_{i,\mathrm{int}},$$
$$\mathrm{Var}(D_i) = \sigma^2_{\mathrm{tot}} + \sigma^2_{\mathrm{int}} - 2\,\mathrm{Cov}(X_{i,\mathrm{tot}}, X_{i,\mathrm{int}}).$$

Implementazione in R

Per Rounded, la differenza media è 0,857 µm e il suo errore standard è 0,028 µm. L'intervallo si calcola sul vettore delle differenze oppure specificando l'appaiamento nella funzione statistica.

```
pa <- subset(f,morfotipo=='Rounded')
diff_coppie <- pa$diametro_tot_um-pa$
    diametro_int_um
ic_coppie <- unname(t.test(diff_coppie)$conf
    .int)
```

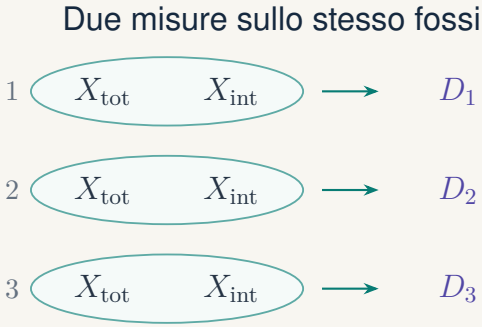
Richiami L'unità campionaria è il fossile: due colonne misurate sullo stesso individuo non raddoppiano n.

La differenza conserva il legame fra le misure

Quando diametro totale e diametro interno appartengono al medesimo fossile, la differenza deve essere calcolata entro individuo. Il diagramma conserva tale appartenenza mediante un contorno comune, dal quale deriva una sola differenza. L'errore standard della differenza media dipende allora dalla dispersione delle differenze individuali, che incorpora la covarianza fra le due misure e richiede indipendenza fra individui.

$$D_i = X_{i,\mathrm{tot}} - X_{i,\mathrm{int}},$$
$$\mathrm{Var}(D_i) = \sigma^2_{\mathrm{tot}} + \sigma^2_{\mathrm{int}} - 2\,\mathrm{Cov}(X_{i,\mathrm{tot}}, X_{i,\mathrm{int}}).$$

Lettura del diagramma



Ogni ellisse identifica un individuo.

Tre individui schematici. Il dataset contiene ottanta coppie Rounded utilizzate nel laboratorio.

Richiami L'appaiamento appartiene al disegno dell'osservazione e deve essere preservato nell'analisi.

Sensibilità al modello e ai valori influenti

L'intervallo t quantifica l'incertezza della media entro un modello, la cui pertinenza richiede esame del disegno e della distribuzione osservata. Un valore estremo può incidere contemporaneamente sul centro e sulla dispersione, mentre una selezione territoriale distorta può spostare l'intero campione. Il confronto fra metodi deve pertanto mantenere lo stesso estimando e rendere esplicite le ipotesi che cambiano.

Sviluppo e interpretazione

Nel laboratorio si confronteranno intervallo t e percentile per Rounded, conservando gli ottanta individui come unità di ricampionamento. La concordanza degli estremi costituisce un controllo di sensibilità numerico, senza dimostrare rappresentatività o copertura in ogni popolazione.

Richiami Una modifica del metodo richiede una motivazione legata al disegno o al comportamento dello stimatore.

Distribuzione empirica e principio di sostituzione

Il bootstrap non parametrico sostituisce la distribuzione ignota con quella empirica, che assegna massa $1/n$ a ciascuna osservazione. Condizionatamente al campione, si estraggono nuove sequenze di indici con reinserimento e si ricalcola la statistica. La distribuzione così ottenuta approssima quella campionaria quando l'unità di ricampionamento e le condizioni di regolarità sono coerenti con il problema inferenziale.

$$\widehat{F}_n = \frac{1}{n}\sum_{i=1}^{n} \delta_{x_i},$$

$$X_1^*, \dots, X_n^* \mid \mathbf{x} \overset{\text{iid}}{\sim} \widehat{F}_n.$$

Sviluppo e interpretazione

Il simbolo δ_{x_i} indica una massa unitaria nel valore osservato x_i. La legge bootstrap è condizionata ai dati disponibili, che definiscono sia i valori selezionabili sia le probabilità assegnate.

$$\widehat{\theta}^* = T_n(X_1^*, \dots, X_n^*).$$

Richiami Il bootstrap della media IID ha giustificazioni asintotiche; piccoli campioni e disegni complessi richiedono cautela.

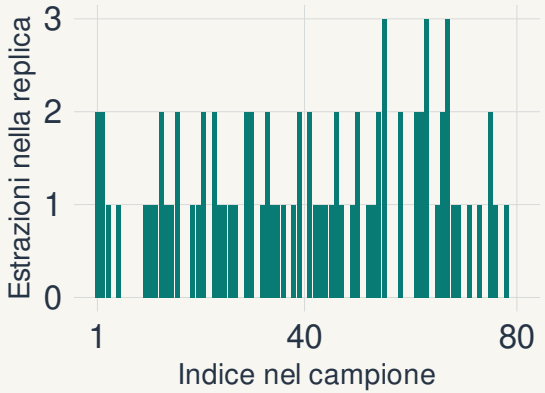
Indici estratti e molteplicità di selezione

Una replica bootstrap può essere rappresentata attraverso gli indici estratti oppure attraverso il numero di volte in cui ogni osservazione viene selezionata. Le molteplicità sommano a n e seguono una distribuzione multinomiale condizionata al campione. La figura mostra una replica degli ottanta fossili Rounded, nella quale alcuni individui sono assenti e altri compaiono più volte.

$$J_j^* \overset{\text{iid}}{\sim} \text{Unif}\{1, \dots, n\},$$

$$N_i^* = \sum_{j=1}^{n} \mathbf{1}\{J_j^* = i\}, \qquad \sum_i N_i^* = n.$$

Evidenza grafica



Replica con seme 311: 80 estrazioni e 55 individui distinti. Le altezze sono molteplicità.

Richiami Per la media, la stessa replica si scrive come somma dei valori estratti o come media ponderata dalle molteplicità.

Le molteplicità traducono gli indici in pesi

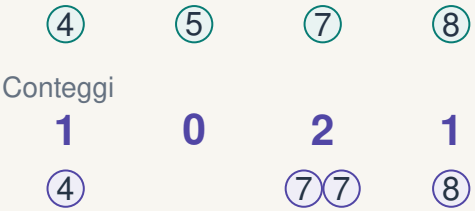
Una sequenza di indici estratti può essere descritta contando quante volte ciascuna osservazione compare nella replica. La rappresentazione per molteplicità rende esplicita la ponderazione indotta dal ricampionamento, nella quale alcuni pesi sono nulli e altri superano uno. Sebbene l'ordine degli indici possa cambiare, la media resta la stessa quando il vettore dei conteggi è invariato.

$$N_i^* = \sum_{j=1}^{n} \mathbf{1}\{J_j = i\},$$

$$\overline{X}^* = \frac{1}{n} \sum_{i=1}^{n} N_i^* x_i.$$

Lettura del diagramma

Una replica come vettore di molteplicità



$$N^* = (1, 0, 2, 1), \quad \sum_i N_i^* = 4$$

$$\bar{x}^* = \frac{1 \cdot 4 + 0 \cdot 5 + 2 \cdot 7 + 1 \cdot 8}{4}$$

Campione x = (4, 5, 7, 8); J_j è l'indice estratto e N_i^* il suo conteggio. La replica (7, 7, 4, 8) ha media 6,5.

Richiami La distribuzione multinomiale delle molteplicità è condizionata al campione osservato.

Una replica esplicita in R

L'estrazione degli indici separa la selezione delle unità dal calcolo della statistica. Tale scelta rende verificabile quali individui partecipino alla replica e permette di conservare insieme più variabili misurate sullo stesso oggetto. Per Rounded, la replica con seme 311 contiene cinquantacinque individui distinti e produce media 6,229 µm, a fronte di 6,064 µm nel campione originale.

$$\overline{X}^* = \frac{1}{n}\sum_{j=1}^{n} x_{J_j^*} = \frac{1}{n}\sum_{i=1}^{n} N_i^* x_i.$$

Implementazione in R

La molteplicità è una proprietà della replica, mentre il campione osservato conserva i suoi ottanta individui. Quando si ricampionano coppie, gli stessi indici devono selezionare tutte le colonne della coppia.

```
set.seed(311)
indici <- sample.int(n,n,replace=TRUE)
replica <- x[indici]
frequenze <- tabulate(indici,nbins=n)
```

Richiami Il seme rende ripetibile la sequenza pseudo-casuale entro lo stesso algoritmo e ambiente.

Seguire gli indici rende visibile il reinserimento

Una replica bootstrap si ottiene estraendo gli indici con reinserimento e applicandoli al campione osservato. Nel caso illustrato, l'indice tre compare due volte, per cui il valore sette contribuisce due volte alla media, mentre il valore cinque rimane escluso. Le quattro posizioni della replica conservano la numerosità originaria, benché gli individui distinti siano soltanto tre. La media ricampionata deriva dunque da una nuova ponderazione delle informazioni già disponibili.

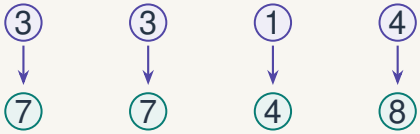
$$x = (4,5,7,8), \quad J = (3,3,1,4),$$
$$x^* = (x_{J_1}, \ldots, x_{J_4}), \qquad \bar{x}^* = 6{,}5.$$

Lettura del diagramma

Campione osservato



Indici estratti



$$\bar{x}^* = (7 + 7 + 4 + 8)/4 = 6{,}5$$

Il valore 7 compare due volte; 5 è assente.

Gli indici sono scelti per illustrare una replica ammissibile. Il calcolo è verificato nello script R dei diagrammi.

Richiami Il reinserimento modifica le molteplicità; il campione empirico resta la sorgente dei valori.

Enumerazione del bootstrap su quattro valori

Il campione $\{4, 5, 7, 8\}$ permette di esaminare il procedimento senza approssimazione Monte Carlo. Ogni replica contiene quattro estrazioni e le sequenze ordinate possibili sono $4^4 = 256$, tutte equiprobabili. Enumerandole si ottiene media bootstrap pari a sei e varianza pari a 0,625. Se invece si estraessero tutti i valori senza reinserimento, cambierebbe soltanto il loro ordine e la media rimarrebbe costante.

$$\mathbb{E}_*(\overline{X}^*) = 6, \qquad \mathrm{Var}_*(\overline{X}^*) = 0{,}625.$$

Implementazione in R

Il pedice asterisco indica momenti calcolati sulla distribuzione condizionata al campione. Il codice genera gli indici di tutte le sequenze e attribuisce loro lo stesso peso.

```
piccolo <- c(4,5,7,8)
# Tutte le 4^4 = 256 sequenze ordinate,
    equiprobabili con reinserimento.
indici_esatti <- as.matrix(expand.grid(rep(
    list(seq_len(4)),4)))
medie_esatte <- apply(indici_esatti,1,
    function(ii)mean(piccolo[ii]))
```

Richiami Con reinserimento, le molteplicità variano; una permutazione completa conserva ogni osservazione una volta.

Momenti condizionati della media bootstrap

Condizionatamente al campione, ciascuna estrazione bootstrap ha valore atteso uguale alla media osservata. La sua varianza è la varianza empirica con denominatore n, poiché ogni valore osservato ha probabilità $1/n$. L'indipendenza delle estrazioni permette quindi di dividere tale varianza per n quando si considera la loro media. Ne segue un'espressione esatta, utile per controllare il risultato della simulazione.

$$\mathbb{E}_*(X_j^*) = \overline{x}, \qquad \mathrm{Var}_*(X_j^*) = \frac{1}{n}\sum_i (x_i - \overline{x})^2.$$

Sviluppo e interpretazione

Usando la varianza campionaria s^2, il secondo momento empirico centrato vale $(n-1)s^2/n$. La varianza della media bootstrap contiene quindi un ulteriore fattore $1/n$.

$$\mathbb{E}_*(\overline{X}^*) = \overline{x},$$
$$\mathrm{Var}_*(\overline{X}^*) = \frac{n-1}{n^2}s^2.$$

Richiami Il fattore (n−1)/n distingue la varianza bootstrap condizionata da s^2/n; le due convergono per n crescente.

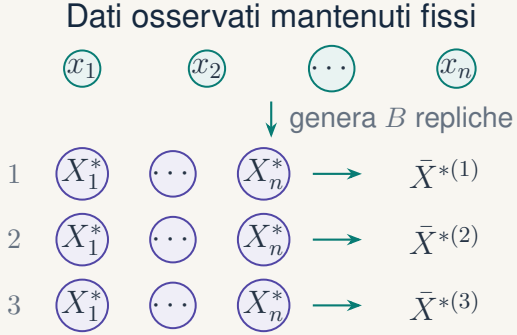
Numerosità del campione e numero delle repliche

Condizionatamente al campione osservato, ogni replica bootstrap contiene n estrazioni dalla distribuzione empirica, mentre B indica quante volte si ripete l'operazione. La varianza condizionata della media dipende dai dati e da n, per cui l'aumento di B rende più precisa la sua approssimazione numerica senza modificare l'informazione osservativa. Il diagramma separa la dimensione interna della replica dal numero delle righe simulate.

$$\mathrm{Var}_*(\overline{X}^*) = \frac{n-1}{n^2} s^2,$$

$$\widehat{\mathrm{SE}}_* \xrightarrow[B\to\infty]{} \sqrt{\mathrm{Var}_*(\overline{X}^*)}.$$

Lettura del diagramma



s^2 è la varianza dei dati osservati con divisore n – 1. Sono mostrate tre delle B repliche, ciascuna di numerosità n.

Richiami B controlla l'approssimazione Monte Carlo; n appartiene al campione su cui si condiziona.

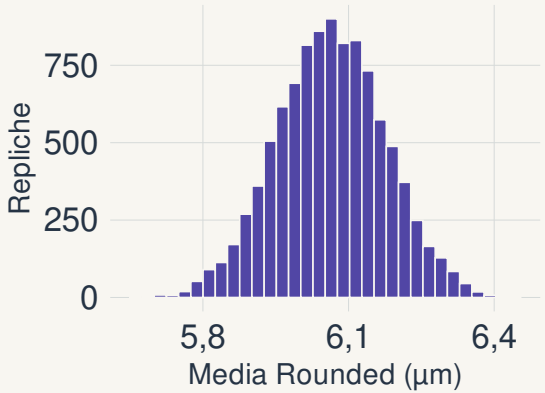
Distribuzione bootstrap della media Rounded

Applicando il ricampionamento a un solo morfotipo, si mantiene la numerosità di ottanta individui e si calcola la media in diecimila repliche. La distribuzione risultante è centrata vicino alla media osservata, poiché l'atteso condizionato della media bootstrap coincide con la media dei dati. La sua dispersione fornisce una stima dell'errore standard bootstrap, che in questa esecuzione vale 0,112 µm.

$$\widehat{\theta}^{*(b)} = \frac{1}{80}\sum_{j=1}^{80} x_{J_j^{*(b)}},$$

$$b = 1, \ldots, B, \qquad B = 10\,000.$$

Evidenza grafica



Diecimila repliche della media Rounded. Il campione originario contiene sempre 80 individui.

Richiami L'errore standard condizionato esatto vale circa 0,11115 µm; la stima Monte Carlo oscilla attorno a esso.

Errore standard bootstrap e bias stimato

La deviazione standard delle statistiche ricampionate stima la dispersione condizionata della procedura. Il denominatore $B-1$ corregge la stima della varianza fra repliche, che sono generate indipendentemente dato il campione. La differenza fra la media delle repliche e la stima osservata viene talvolta usata per stimare il bias; nel caso della media, il bias bootstrap condizionato è esattamente nullo e la differenza simulata riflette soltanto errore Monte Carlo.

$$\overline{\theta}^{*} = \frac{1}{B}\sum_{b=1}^{B} \widehat{\theta}^{*(b)},$$

$$\widehat{\mathrm{SE}}_{*} = \sqrt{\frac{1}{B-1}\sum_{b} (\widehat{\theta}^{*(b)} - \overline{\theta}^{*})^{2}}.$$

Sviluppo e interpretazione

Il numero B controlla la precisione con cui viene approssimata la distribuzione bootstrap. La numerosità n appartiene invece al campione osservato e determina l'informazione disponibile sulla popolazione.

$$\widehat{\mathrm{bias}}_{*} = \overline{\theta}^{*} - \widehat{\theta}.$$

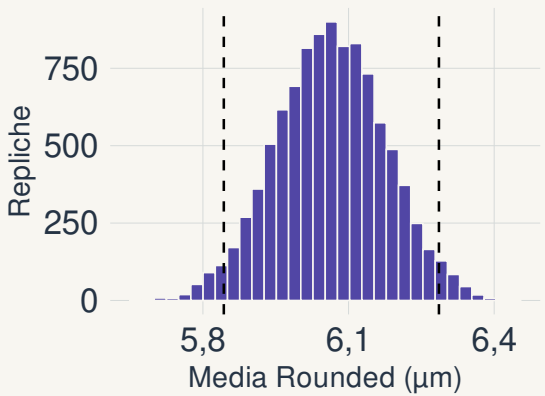
Richiami Un bias bootstrap nullo per la media non dimostra che il campione sia privo di distorsione di selezione.

Intervallo percentile e ordinamento delle repliche

L'intervallo percentile utilizza i quantili inferiore e superiore della distribuzione bootstrap della statistica. Nel gruppo Rounded i limiti al 2,5% e al 97,5% sono 5,843 e 6,286 µm. La costruzione è semplice da implementare, ma la sua copertura è approssimata e può risultare inadeguata quando lo stimatore è distorto, il campione è poco informativo o la distribuzione presenta caratteristiche problematiche.

$$C^*_{1-\alpha} = [q^*_{\alpha/2},\ q^*_{1-\alpha/2}].$$

Evidenza grafica



Livello nominale $1-\alpha = 0{,}95$. I tratteggi indicano i quantili $q^*_{0{,}025}$ e $q^*_{0{,}975}$, calcolati con type = 7 di R.

Richiami L'intervallo percentile non è un intervallo esatto universale; il suo livello nominale richiede una giustificazione.

Interpolazione dei quantili in R

Per rendere riproducibili gli estremi occorre dichiarare la convenzione dei quantili. Con il tipo sette di R, la posizione associata alla probabilità p è $h = 1 + (B-1)p$. Quando tale posizione non è intera, il quantile interpola linearmente fra le due statistiche ordinate adiacenti. Il controllo numerico confronta questa formula esplicita con la funzione di R sui medesimi valori ricampionati.

$$h = 1 + (B-1)p, \qquad j = \lfloor h \rfloor, \qquad \gamma = h - j,$$
$$q_p^* = (1-\gamma)\widehat{\theta}^*_{(j)} + \gamma \widehat{\theta}^*_{(j+1)}.$$

Implementazione in R

Le parentesi nel pedice indicano l'ordinamento crescente delle statistiche. Agli estremi $p = 0$ e $p = 1$ si usano rispettivamente il minimo e il massimo, evitando indici esterni al vettore.

```
q95 <- function(v) unname(quantile(v,c
    (.025,.975),type=7))
```

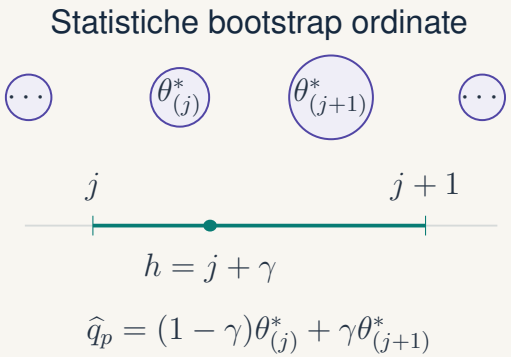
Richiami La notazione q* indica un quantile delle repliche; il livello p specifica quale frazione della distribuzione si considera.

Il quantile interpola fra statistiche ordinate

La convenzione type 7 di R associa alla probabilità p una posizione h nell'ordinamento delle B statistiche bootstrap. Qualora h non sia intero, il quantile viene interpolato fra i due valori adiacenti, con pesi che dipendono dalla parte frazionaria della posizione. La rappresentazione mostra quindi un'operazione sull'ordinamento delle statistiche, che deve essere dichiarata quando si richiede la riproduzione degli estremi percentili.

$$h = 1 + (B-1)p, \quad j = \lfloor h \rfloor, \quad \gamma = h - j, \qquad 0 < p < 1.$$

Lettura del diagramma



Si interpola fra due statistiche adiacenti.

La posizione illustrata è schematica. Per p = 0 o p = 1 si usano minimo e massimo.

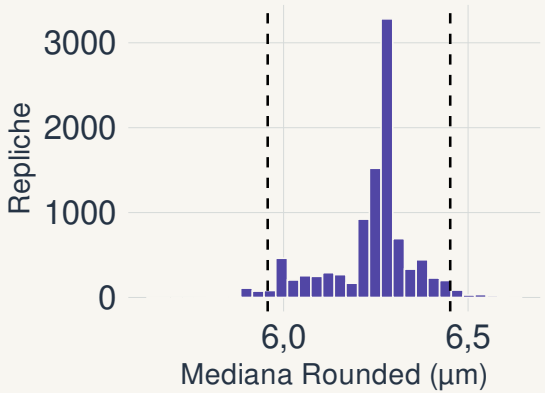
Richiami Le parentesi nel pedice indicano l'ordinamento, non l'indice della replica originaria.

Bootstrap della mediana

Il principio del ricampionamento può essere applicato alla mediana, mantenendo invariata la scelta degli individui come unità. La statistica cambia, per cui la distribuzione bootstrap può assumere una forma differente da quella della media. Nel gruppo Rounded la mediana osservata è 6,270 µm e l'intervallo percentile va da 5,957 a 6,452 µm. Valori ripetuti e campioni piccoli possono rendere la distribuzione fortemente discreta.

$$\widehat{m}^{*(b)} = \text{mediana}(x_{J_1^{*(b)}}, \ldots, x_{J_n^{*(b)}}).$$

Evidenza grafica



Diecimila mediane bootstrap Rounded. I limiti tratteggiati delimitano l'intervallo percentile.

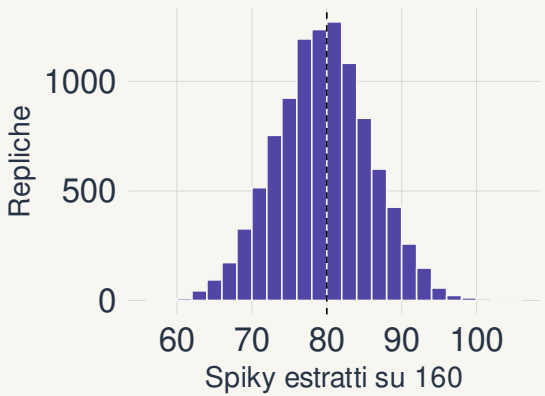
Richiami Le giustificazioni usuali per la mediana richiedono regolarità della distribuzione vicino al quantile di interesse.

Ricampionamento pooled e composizione casuale

Il ricampionamento pooled estrae centosessanta individui dall'insieme dei due morfotipi, consentendo alla loro composizione di cambiare fra repliche. Poiché la quota osservata di Spiky è un mezzo, il numero di individui Spiky selezionati segue una distribuzione binomiale condizionata al campione. Il procedimento rappresenta dunque una miscela con quote casuali, la cui incertezza comprende anche la variabilità della composizione.

$$N_S^* \mid \mathbf{x} \sim \mathrm{Bin}(160,\, 1/2),$$
$$\mathbb{E}_*(N_S^*) = 80, \qquad \mathrm{Var}_*(N_S^*) = 40.$$

Evidenza grafica



Nel pooled la numerosità totale resta 160; il numero di Spiky varia intorno a 80, mentre la loro quota varia intorno a 0,5.

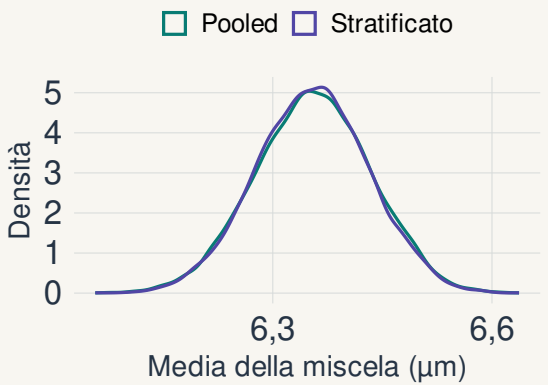
Richiami La distribuzione empirica pooled assegna uguale probabilità a ogni riga del file.

Ricampionamento stratificato a quote fisse

Il generatore dei fossili fissa ottanta osservazioni per ciascun morfotipo. Per riprodurre questo disegno si estraggono ottanta individui con reinserimento entro ciascun gruppo e si combinano le due medie con pesi un mezzo. Il ricampionamento conserva così le quote, lasciando variare i valori selezionati internamente. Nel confronto con il pooled, la stima osservata coincide, mentre cambia la distribuzione condizionata della statistica.

$$\widehat{\mu}^{*(b)}_{\mathrm{str}} = \tfrac{1}{2}\overline{X}^{*(b)}_{R} + \tfrac{1}{2}\overline{X}^{*(b)}_{S},$$
$$n^{*}_{R} = n^{*}_{S} = 80.$$

Evidenza grafica



Densità bootstrap pooled e stratificata sul medesimo campione sintetico.

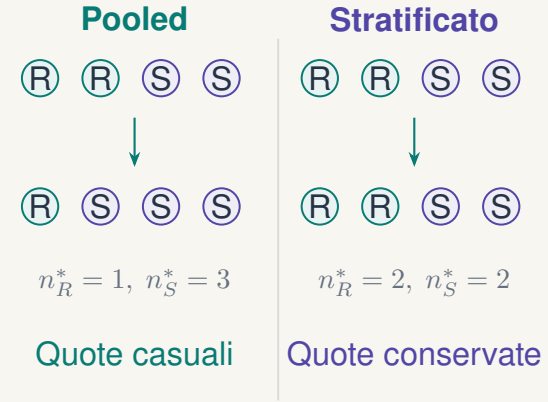
Richiami Il disegno stratificato fissa le numerosità interne e i pesi dell'estimando.

Le quote distinguono pooled e stratificato

Se il campione contiene gruppi con numerosità fissate dal disegno, il ricampionamento stratificato estrae separatamente entro ciascun gruppo, mantenendone le quote. Il pooled seleziona invece dall'insieme delle righe, per cui la composizione della replica può cambiare. Nel piccolo esempio, il numero complessivo rimane quattro in entrambi gli schemi, mentre soltanto il secondo conserva due unità per gruppo.

$$N_S^* \mid \text{pooled} \sim \mathrm{Bin}(4,\, 1/2),$$
$$N_S^* \mid \text{stratificato} = 2.$$

Lettura del diagramma



R e S indicano i due morfotipi. L'esempio usa quote 2/2; il dataset del corso ha quote 80/80.

Richiami La scelta dello schema dipende dal disegno e dall'estimando che si intende conservare.

Varianza entro gruppi e fra gruppi

La differenza fra pooled e stratificato si comprende applicando la decomposizione della varianza totale alla miscela. La variabilità individuale comprende la media delle varianze interne e un termine dovuto alla distanza fra le medie dei gruppi. Quando le quote sono fissate nel ricampionamento, la composizione non introduce variazione fra repliche. Il confronto va quindi interpretato rispetto al disegno, anche quando le due ampiezze risultano numericamente vicine.

$$\begin{aligned}\operatorname{Var}(X) &= \mathbb{E}[\operatorname{Var}(X \mid H)] \\ &\quad + \operatorname{Var}[\mathbb{E}(X \mid H)], \\ &= \tfrac{1}{2}\sigma_R^2 + \tfrac{1}{2}\sigma_S^2 + \tfrac{1}{4}(\mu_S - \mu_R)^2.\end{aligned}$$

Sviluppo e interpretazione

Qui H identifica il morfotipo e le quote della miscela sono entrambe un mezzo. Per campioni stratificati indipendenti di ottanta unità, il contributo alla varianza della media dipende soltanto dalle varianze interne.

$$\begin{aligned}&\operatorname{Var}(\widehat{\mu}_{\mathrm{str}}) \\ &= \frac{\sigma_R^2 + \sigma_S^2}{320}.\end{aligned}$$

Richiami La formula della miscela usa varianze di popolazione; i controlli R verificano anche l'identità empirica con denominatori coerenti.

Implementazione del bootstrap stratificato

Il codice estrae separatamente entro Rounded e Spiky, mantenendo entrambe le numerosità pari a ottanta. Poiché le medie ricampionate vengono combinate con pesi fissati a un mezzo, ogni replica riguarda lo stesso estimando. L'errore standard bootstrap risultante è 0,077 µm; quello ottenuto mediante la formula analitica plug-in è 0,076 µm. La piccola differenza riflette sia l'approssimazione Monte Carlo sia la varianza empirica usata dal bootstrap.

$$\mathrm{Var}_*(\widehat{\mu}^*_{\mathrm{str}}) = \tfrac{1}{4}\frac{79}{80^2}s_R^2 + \tfrac{1}{4}\frac{79}{80^2}s_S^2.$$

Implementazione in R

La varianza condizionata esatta usa il fattore $79/80$, coerentemente con la derivazione della media bootstrap. La verifica confronta la deviazione standard simulata con questa espressione.

```
set.seed(314)
b_strat <- replicate(B,.5*mean(sample(x,80,
    TRUE))+.5*mean(sample(y,80,TRUE)))
```

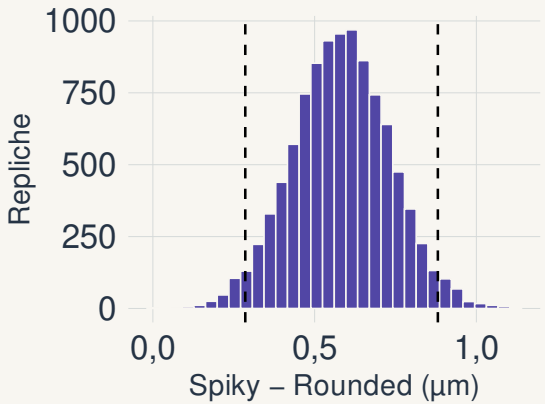
Richiami Le chiamate sample operano entro ciascun gruppo e usano replace = TRUE.

Bootstrap di una differenza fra gruppi

Per stimare il contrasto Spiky meno Rounded si ricampionano indipendentemente gli individui entro ciascun morfotipo e si sottraggono le due medie. Il segno mantiene così il medesimo significato in tutte le repliche. Il contrasto osservato è 0,582 µm, con intervallo percentile da 0,286 a 0,881 µm. La conclusione riguarda le popolazioni definite dal modello dei due gruppi e dal relativo campionamento.

$$\widehat{\Delta}^{*(b)} = \overline{X}_S^{*(b)} - \overline{X}_R^{*(b)}.$$

Evidenza grafica



Contrasto orientato S – R. I limiti percentili sono ricavati dalle 10.000 differenze ricampionate.

Richiami Il ricampionamento entro gruppi conserva l'appartenenza; una permutazione delle etichette risponderebbe a un'altra domanda.

Ricampionamento di coppie complete

Nel caso dei diametri totale e interno, la selezione deve riguardare il fossile insieme a entrambe le misure. Un modo equivalente consiste nel costruire prima le differenze individuali e ricampionare quel vettore. L'estrazione indipendente delle due colonne altererebbe la covarianza interna, producendo una distribuzione della differenza che non riproduce il disegno appaiato.

$$D_i = X_{i,\mathrm{tot}} - X_{i,\mathrm{int}},$$
$$\overline{D}^{*(b)} = \frac{1}{n}\sum_{j=1}^{n} D_{J_j^{*(b)}}.$$

Implementazione in R

Per Rounded, l'errore standard bootstrap della differenza media vale 0,027 µm, vicino al valore 0,028 µm ottenuto mediante la deviazione standard delle differenze e la numerosità delle coppie.

```
set.seed(1315)
b_paired <- boot_media(diff_coppie)
```

Richiami La relazione fra colonne è parte del dato: gli indici di selezione devono conservarla.

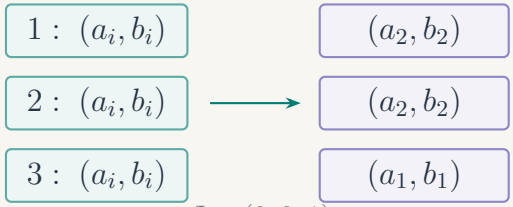
Nel ricampionamento appaiato si estraggono coppie

Quando le variabili sono misurate sullo stesso individuo, un indice estratto deve selezionare entrambe le colonne della coppia. La replica illustrata ripete due volte il secondo individuo e una volta il primo, conservando ogni associazione originaria. Applicare indici indipendenti alle due colonne produrrebbe combinazioni che non corrispondono alle coppie osservate e modificherebbe la covarianza da cui dipende l'incertezza della differenza.

$$(A_j^*, B_j^*) = (a_{J_j}, b_{J_j}),$$
$$\overline{D}^* = \frac{1}{n}\sum_j (a_{J_j} - b_{J_j}).$$

Lettura del diagramma

Selezionare l'individuo conserva la coppia



$$J = (2, 2, 1)$$
$$D_j^* = a_{J_j} - b_{J_j}$$

Lo stesso indice seleziona entrambe le colonne.

Le lettere a e b indicano due misure dello stesso individuo. Gli indici della replica sono (2, 2, 1).

Richiami Calcolare prima le differenze e ricampionarle equivale a ricampionare le coppie complete.

Bootstrap delle medie di stazione

Per l'estimando che assegna uguale peso alle stazioni, si possono ricampionare le sei medie locali, assumendo che costituiscano unità indipendenti e identicamente distribuite nel dominio d'inferenza. Ogni replica seleziona sei stazioni con reinserimento e ne calcola la media equiponderata. Tale procedura rappresenta un livello specifico del disegno e richiede una giustificazione della selezione dei siti.

$$J_g^* \overset{\text{iid}}{\sim} \text{Unif}\{1, \dots, G\},$$

$$\widehat{\theta}_G^* = \frac{1}{G} \sum_{g=1}^{G} \overline{\rho}_{J_g^*}, \qquad G = 6.$$

Implementazione in R

Nel disegno bilanciato, selezionare una stazione con tutti i suoi provini e calcolare la media complessiva equivale a ricampionare le medie locali. Con numerosità diverse, le due procedure possono implicare pesi differenti.

```
set.seed(316)
b_righe <- boot_media(d$densita)
b_stazioni <- boot_media(st$densita)
```

Richiami L'unità primaria qui è la stazione. Sei unità costituiscono una base limitata per valutare code e copertura.

La replica per stazioni conserva il livello primario

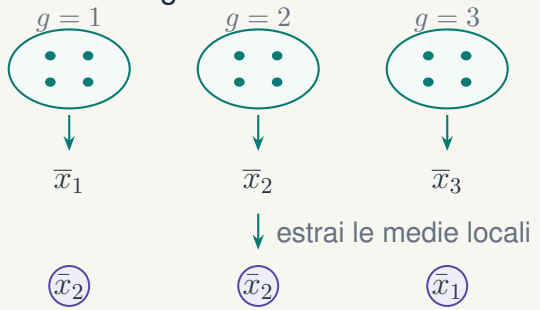
Per l'estimando che assegna uguale peso alle stazioni, si possono ricampionare le medie locali quando le stazioni costituiscono unità indipendenti e rappresentative del dominio. Nel disegno bilanciato, selezionare una stazione con tutti i suoi provini conduce alla stessa media complessiva che si ottiene selezionando la sua media locale. Il diagramma riduce il numero dei gruppi per mostrare l'operazione, mantenendo quattro provini per gruppo.

$$\widehat{\theta}^{*} = \frac{1}{G}\sum_{j=1}^{G} \overline{x}_{J_j},$$

$$J_j \overset{\text{iid}}{\sim} \text{Unif}\{1, \ldots, G\}.$$

Lettura del diagramma

Le stazioni vengono selezionate come unità



$$\widehat{\theta}^{*} = (\bar{x}_2 + \bar{x}_2 + \bar{x}_1)/3$$

Sono mostrate tre stazioni illustrative. Nei calcoli del modulo le stazioni osservate e ricampionate sono sei.

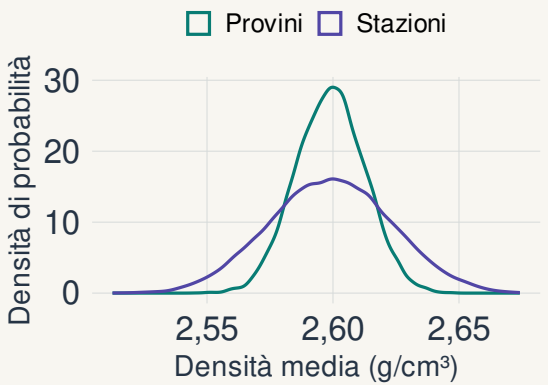
Richiami La giustificazione dell'indipendenza e della rappresentatività dei siti precede il ricampionamento.

Confronto fra provini e stazioni

Il bootstrap delle ventiquattro righe tratta i provini come unità indipendenti, mentre quello delle medie locali attribuisce l'indipendenza alle sei stazioni. Nel caso didattico, gli errori standard sono rispettivamente 0,014 e 0,024 g/cm^3. La differenza quantifica l'effetto dei due schemi sullo stesso campione; la scelta scientifica deve dipendere dalla struttura di dipendenza e dall'estimando, anziché dall'ampiezza preferita.

$$\widehat{\mathrm{SE}}_{\mathrm{righe}} = 0{,}014,$$
$$\widehat{\mathrm{SE}}_{\mathrm{stazioni}} = 0{,}024\ \mathrm{g\,cm^{-3}}.$$

Evidenza grafica



Distribuzioni condizionate della media, con 10.000 repliche per ciascuno schema.

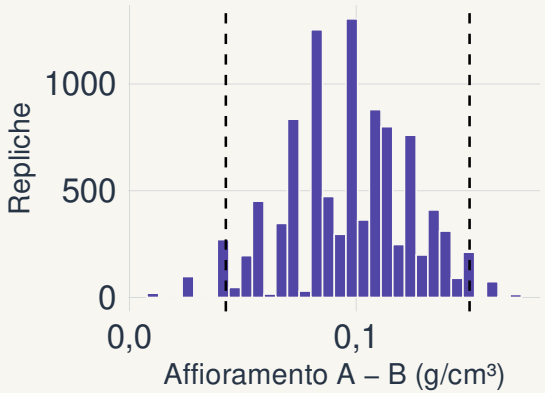
Richiami Il confronto osservato non stabilisce un ordinamento universale fra gli errori standard.

Affioramenti conservati come strati

Le sei stazioni appartengono a due affioramenti, ciascuno rappresentato da tre siti. Per il contrasto A meno B si ricampionano le medie di stazione entro ciascun affioramento, mantenendo separate le due appartenenze. Il contrasto osservato vale 0,097 g/cm^3 e l'intervallo percentile va da 0,042 a 0,150 g/cm^3. La ridotta numerosità dei siti limita la capacità del ricampionamento di rappresentare la variabilità delle popolazioni.

$$\widehat{\Delta}^*_{AB} = \frac{1}{3}\sum_{j=1}^{3} \overline{\rho}_{A,J_j^*} - \frac{1}{3}\sum_{j=1}^{3} \overline{\rho}_{B,K_j^*}.$$

Evidenza grafica



Tre stazioni ricampionate entro A e tre entro B. I limiti sono condizionati a queste sei stazioni.

Richiami Il contrasto fra affioramenti non implica un effetto causale dell'appartenenza geologica.

Numerosità diseguali e obiettivo dell'aggregazione

Quando le stazioni contengono quantità diverse di provini, il ricampionamento dei gruppi interi richiede una regola di aggregazione esplicita. La media delle medie equipondera le stazioni estratte, mentre il rapporto fra somma dei valori e numero totale di provini assegna peso proporzionale alla numerosità. Le due statistiche rispondono a estimandi differenti, pur conservando entrambe la struttura interna ai gruppi.

$$\widehat{\theta}^*_{\text{siti}} = \frac{1}{G}\sum_{g=1}^{G} \overline{\rho}_{J_g^*},$$

$$\widehat{\theta}^*_{\text{provini}} = \frac{\sum_g n_{J_g^*}\overline{\rho}_{J_g^*}}{\sum_g n_{J_g^*}}.$$

Sviluppo e interpretazione

G conta le stazioni estratte, J_g^* identifica la stazione selezionata, n_j la sua numerosità e $\overline{\rho}_j$ la sua media. Se la selezione avviene a più stadi, il ricampionamento deve riprodurre i livelli casuali del disegno; un secondo ricampionamento entro sito può alterare la varianza.

Richiami Con stazioni bilanciate le due espressioni coincidono; l'equivalenza non si estende automaticamente ai disegni diseguali.

Aggregazione di gruppi diseguali

Quando le stazioni contengono quantità diverse di provini, la selezione dei gruppi deve essere accompagnata dalla definizione della statistica da ricalcolare. La media delle medie locali attribuisce uguale peso a ogni stazione selezionata, mentre il rapporto fra somma dei valori e numero dei provini assegna peso proporzionale alla numerosità. Le due espressioni coincidono soltanto sotto condizioni particolari, fra le quali rientra il disegno bilanciato.

$$\widehat{\theta}^{*}_{\text{siti}} = G^{-1} \sum_{j} \overline{x}_{J_j},$$

$$\widehat{\theta}^{*}_{\text{provini}} = \frac{\sum_{j} n_{J_j} \overline{x}_{J_j}}{\sum_{j} n_{J_j}}.$$

Lettura del diagramma

Una replica con gruppi di diversa numerosità



$$\widehat{\theta}^{*}_{\text{siti}} = (\bar{x}_A + \bar{x}_B)/2$$

$$\widehat{\theta}^{*}_{\text{provini}} = (2\bar{x}_A + 8\bar{x}_B)/10$$

Esempio con due gruppi selezionati, di dimensioni due e otto. I punti rappresentano unità, non misure.

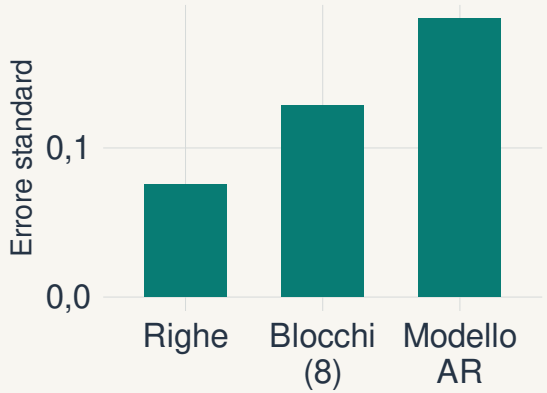
Richiami Conservare la struttura dei gruppi non determina da solo quale estimando venga riprodotto.

Dipendenza temporale e ricampionamento a blocchi

In una serie dipendente, estrarre singole righe distrugge le relazioni temporali fra osservazioni vicine. Il ricampionamento di blocchi contigui conserva parte di questa struttura, pur introducendo una scelta ulteriore nella lunghezza del blocco. L'esempio usa una serie AR(1) simulata con coefficiente 0,7 e confronta il bootstrap IID, blocchi mobili di otto valori e l'errore standard teorico della media sotto il modello generatore.

$$X_t = \phi X_{t-1} + \varepsilon_t, \quad \phi = 0{,}7,$$
$$\mathrm{Var}(X_t) = 1, \quad \gamma(h) = \phi^{|h|}.$$

Evidenza grafica



Serie stazionaria di 160 valori, con innovazioni ε_t IID di media zero e varianza $1 - 0{,}7^2$. Il blocco di otto è illustrativo, senza garanzia di copertura.

Richiami Questo esempio anticipa M09: lunghezza del blocco, stazionarietà e tendenza richiedono valutazioni specifiche.

Il blocco conserva un tratto della dipendenza

Nel bootstrap a blocchi mobili si selezionano segmenti contigui della serie, mantenendo l'ordine delle osservazioni entro ciascuno di essi. Il piccolo esempio rende espliciti selezione, concatenazione e troncamento, necessari quando la lunghezza complessiva dei blocchi supera quella del campione. Poiché le giunzioni introducono vicinanze artificiali, la procedura conserva soltanto parte della dipendenza e richiede una scelta motivata della lunghezza del blocco.

$$J_k \overset{\text{iid}}{\sim} \mathrm{Unif}\{1, \dots, n-\ell+1\},$$
$$B_k = (X_{J_k}, \dots, X_{J_k+\ell-1}),$$
$$X^* = \mathrm{concat}(B_1, \dots, B_K)_{1:n}.$$

Lettura del diagramma



L'ordine interno sopravvive entro ciascun blocco.

Gli interi indicano posizioni temporali. L'esempio usa n = 8 e ℓ = 3; il caso AR(1) del modulo usa n = 160 e ℓ = 8.

Richiami La lunghezza del blocco governa il compromesso fra dipendenza conservata e variabilità del ricampionamento.

Informazione disponibile e limiti del bootstrap

Il bootstrap utilizza soltanto i valori osservati e le relazioni che lo schema di ricampionamento conserva. Di conseguenza, una base territoriale incompleta, un errore sistematico di misura o un numero molto ridotto di stazioni restano limiti dell'analisi. Aumentare le repliche consente di descrivere più precisamente la distribuzione condizionata costruita, mentre la giustificazione dell'inferenza richiede informazioni sul processo che ha prodotto il campione.

Sviluppo e interpretazione

Per la media di sei stazioni, il percentile va da 2,553 a 2,645 g/cm^3. L'intervallo t sulle sei medie va da 2,532 a 2,666 g/cm^3, sotto normalità e indipendenza delle medie locali. La differenza fra metodi va riportata insieme alle rispettive ipotesi.

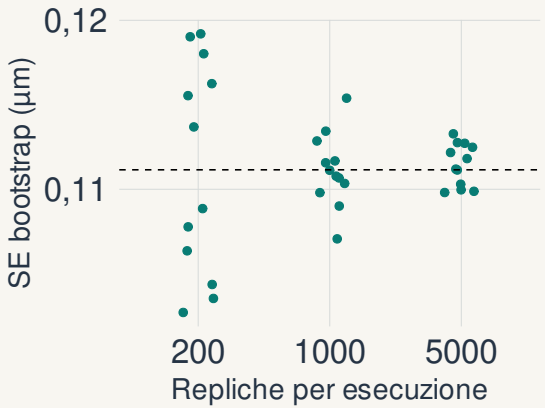
Richiami La sensibilità al metodo è informativa; scegliere il metodo perché produce l'intervallo più stretto non giustifica l'inferenza.

Errore Monte Carlo e numero delle repliche

Con il campione fissato, si ripete il calcolo dell'errore standard bootstrap mediante dodici esecuzioni indipendenti per ciascun valore di B. La dispersione fra esecuzioni misura l'approssimazione numerica del procedimento. Nel caso della media Rounded è disponibile il valore condizionato esatto, per cui il confronto permette di separare la precisione della simulazione dall'incertezza inferenziale associata agli ottanta individui osservati.

$$\mathrm{SE}_* = \sqrt{\frac{n-1}{n^2}s^2}, \qquad n = 80.$$

Evidenza grafica



Linea tratteggiata: SE condizionato esatto. Ogni punto deriva da una nuova sequenza bootstrap.

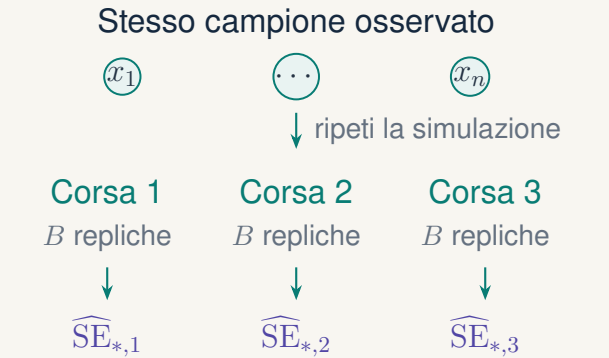
Richiami B controlla l'approssimazione Monte Carlo; n appartiene al campione e resta invariato.

Ripetere la simulazione misura l’approssimazione

Per valutare la precisione Monte Carlo, si mantiene fisso il campione e si esegue più volte il bootstrap, usando nuove sequenze pseudocasuali. Ogni corsa produce una stima dell’errore standard o degli estremi percentili, la cui variabilità descrive l’approssimazione numerica. Il confronto fra valori diversi di B consente quindi di stabilire quanto la sintesi dipenda dal numero delle repliche, senza confondere tale variazione con quella dovuta al campionamento dei dati.

$$\widehat{\mathrm{SE}}_{*,r} = \mathrm{sd}(\widehat{\theta}^{*(1,r)}, \ldots, \widehat{\theta}^{*(B,r)}), \quad r = 1, \ldots, R.$$

Lettura del diagramma



La dispersione fra corse misura l’errore numerico.

Il laboratorio N18 utilizza dodici corse per ciascuno dei valori B = 200, 1.000 e 5.000.

Richiami La stabilità numerica di un intervallo non dimostra l’adeguatezza del modello o del disegno.

Probabilità simulate e precisione Monte Carlo

La frequenza con cui una statistica simulata soddisfa una condizione è la media di indicatori. Condizionatamente ai dati, repliche indipendenti consentono quindi di applicare la formula binomiale al suo errore Monte Carlo. Per una probabilità 0,025 e diecimila repliche, tale errore è circa 0,00156. Questa quantità riguarda la probabilità simulata, mentre la precisione di un quantile dipende anche dalla forma locale della distribuzione.

$$\widehat{p}_B = \frac{1}{B}\sum_{b} \mathbf{1}\{\widehat{\theta}^{*(b)} \le t\},$$

$$\mathrm{SE}_{\mathrm{MC}}(\widehat{p}_B) = \sqrt{\frac{p_*(1-p_*)}{B}}.$$

Sviluppo e interpretazione

Qui t è una soglia fissata e $p_* = \Pr_*(\widehat{\theta}^* \le t)$ la probabilità condizionata ai dati. Per valutare gli estremi percentili, il laboratorio salva i limiti in dodici esecuzioni indipendenti. Il confronto fra corse distingue la stabilità numerica dalle proprietà inferenziali.

Richiami La formula binomiale quantifica la variabilità di una frequenza; non fornisce direttamente il SE del quantile.

Seme, algoritmo e tracciabilità dell'esecuzione

La riproduzione numerica richiede che dati, algoritmo pseudo-casuale, seme e versioni dei pacchetti siano documentati. Il progetto assegna semi distinti agli esperimenti, affinché una modifica a una simulazione non sposti le sequenze delle altre. I frammenti presenti nelle slide sono estratti dal codice eseguito, mentre risultati e informazioni di sessione vengono salvati in file separati.

Implementazione in R

Il comando iniziale specifica il generatore uniforme, il metodo per le normali e l'algoritmo di campionamento discreto. Il controllo di riproducibilità riesegue l'intero progetto da una cartella contenente soltanto dati e sorgenti.

```
RNGkind('Mersenne-Twister','Inversion','
    Rejection')
```

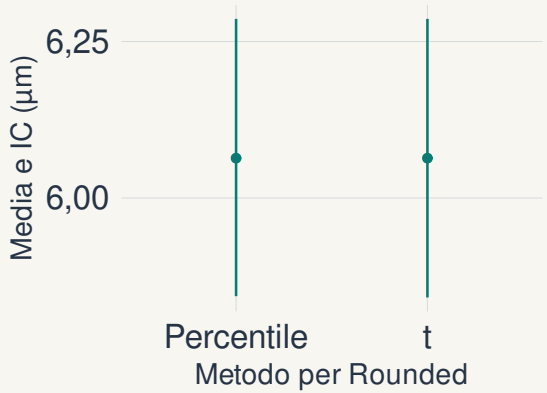
Richiami La riproducibilità del risultato numerico documenta il calcolo; la validità scientifica dipende anche dal disegno.

Confronto fra intervallo t e percentile

Sul medesimo campione Rounded, l'intervallo t e quello percentile risultano vicini. La concordanza è compatibile con una distribuzione bootstrap della media pressoché simmetrica, ma conserva le differenze fra le due costruzioni: il primo utilizza un perno con validità esatta sotto normalità IID, mentre il secondo ricava i limiti dalla distribuzione condizionata delle repliche. Entrambi richiedono coerenza fra unità osservate e popolazione di riferimento.

$$C_t = [5{,}841;\ 6{,}286],$$
$$C_{\text{perc}} = [5{,}843;\ 6{,}286]\ \mu\text{m}.$$

Evidenza grafica



Entrambi gli intervalli riguardano la media Rounded, stimata sugli stessi 80 individui.

Richiami Il confronto tiene fisso l'estimando; modificare contemporaneamente metodo e popolazione impedirebbe una lettura univoca.

Costruzione di una figura con ggplot2

Una figura didattica deve rendere leggibili le unità e la relazione fra osservazioni e sintesi. Per i provini, l'asse orizzontale distingue le stazioni e il colore identifica l'affioramento, mentre un lieve spostamento orizzontale separa i punti sovrapposti senza alterarne la densità. Le medie locali vengono aggiunte mediante uno strato distinto, affinché il lettore possa confrontarle con la dispersione interna.

Implementazione in R

Il tema comune mantiene Nimbus Sans e palette originali. La leggibilità degli assi viene controllata nel PDF finale.

```
p <- ggplot(d,aes(stazione,densita,colour=
    affioramento))+
 geom_point(size=3,position=position_jitter(
    width=.12,height=0,seed=1))+
 geom_point(data=st,shape=18,size=5)+scale_
    colour_manual(values=col_geo)+
 scale_y_continuous(labels=fmt,breaks=c
    (2.5,2.6,2.7))+labs(x='Stazione',y='
    Densità (g/cm³)')
```

Richiami Lo spostamento grafico agisce soltanto sull'asse categorico; i valori verticali restano quelli misurati.

Redazione di una conclusione inferenziale

Una conclusione completa collega il valore stimato alla popolazione dichiarata, all'unità di campionamento e alle ipotesi del metodo. Per il campione di stazioni, la media equiponderata è 2,599 g/cm^3 e il percentile bootstrap va da 2,553 a 2,645 g/cm^3. La lettura deve precisare che il calcolo assume medie locali IID e che i sei siti sintetici offrono una rappresentazione limitata della variabilità territoriale.

Sviluppo e interpretazione

La relazione di laboratorio riporta anche il numero di provini, il numero di stazioni, le diecimila repliche, il seme e la convenzione dei quantili. Il confronto con lo schema per righe documenta la sensibilità alla definizione dell'unità indipendente.

Richiami La quantità stimata, le ipotesi e il dominio devono essere riconoscibili nella stessa conclusione.

Esercizio 1: pesi e stazione tipica

Due stazioni presentano medie di densità pari a 2,4 e 2,8 g/cm^3, con rispettivamente due e otto provini. Si richiede di calcolare la media complessiva dei provini e la media equiponderata delle stazioni, motivando quale descriva una stazione scelta con uguale probabilità fra le due. Occorre inoltre spiegare quale informazione aggiuntiva servirebbe per estendere la conclusione a un territorio più ampio.

$$(n_1, \overline{\rho}_1) = (2{,}2{,}4), \qquad (n_2, \overline{\rho}_2) = (8{,}2{,}8).$$

Sviluppo e interpretazione

La soluzione deve esplicitare i pesi prima del calcolo e conservare l'unità g/cm^3. Un risultato numerico accompagnato soltanto dalla parola media lascia ambiguo l'estimando.

Richiami Laboratorio collegato: N09. Criteri: estimando, pesi, calcolo e dominio d'inferenza.

Soluzione 1: due aggregazioni esplicite

La media dei provini assegna peso 0,2 alla prima stazione e 0,8 alla seconda, producendo 2,72 g/cm^3. La media equiponderata assegna invece peso un mezzo a ciascun sito e vale 2,60 g/cm^3. Quest'ultima descrive la scelta uniforme fra le due stazioni osservate. Per riferirla a un territorio occorrerebbe giustificare che i siti selezionati rappresentino la popolazione di stazioni d'interesse.

$$\widehat{\theta}_{\text{provini}} = \frac{2 \cdot 2{,}4 + 8 \cdot 2{,}8}{10} = 2{,}72,$$
$$\widehat{\theta}_{\text{siti}} = \frac{2{,}4 + 2{,}8}{2} = 2{,}60.$$

Sviluppo e interpretazione

Il diverso risultato dipende dalla ponderazione. La maggiore numerosità di provini nella seconda stazione non dimostra, da sola, che quel sito debba rappresentare una porzione maggiore del territorio.

Richiami La ponderazione discende dalla quantità d'interesse e dal disegno, che devono precedere il calcolo.

Esercizio 2: covarianza e numerosità effettiva

Un disegno comprende sei stazioni indipendenti con quattro provini per stazione. Si assuma varianza marginale unitaria e correlazione comune 0,6 entro sito. Si richiede di contare le coppie interne, ricavare la varianza della media e confrontarla con quella ottenuta assumendo ventiquattro osservazioni indipendenti. La numerosità effettiva dovrà essere interpretata rispetto a questo modello, indicando quale ipotesi ne limita la generalizzazione.

$$G = 6, \qquad m = 4, \qquad \sigma^2 = 1, \qquad \eta = 0{,}6.$$

Sviluppo e interpretazione

La derivazione deve partire dalla somma delle covarianze. La verifica R costruisce una matrice con sei blocchi indipendenti, ciascuno dei quali contiene le covarianze dei quattro provini.

Richiami Laboratorio collegato: N04. Esplicitare la differenza fra numerosità osservata e numerosità equivalente per la varianza.

Soluzione 2: contributo delle coppie interne

Ogni stazione contiene sei coppie non ordinate e il disegno ne comprende trentasei. Il contributo delle covarianze entra due volte nella varianza della somma, producendo $24 + 2 \cdot 36 \cdot 0,6 = 67,2$. Dividendo per 24^2, la varianza della media è circa 0,1167, pari a 2,8 volte il valore indipendente. La numerosità equivalente è circa 8,57 e descrive esclusivamente l'informazione sulla media entro il modello assunto.

$$\mathrm{Var}(\overline{X}) = \frac{67,2}{576} = 0,116\overline{6},$$

$$\mathrm{DEFF} = 2,8, \qquad n_{\mathrm{eff}} = \frac{24}{2,8} \approx 8,57.$$

Sviluppo e interpretazione

Il caso usa G = 6 stazioni, m = 4 provini per sito, varianza marginale uno e correlazione interna 0,6. Equicorrelazione, varianze uguali e indipendenza fra siti giustificano l'espressione. Con strutture diverse occorre usare la matrice di covarianza pertinente.

Richiami n effettivo è una quantità equivalente per una statistica e un modello, non un nuovo conteggio di provini.

Esercizio 3: confidenza e copertura

Si osserva un campione normale IID di venti valori con media 5,4 e deviazione standard due. Si richiede di costruire l'intervallo t al 95%, indicare quali quantità siano casuali prima del campionamento e spiegare il significato frequentista del livello nominale. Successivamente si confronterà tale interpretazione con la proporzione di copertura ottenuta nei duemila esperimenti simulati.

$$n = 20, \qquad \overline{x} = 5{,}4, \qquad s = 2.$$

Sviluppo e interpretazione

La spiegazione deve distinguere il parametro fissato, gli estremi casuali della procedura e gli estremi numerici del singolo intervallo osservato. Deve inoltre motivare perché la frequenza simulata possa oscillare attorno a 0,95.

Richiami Laboratori collegati: N06 e N07. La probabilità di copertura appartiene alla procedura ripetuta.

Soluzione 3: intervallo e ripetizione ideale

Il quantile t a diciannove gradi di libertà è circa 2,093, da cui segue una semiampiezza di circa 0,936. L'intervallo osservato è pertanto circa $[4,464; 6,336]$. Sotto il modello normale IID, ripetendo campionamento e costruzione si ottengono intervalli che includono il parametro nel 95% delle ripetizioni. La proporzione osservata in un numero finito di simulazioni è una stima di tale probabilità.

$$a = 2{,}093\frac{2}{\sqrt{20}} \approx 0{,}936,$$
$$C_{0,95} \approx [4{,}464;\ 6{,}336].$$

Sviluppo e interpretazione

Il campione ha n = 20, media 5,4 e deviazione standard 2. Dopo l'osservazione gli estremi sono numeri fissati: la procedura frequentista non assegna automaticamente una probabilità al parametro condizionata a questo particolare intervallo.

Richiami La copertura esatta del 95% discende dalle ipotesi e dal perno, non dal numero di decimali riportati.

Esercizio 4: schema di ricampionamento

Si confrontino tre problemi: media di una miscela con quote di morfotipo fissate, differenza fra due misure sullo stesso fossile e media equiponderata di stazioni indipendenti. Per ciascuno si specifichino l'unità estratta, le appartenenze da conservare e la statistica ricalcolata. La risposta dovrà spiegare quale informazione verrebbe alterata ricampionando indistintamente tutte le righe o tutte le colonne.

Sviluppo e interpretazione

La soluzione deve tradurre il disegno in un algoritmo verificabile. Sono richiesti gli indici estratti, la numerosità di ciascuna replica e una formula della statistica, accompagnati da una breve interpretazione.

Richiami Laboratori collegati: N14, N15 e N16. Valutare la corrispondenza fra algoritmo ed estimando.

Soluzione 4: conservazione della struttura

Per la miscela a quote fisse si estraggono ottanta individui entro ciascun morfotipo e si combinano le medie con pesi un mezzo. Per le misure appaiate si selezionano coppie complete, oppure differenze individuali già calcolate. Per le stazioni si estraggono sei medie locali con reinserimento. Ogni schema preserva una diversa struttura, che appartiene alla definizione dell'esperimento di campionamento.

$$\widehat{\mu}^{*}_{\mathrm{str}} = \tfrac{1}{2}\overline{X}^{*}_{R} + \tfrac{1}{2}\overline{X}^{*}_{S},$$

$$\overline{D}^{*} = \frac{1}{n}\sum_{j} D_{J^{*}_{j}}, \qquad \widehat{\theta}^{*}_{G} = \frac{1}{G}\sum_{g} \overline{\rho}_{J^{*}_{g}}.$$

Sviluppo e interpretazione

Il pooled rende casuali le quote, la selezione indipendente delle colonne rompe l'appaiamento e il bootstrap per provini omette la dipendenza entro stazione. Le conseguenze vanno valutate rispetto al parametro dichiarato.

Richiami La scelta dello schema precede il confronto degli intervalli ottenuti.

La struttura dei dati orienta il ricampionamento

La scelta dell'unità da estrarre richiede che siano già definiti estimando, disegno e relazioni fra le osservazioni. Lo schema raccoglie alcuni casi studiati nel modulo, indicando quale struttura debba essere conservata nella replica. Qualora più strutture siano presenti contemporaneamente, come stazioni raggruppate entro affioramenti, il procedimento deve combinarle in modo coerente, esplicitando le ulteriori ipotesi richieste.

Lettura del diagramma

Struttura dichiarata del campione

Individui indipendenti	→	Righe
Misure appaiate	→	Coppie
Quote fissate	→	Entro strato
Dipendenza entro sito	→	Stazioni
Dipendenza temporale	→	Blocchi

Raccordo per gli esercizi: ogni riga richiede le ipotesi discusse nelle rispettive sezioni.

Richiami Il diagramma orienta la scelta; l'adeguatezza inferenziale richiede una giustificazione specifica.

Consegna applicativa: una relazione riproducibile

La relazione finale confronta la media pooled dei fossili con la media equiponderata dei morfotipi ricampionati separatamente. Si richiedono controllo dei dati, definizione dell'estimando, descrizione degli schemi, figura delle distribuzioni bootstrap e tabella con stime, errori standard e limiti percentili. La discussione deve collegare le differenze al generatore a quote fisse e indicare quali conclusioni restino condizionate alla natura sintetica del caso.

Sviluppo e interpretazione

Il progetto consegnato comprende script eseguibili dalla radice, CSV di input, risultati non arrotondati, versione di R e pacchetti, semi e figura vettoriale. Il testo finale deve essere comprensibile anche a chi non ha assistito al laboratorio.

Richiami Laboratori N13–N18. La rubrica completa e le soluzioni dei venti laboratori sono nel fascicolo allegato.

Risultati attesi e criteri di discussione

La media osservata coincide nei due schemi ed è 6,355 µm. Il pooled produce errore standard 0,079 µm e intervallo $[6,201; 6,506]$, mentre lo stratificato produce 0,077 µm e intervallo $[6,201; 6,504]$. Il secondo conserva le quote del generatore. La vicinanza numerica degli estremi non elimina la differenza fra i disegni, che deve essere esplicitata nella conclusione.

Sviluppo e interpretazione

Il campione contiene 80 Rounded e 80 Spiky; la media stratificata usa pesi 1/2 e 10.000 repliche entro gruppo. La valutazione assegna due punti a ciascuna dimensione: quantità d'interesse, controllo dei dati, metodo, interpretazione e riproducibilità.

Richiami I limiti percentili dipendono dal seme e da B; la tabella completa conserva i valori prima dell'arrotondamento.

Notazione e ipotesi essenziali

La notazione deve consentire di riconoscere l'oggetto a cui appartiene ogni misura di variabilità. σ descrive la dispersione di popolazione, S quella stimata dai dati, mentre SE riguarda una statistica su campioni ripetuti. Il numero n conta le unità del campione, G le stazioni e B le repliche bootstrap. Il simbolo asterisco indica sempre una quantità condizionata al campione osservato.

Sviluppo e interpretazione

Le derivazioni richiamano, quando necessarie, indipendenza, identica distribuzione, momenti finiti, normalità o struttura stratificata. Un'identità algebrica resta distinta dalla sua interpretazione probabilistica, che richiede il modello dichiarato nella pagina.

Richiami Le formule della varianza, della copertura e del ricampionamento vanno lette insieme alle rispettive ipotesi.

Fonti e percorso successivo

Il modulo utilizza dati e casi del corso, documentazione primaria di R e riferimenti didattici aperti per verificare terminologia e procedure. Testi, derivazioni, figure ed esercizi sono stati ricostruiti per questo percorso. Il modulo M06 svilupperà i confronti fra gruppi, collegando dimensione dell'effetto, intervalli e test alla struttura del campionamento che qui è stata esplicitata.

Sviluppo e interpretazione

[RSTATS] R Core Team: t.test e funzioni statistiche. [BOOT] Documentazione del pacchetto boot: ricampionamento e strati. [RQUANT] quantile: convenzioni dei quantili. [NIST] Confidence Limits for the Mean. [GGPLOT] Documentazione di ggplot2. [CORSO] Materiali e CSV forniti. [DER] Derivazioni e simulazioni del corso.

Richiami URL, data di consultazione e impiego delle fonti sono riportati nella documentazione del progetto.