P02 · REVISIONE R6

Foraminiferi, coppe e campagne

Copertura temporale, confronti appaiati e limiti di quattro repliche

22 slide · teoria, derivazioni, figure e applicazioni in R.
Provenienza dei dati e sorgenti nei materiali allegati.

P02

Percorso del modulo

3 Fonte e supporto delle osservazioni

6 Copertura e definizione del confronto

14 Incertezza con quattro unità

20 Interpretazione e nuova raccolta

I numeri indicano le pagine iniziali; i titoli sono cliccabili. Codice, figure e verifiche sono inclusi nel progetto.

Una domanda sulla variazione della taglia

Il progetto esamina il diametro massimo medio di Neogloboquadrina pachyderma in coppe di una trappola sedimentaria della Penisola Antartica occidentale, collocata a 170 metri di profondità. L’estratto PANGAEA conserva trentasei righe del supplemento di Mikis e collaboratori, con date centrali e sintesi morfometriche. La domanda confronta le fasce calendario ottobre–marzo e aprile–settembre nelle campagne che le rappresentano entrambe. Le fasce definiscono un criterio temporale di raggruppamento, del quale occorre distinguere il significato dalle condizioni ambientali effettivamente vissute dagli organismi.

Lettura del diagramma



Schema non in scala.

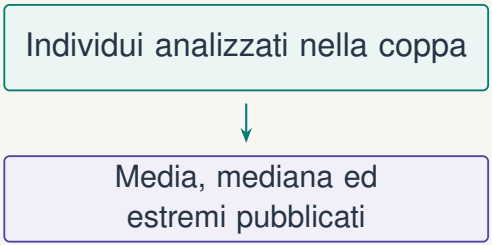
Richiami La domanda deve rispettare il supporto temporale e materiale della misura disponibile.

Mikis et al., 2019; PANGAEA.902776, CC BY 4.0

La riga rappresenta una sintesi di coppa

Ogni riga contiene una sintesi degli individui analizzati nella coppa, con media, mediana, minimo e massimo del diametro massimo. La tabella selezionata non include il numero degli individui né la loro deviazione standard, per cui queste quantità non possono essere ricostruite a partire dai soli estremi. Il confronto usa medie di coppa e mantiene esplicita questa unità. Aumentare il numero di gusci misurati entro una coppa e aumentare il numero di campagne indipendenti migliorerebbe componenti differenti dell'informazione.

Lettura del diagramma



Una riga conserva una sintesi già eseguita.

Richiami Il livello di aggregazione della fonte determina quali quantità siano identificabili dai dati.

Controlli sul dizionario e sulle sintesi

La coppia campagna–coppa identifica ogni riga e viene verificata prima del raggruppamento. Il codice controlla profondità, conversione delle date e ordine fra minimo, media e massimo, mantenendo le unità in micrometri. Gli estremi descrivono la dispersione degli individui osservati e non costituiscono un intervallo di confidenza della media. La data rappresenta il punto centrale attribuito alla coppa; la durata della raccolta e il flusso di gusci richiederebbero metadati ulteriori per una ponderazione temporale o quantitativa.

Implementazione in R

```
d <- read.csv('dati/progetti/foraminiferi.
    csv')
d$date <- as.Date(d$date)
stopifnot(nrow(d)==36,
 !anyDuplicated(paste(d$trap_year,d$cup_id))
    ,
 all(d$depth_m==170),
 all(d$diam_min_um<=d$diam_mean_um),
 all(d$diam_mean_um<=d$diam_max_um))
head(d)
```

Richiami La plausibilità delle sintesi non sostituisce le informazioni sul protocollo e sul numero degli individui.

Due fasce calendario definite prima del calcolo

La classificazione assegna ottobre, novembre, dicembre, gennaio, febbraio e marzo alla prima fascia, lasciando aprile–settembre alla seconda. Il mese viene ricavato dalla data centrale della coppa e la campagna mantiene l'identificativo fornito nella fonte. Questa regola è riproducibile, ma non misura direttamente temperatura, luce, alimento o condizioni di dissoluzione. La denominazione delle fasce conserva pertanto i mesi effettivi, evitando di trasformare il raggruppamento in una diagnosi automatica del meccanismo stagionale.

$$S_i = \begin{cases} 1, & m_i \in \{10,11,12,1,2,3\}, \\ 0, & m_i \in \{4,5,6,7,8,9\}. \end{cases}$$

Sviluppo e interpretazione

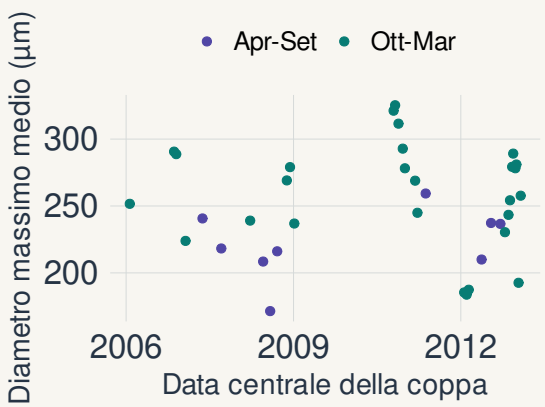
m_i: mese della data centrale della coppa i; S_i: indicatore della fascia ottobre–marzo. Una diversa definizione modificherebbe il confronto e andrebbe giustificata prima dell'esito. Per coppe che attraversano il confine, la data centrale è una convenzione, la cui sensibilità può essere studiata con le date di apertura e chiusura.

Richiami La regola temporale definisce il confronto e mantiene distinti calendario e processo ambientale.

L’irregolarità temporale resta visibile

Le trentasei medie sono rappresentate alle rispettive date centrali senza unirle mediante una linea continua. Questa scelta conserva le lacune e la diversa densità di campionamento, evitando che il disegno suggerisca valori nei periodi privi di osservazioni. I colori distinguono le due fasce calendario, mentre la variabilità dei punti riflette insieme differenze fra coppe, campagne e condizioni di raccolta. La figura precede ogni test perché rende evidente che la composizione dei gruppi dipende dalla copertura disponibile.

Evidenza grafica



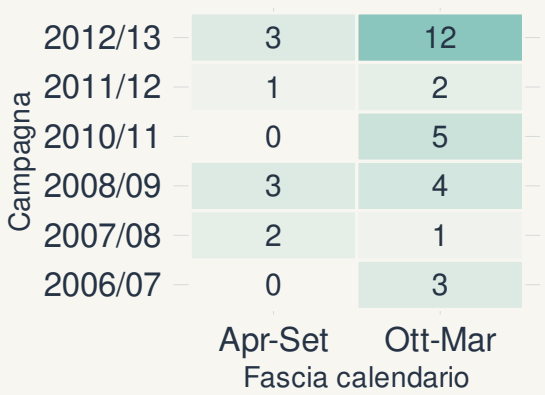
Trentasei medie di coppa, rappresentate alle date centrali. Le interruzioni della serie rimangono esplicite.

Richiami La rappresentazione temporale rende riconoscibile il supporto osservativo del confronto.

La matrice dei conteggi identifica le coppie

La tabella grafica incrocia le sei campagne con le due fasce e riporta il numero di coppe disponibili in ogni cella. Due campagne rappresentano soltanto una fascia, mentre quattro contengono entrambe le condizioni necessarie al confronto appaiato. I conteggi differiscono anche nelle campagne complete, per cui una media su tutte le coppe attribuirebbe pesi disuguali agli anni. La selezione delle campagne complete definisce una popolazione osservativa più ristretta, della quale devono essere dichiarate composizione e ragione dell'inclusione.

Evidenza grafica



Numero di coppe per campagna e fascia. Una cella vuota di osservazioni è indicata da zero.

Richiami La copertura determina quali confronti siano sostenuti dai dati e con quali pesi.

Media delle coppe riunite e pesi impliciti

Riunendo tutte le coppe di ciascuna fascia, la differenza risulta circa 36,66 micrometri. Il confronto Welch restituisce una probabilità di riferimento prossima a 0,004, assumendo indipendenza fra coppe e ignorando la struttura delle campagne. Questo controesempio attribuisce maggiore peso alle campagne più campionate, includendo quelle incomplete soltanto in una fascia. La quantità stimata e il modello di dipendenza differiscono quindi da quelli del confronto per campagne complete.

$$\widehat{\Delta}_{coppe} = \frac{1}{N_1} \sum_{i:S_i=1} y_i - \frac{1}{N_0} \sum_{i:S_i=0} y_i$$

Sviluppo e interpretazione

y_i: diametro massimo medio della coppa i, in µm; $S_i = 1$: ottobre–marzo, $S_i = 0$: aprile–settembre. N_s conta le coppe nella fascia s. La differenza rispetto alla stima appaiata riflette composizione e ponderazione: cambia anche l'oggetto della media, oltre alla formula dell'errore standard.

Richiami Una probabilità piccola non corregge una scelta inadeguata dell'unità o della ponderazione.

L’estimando delle campagne complete

Si calcola la media delle coppe entro ogni combinazione campagna–fascia e poi la differenza ottobre–marzo meno aprile–settembre. La media finale assegna uguale peso alle quattro campagne complete, indipendentemente dal numero delle coppe. Una ponderazione per durata, individui o flusso sedimentario definirebbe un’altra quantità, che richiederebbe informazioni ulteriori.

$$\overline{y}_{gs} = \frac{1}{n_{gs}} \sum_{i \in (g,s)} y_i, \qquad d_g = \overline{y}_{g1} - \overline{y}_{g0}$$

$$\widehat{\Delta} = \frac{1}{4} \sum_{g=1}^{4} d_g$$

Lettura del diagramma



g: campagna; s: fascia, 1 per ottobre–marzo e 0 per aprile–settembre. n_{gs}: coppe disponibili; y_i: media della coppa, in µm.

Richiami Il denominatore finale è costituito dalle quattro campagne complete.

Costruzione delle coppie in R

Il raggruppamento produce una riga per campagna e fascia, mentre la trasformazione in formato largo colloca le due medie sulla stessa riga. La selezione delle righe complete rende esplicito il requisito dell'appaiamento. Le etichette S1 e S0 indicano rispettivamente ottobre–marzo e aprile–settembre. Il controllo di quattro differenze e il confronto con la tabella esportata permettono di verificare che la costruzione delle coppie rispetti il protocollo dichiarato.

Implementazione in R

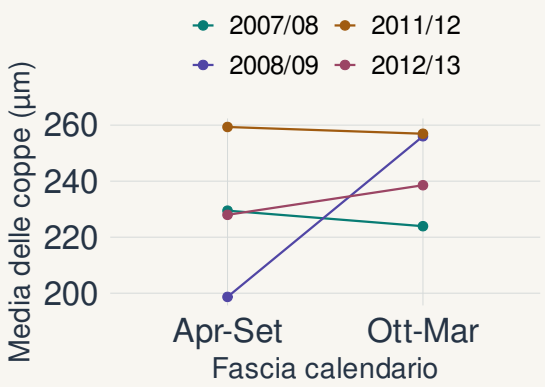
```
d <- read.csv('dati/progetti/foraminiferi.
    csv')
m <- as.integer(format(as.Date(d$date),'%m')
    )
d$S <- ifelse(m%in%c(10:12,1:3),'S1','S0')
a <- aggregate(diam_mean_um~trap_year+S,d,
    mean)
w <- reshape(a,idvar='trap_year',
 timevar='S',direction='wide')
w <- w[complete.cases(w),]
delta <- w$diam_mean_um.S1-w$diam_mean_um.S0
stopifnot(length(delta)==4)
mean(delta)
```

Richiami La trasformazione della tabella deve conservare la corrispondenza fra le due medie della medesima campagna.

Le quattro coppie mostrano andamenti differenti

Le linee collegano le due medie della stessa campagna e rendono visibile l'eterogeneità dei confronti. Due campagne mostrano differenze negative, una una differenza positiva contenuta e una un incremento molto maggiore. Le linee descrivono un abbinamento fra medie di fascia, senza rappresentare una traiettoria continua nel tempo. Il grafico suggerisce di studiare direttamente le quattro differenze, poiché una sintesi complessiva potrebbe nascondere il contributo sproporzionato di una singola campagna.

Evidenza grafica



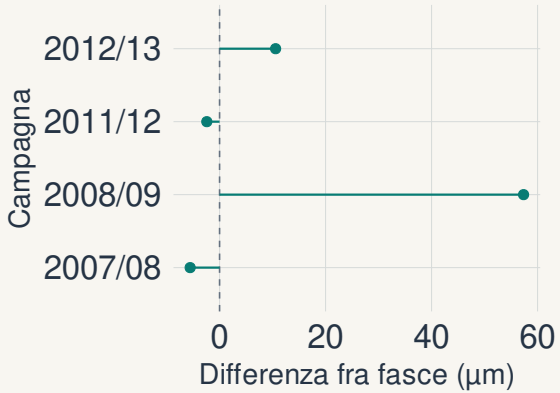
Medie delle coppe nelle quattro campagne complete. Ogni linea collega le due fasce della stessa campagna.

Richiami La struttura appaiata rende visibile la variabilità delle differenze che entrano nell'inferenza.

Quattro differenze come osservazioni dell’analisi

Le differenze sono circa meno 5,55, più 57,35, meno 2,41 e più 10,57 micrometri, nelle quattro campagne ordinate cronologicamente. La loro media è circa 14,99 micrometri, mentre la dispersione rimane elevata rispetto a questa grandezza. La campagna 2008–2009 contribuisce in modo rilevante alla media positiva. I valori disponibili descrivono campagne di uno stesso sito e non garantiscono indipendenza temporale; tale ipotesi va discussa quando si utilizza la distribuzione delle differenze come base per un intervallo o un test.

Evidenza grafica



Differenza ottobre–marzo meno aprile–settembre. La linea verticale indica uguaglianza fra le due medie di fascia.

Richiami Segno, grandezza e variabilità delle differenze precedono l’interpretazione del test.

Intervallo t sulle differenze di campagna

Il test appaiato coincide con un test sulla media delle quattro differenze. L'errore standard è circa 14,55 micrometri e l'intervallo t al 95%, con tre gradi di libertà, si estende da circa meno 31,30 a più 61,28 micrometri. L'esattezza richiede differenze indipendenti e gaussiane; con quattro campagne la verifica empirica della forma distributiva rimane debole. La probabilità di riferimento, circa 0,379, riguarda questa costruzione e non esprime la probabilità che una variazione stagionale sia assente.

$$SE(\bar{d}) = \frac{s_d}{\sqrt{4}}, \qquad IC_{95\%} = \bar{d} \pm t_{0,975;3}\frac{s_d}{2}$$

Sviluppo e interpretazione

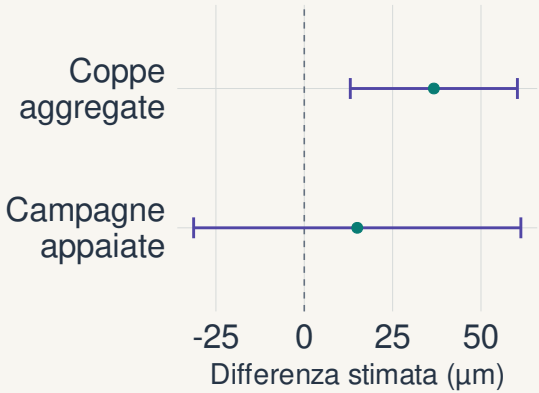
$\bar{d}$: media delle quattro differenze; s_d: deviazione standard con denominatore 3; $t_{0,975;3} \simeq 3,182$. L'intervallo comprende differenze negative e positive rilevanti. La compatibilità con zero non dimostra equivalenza, che richiederebbe limiti di rilevanza prestabiliti e un disegno adeguato.

Richiami Con poche unità, la conclusione deve esplicitare le ipotesi e l'ampiezza dell'incertezza.

Il confronto fra procedure cambia anche la domanda

La figura accosta il confronto sulle coppe riunite e quello sulle campagne complete, con i rispettivi intervalli classici. La differenza delle stime dipende da pesi e campagne incluse, mentre la differenza dell'incertezza riflette anche l'unità scelta e le assunzioni di indipendenza. Il risultato più netto sulle coppe non offre una ragione per preferire quella procedura. La discussione identifica prima l'oggetto della media e il disegno delle osservazioni, così da scegliere un'analisi pertinente alla domanda e dichiararne i limiti.

Evidenza grafica



Coppe riunite: controesempio Welch. Campagne appaiate: intervallo t sulle quattro differenze. Cambiano quantità e ipotesi.

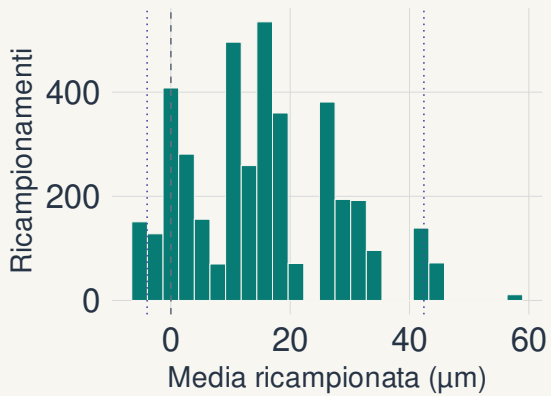
Richiami Il confronto delle probabilità di riferimento è subordinato alla comparabilità degli estimandi.

Il bootstrap conserva la campagna come unità

Ogni replica estrae quattro differenze di campagna con reinserimento e ne calcola la media. I quattromila piani condivisi producono soltanto trentacinque valori distinti, perché il campione originario contiene quattro quantità e le loro combinazioni di molteplicità sono limitate. L'intervallo percentile va da circa meno 3,98 a più 42,41 micrometri. Il ricampionamento descrive la sensibilità alle campagne osservate, senza rappresentare automaticamente campagne climaticamente differenti o condizioni assenti dal sito e dal periodo considerati.

$$\bar{d}^{*} = \frac{1}{4}\sum_{r=1}^{4} d_{I_r}, \qquad I_r \overset{\text{iid}}{\sim} \text{Unif}\{1,2,3,4\}$$

Evidenza grafica



d_g: differenza di campagna, in µm. 4000 estrazioni con reinserimento; viola: quantili percentili della media ricampionata.

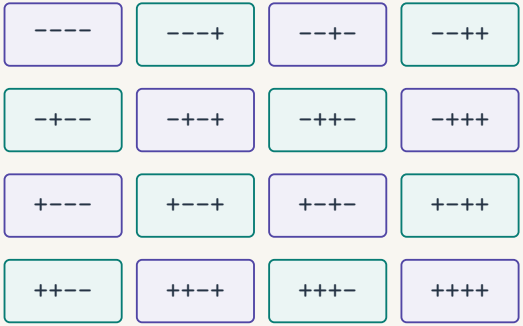
Richiami Il ricampionamento rende esplicita la variabilità del campione disponibile senza crearne nuove unità.

Ribaltamento dei segni e ipotesi di simmetria

Un controllo ulteriore conserva le grandezze delle differenze e ne enumera i possibili segni. Con quattro differenze si ottengono sedici configurazioni, considerate equiprobabili sotto un'ipotesi di simmetria e indipendenza dei segni rispetto alla nullità dell'effetto. Nel disegno osservativo non è avvenuta una randomizzazione dei segni: l'interpretazione dipende quindi da questa ipotesi di riferimento. Otto configurazioni hanno una media in valore assoluto almeno pari a quella osservata, producendo una probabilità bilaterale di un mezzo.

$$T(s) = \frac{1}{4}\sum_{g=1}^{4} s_g d_g, \qquad s_g \in \{-1, +1\}$$

Lettura del diagramma



Viola: otto esiti estremi.

d_g: differenza ottobre–marzo meno aprile–settembre nella campagna g; s_g: segno applicato. T(s) è la media dopo i ribaltamenti.

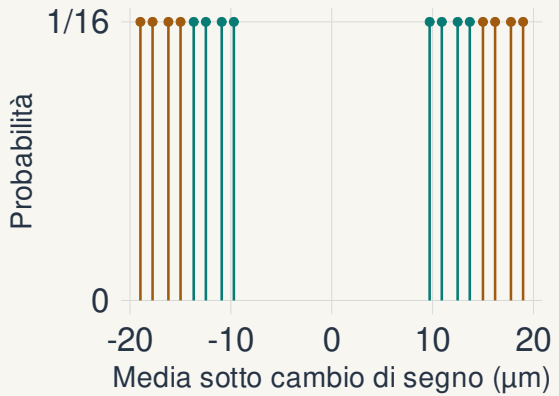
Richiami L'enumerazione è esatta per il riferimento scelto, la cui pertinenza al disegno osservativo deve essere motivata.

La risoluzione del test dipende dal disegno

La distribuzione di riferimento contiene sedici masse di probabilità uguali a un sedicesimo. La simmetria associa a ogni configurazione quella con tutti i segni invertiti, per cui il più piccolo valore bilaterale possibile è due sedicesimi, pari a 0,125, quando le due configurazioni estreme sono uniche. Una maggiore precisione numerica del calcolo non supera questo limite, che deriva dal numero delle unità e dal riferimento utilizzato. Nel caso osservato la probabilità è 0,5, coerentemente con le otto configurazioni evidenziate.

$$p = \frac{\#\{|T(s)| \geq |\bar{d}|\}}{16} = \frac{8}{16} = 0{,}5$$

Evidenza grafica



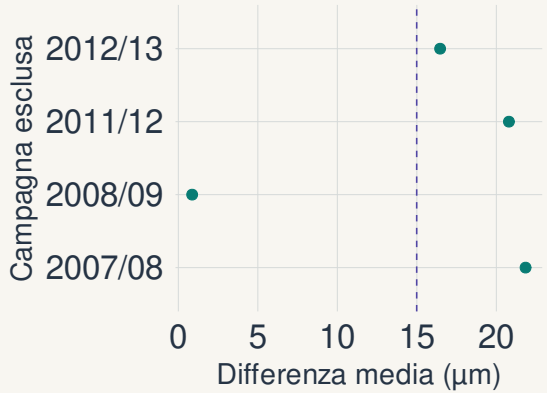
T(s): media delle differenze con segni ribaltati; $\bar{d} = 14{,}99$ µm: media osservata. Ocra: otto configurazioni almeno altrettanto estreme.

Richiami La risoluzione inferenziale deriva dal disegno e resta distinta dalla precisione aritmetica.

Sensibilità alla singola campagna

L'omissione di una campagna alla volta produce medie comprese fra circa 0,87 e 21,84 micrometri. Escludendo il 2008–2009, la differenza media si avvicina allo zero, rendendo evidente il contributo di quell'anno alla sintesi complessiva. Questa diagnosi orienta l'esame della copertura e delle condizioni ambientali, senza fornire da sola una motivazione per eliminare la campagna. La relazione deve conservare il risultato sul campione completo e discutere le alternative attraverso evidenze indipendenti dalla convenienza della conclusione.

Evidenza grafica



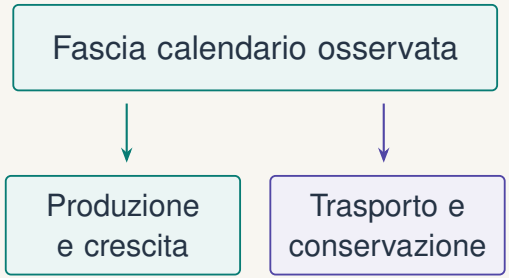
Media delle tre differenze rimaste dopo ogni omissione. La linea viola indica la media sulle quattro campagne.

Richiami L'influenza di una campagna orienta il controllo del disegno e del contesto, prima di qualsiasi esclusione.

Dal calendario alle ipotesi ambientali

Le fasce temporali possono essere associate a condizioni differenti di produzione, nutrimento, trasporto e conservazione dei gusci, ma il confronto delle medie non distingue questi meccanismi. Una sola posizione geografica e quattro campagne complete delimitano ulteriormente l'argomento. Il risultato sostiene una descrizione della differenza nelle campagne disponibili, accompagnata da un'incertezza ampia e da sensibilità fra anni. Per studiare il meccanismo servirebbero misure ambientali concomitanti e un disegno che colleghi tali variazioni alle proprietà morfometriche osservate.

Lettura del diagramma



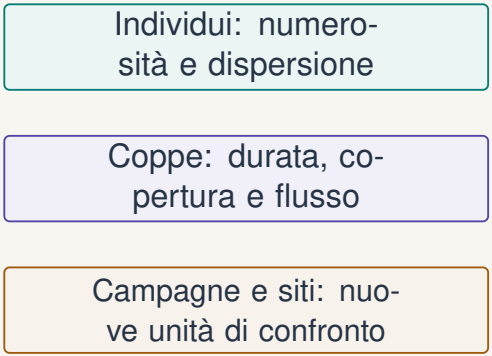
Meccanismi da distinguere con dati ulteriori

Richiami Il raggruppamento temporale descrive un confronto e lascia aperta l'identificazione dei meccanismi.

Progettare una copertura più informativa

Una raccolta successiva dovrebbe migliorare la copertura delle due fasce in più campagne, documentando intervalli di apertura delle coppe, numero di individui, dispersione delle misure e flusso sedimentario. Queste informazioni permetterebbero di definire ponderazioni coerenti con la quantità scientifica di interesse e di separare l'incertezza interna alle coppe dalla variabilità fra campagne. Ulteriori siti amplierebbero il dominio geografico, purché la loro selezione e i protocolli fossero comparabili. Il miglioramento del disegno riguarda pertanto livelli diversi della gerarchia osservativa.

Lettura del diagramma



Richiami La raccolta aggiuntiva va progettata rispetto alla componente di incertezza che si vuole ridurre.

Relazione e discussione del confronto

La consegna include matrice della copertura, grafico delle coppie, definizione della differenza, intervallo t, bootstrap, controllo dei segni e sensibilità alle campagne. L'esercizio confronta il risultato sulle coppe riunite con quello appaiato, spiegando come cambino pesi, campione e assunzioni. Una risposta adeguata mantiene distinti assenza di evidenza netta, equivalenza fra fasce e identificazione di un meccanismo. Codice, dati e attribuzioni consentono di ricostruire il procedimento e di proporre una nuova raccolta coerente con i limiti emersi.

Sviluppo e interpretazione

R/P02_figure.R produce le figure e le tabelle a partire dall'estratto conservato in dati/progetti. La fonte è Mikis et al. (2019), PANGAEA.902776, distribuita con licenza CC BY 4.0. Il progetto raccorda campionamento gerarchico, inferenza sulla media e test appaiati dei moduli M01, M05 e M06.

Richiami La relazione sostiene la conclusione attraverso il disegno osservativo, oltre che attraverso i risultati numerici.

Mikis et al., 2019, PANGAEA.902776; CC BY 4.0