P05 · REVISIONE R6

CO_2: tendenza e calendario stagionale

Medie mensili derivate, dipendenza residua e forma del trend

22 slide · teoria, derivazioni, figure e applicazioni in R.
Provenienza dei dati e sorgenti nei materiali allegati.

P05

Percorso del modulo

3 Provenienza e aggregazione della serie

8 Scale temporali e modello della media

14 Dipendenza e incertezza della pendenza

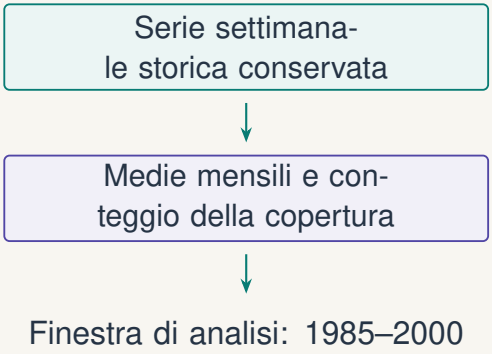
19 Curvatura, interpretazione e consegna

I numeri indicano le pagine iniziali; i titoli sono cliccabili. Codice, figure e verifiche sono inclusi nel progetto.

Una tendenza entro una finestra storica definita

Il progetto stima la tendenza della CO_2 a Mauna Loa nella finestra 1985–2000, utilizzando medie mensili derivate da osservazioni settimanali storiche distribuite con statsmodels. La fonte attribuisce la serie a Keeling e Whorf, attraverso CDIAC, e conserva il periodo fino al 2001. La domanda distingue una componente lineare e un calendario stagionale medio, esaminando poi la dipendenza rimasta nei residui. Il risultato riguarda questa finestra e questa aggregazione, mentre un aggiornamento richiederebbe la ricostruzione del protocollo su dati ufficiali nuovi.

Lettura del diagramma



Richiami Provenienza, aggregazione e finestra temporale definiscono l'oggetto della stima.

L’archivio distingue righe e osservazioni disponibili

Il file conserva 2284 date settimanali, delle quali 59 hanno concentrazione mancante; i valori disponibili sono quindi 2225. La regolarità delle date e l’unicità delle righe vengono verificate prima dell’aggregazione. Una data presente con valore mancante mantiene informazione sulla copertura e non viene trasformata in concentrazione nulla. L’audit considera anche il periodo 1980–1984, precedente alla finestra finale, così che la selezione temporale e le lacune che la motivano rimangano documentate nell’intero procedimento.

$$n_{righe} = 2284, \qquad n_{validi} = 2284 - 59 = 2225$$

Sviluppo e interpretazione

La serie mensile costruita nel progetto è una media delle settimane disponibili assegnate al mese dalla loro data. Essa va distinta da un prodotto mensile ufficiale ottenuto con altri protocolli di campionamento, controllo e ponderazione temporale.

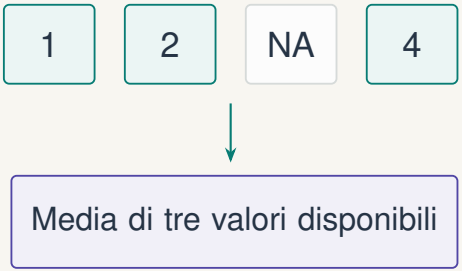
Richiami Il conteggio dei dati disponibili accompagna la sintesi numerica e ne chiarisce il supporto osservativo.

La media mensile mantiene il proprio denominatore

Per ogni mese si calcola la media aritmetica delle concentrazioni settimanali disponibili e si registra il numero dei contributi. Il procedimento assegna uguale peso alle settimane osservate, senza interpolare quelle assenti. Una media pesata per giorni effettivamente coperti richiederebbe metadati e una convenzione differente. L'analisi seleziona i 192 mesi del 1985–2000, per i quali il numero di settimane valide è almeno tre, mantenendo esplicito il criterio di copertura applicato alla finestra.

$$\overline{C}_m = \frac{1}{n_m} \sum_{w \in O_m} C_w, \qquad n_m = |O_m| \geq 3$$

Lettura del diagramma



Schema: il valore mancante resta escluso dalla somma.

O_m: settimane valide assegnate al mese m; C_w: concentrazione settimanale in ppm; n_m: numero dei contributi.

Richiami Una media derivata deve conservare la regola di selezione e il numero dei contributi effettivi.

La copertura viene calcolata prima della selezione

Il frammento costruisce separatamente le medie e i conteggi, riunendoli mediante il mese. L'unione conserva anche eventuali mesi privi di media, che resterebbero riconoscibili attraverso il conteggio nullo. La finestra viene poi selezionata con estremi dichiarati e verificata rispetto al requisito delle tre settimane. Questa sequenza rende l'aggregazione controllabile e impedisce che una media numericamente definita nasconda un supporto temporale insufficiente per la comparabilità richiesta dall'analisi.

Implementazione in R

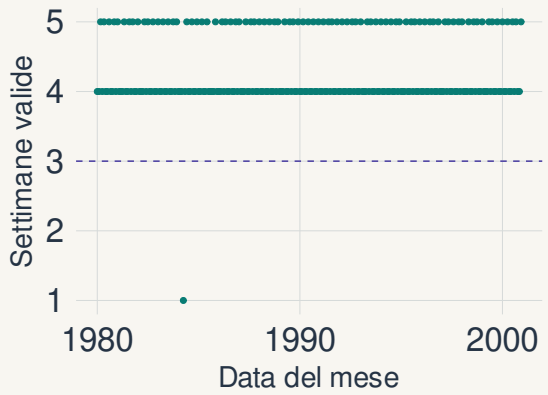
```
d <- read.csv('dati/progetti/co2_weekly.csv'
    )
d$ym <- format(as.Date(d$date),'%Y-%m')
d$valido <- as.integer(!is.na(d$co2_ppm))
a <- aggregate(co2_ppm~ym,d,mean)
n <- aggregate(valido~ym,d,sum)
m <- merge(n,a,by='ym',all.x=TRUE)
z <- subset(m,ym>='1985-01' & ym<='2000-12')
stopifnot(nrow(z)==192,all(z$valido>=3))
```

Richiami Il criterio di copertura viene applicato a una tabella che conserva sia la sintesi sia il denominatore.

L’audit rende visibile il mese scarsamente coperto

Nel periodo più ampio 1980–2000, aprile 1984 contiene soltanto una settimana valida. La figura conserva questo mese e gli altri conteggi, insieme alla soglia di tre contributi richiesta nella finestra finale. La presenza di una media per aprile non garantirebbe quindi una copertura confrontabile con quella dei mesi successivi. La selezione 1985–2000 viene documentata attraverso questo controllo e non mediante una cancellazione silenziosa delle osservazioni problematiche dall’archivio originale.

Evidenza grafica



Settimane valide per mese dal 1980 al 2000.

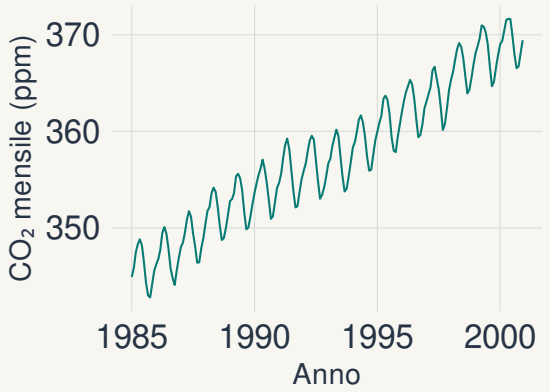
Riferimento viola: criterio minimo di tre contributi.

Richiami La qualità della copertura va resa leggibile anche fuori dalla finestra infine utilizzata.

La serie presenta crescita e oscillazione annuale

Le 192 medie mensili mostrano una crescita di lungo periodo sulla quale si sovrappone un'oscillazione stagionale. La rappresentazione temporale conserva entrambe le scale e permette di valutare se una tendenza lineare costituisca una sintesi ragionevole della finestra. La regolarità visiva del ciclo non implica che ampiezza e forma siano identiche in tutti gli anni. Il modello successivo assume un calendario medio, la cui adeguatezza verrà esaminata attraverso residui e sensibilità della forma della tendenza.

Evidenza grafica



Medie mensili derivate dalle settimane disponibili, gennaio 1985–dicembre 2000.

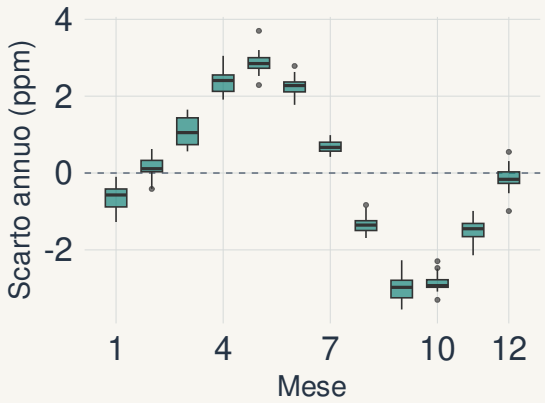
Richiami La separazione delle componenti temporali richiede ipotesi esplicite sulla forma della media.

Gli scarti annui isolano una descrizione stagionale

Sottraendo a ciascun mese la media del proprio anno si ottiene una descrizione della posizione stagionale relativa. I boxplot riuniscono, per ogni mese calendario, gli scarti osservati nei sedici anni della finestra. La dispersione delle scatole riguarda la variabilità fra anni e non l'incertezza della pendenza temporale. La trasformazione viene utilizzata soltanto per la visualizzazione, mentre il modello finale è stimato sulle concentrazioni mensili originarie, conservando la componente di crescita che la centratura annua rimuove.

$$A_{y,m} = C_{y,m} - \frac{1}{12}\sum_{j=1}^{12} C_{y,j}$$

Evidenza grafica



$C_{y,m}$: media mensile nell'anno y e mese m; $A_{y,m}$: scarto dalla media annua, in ppm. Sedici valori per mese.

Richiami Una trasformazione descrittiva va distinta dalla risposta utilizzata nella stima del modello.

Una pendenza e undici contrasti mensili

Il modello associa alla concentrazione una tendenza lineare e undici effetti mensili, lasciando gennaio come categoria di riferimento. Il tempo viene espresso in anni e centrato rispetto al 1993, così che la pendenza abbia unità ppm per anno. L'intercetta riguarda il gennaio di riferimento al tempo centrato zero secondo la convenzione adottata. Gli effetti mensili descrivono differenze medie rispetto a gennaio, mentre la pendenza rappresenta una crescita comune al calendario stagionale mantenuto costante.

$$C_t = \alpha + \beta \tau_t + \sum_{m=2}^{12} \gamma_m \mathbf{1}\{M_t = m\} + \varepsilon_t$$

Sviluppo e interpretazione

C_t: media mensile in ppm; M_t: mese, da 1 a 12; $\tau_t = \text{anno}_t + (M_t - 0,5)/12 - 1993$, in anni. α: intercetta; β: pendenza; γ_m: contrasto con gennaio; ε_t: errore a media nulla. Si fissa $\gamma_1 = 0$. Le tredici colonne sono intercetta, tempo e undici indicatori; dodici indicatori più intercetta sarebbero ridondanti.

Richiami La categoria di riferimento e l'unità del tempo determinano il significato dei coefficienti.

Il rango esprime l'identificabilità dei coefficienti

La verifica del rango controlla che le colonne della matrice del modello forniscano informazioni linearmente distinte. La scelta di gennaio come riferimento elimina la ridondanza fra intercetta e indicatori mensili, rendendo identificabili i coefficienti nella parametrizzazione adottata. Cambiare il mese di riferimento modificherebbe intercetta e contrasti, lasciando invariati valori adattati e pendenza temporale. Questa equivalenza riguarda una ricodifica dello stesso spazio delle medie, mentre aggiungere una curvatura introdurrebbe uno spazio di modelli più ampio.

$$\operatorname{rank}(X) = 13, \qquad n - k = 192 - 13 = 179$$

Lettura del diagramma



192 righe, 13 colonne indipendenti

X: matrice del modello; n = 192 mesi; k = 13 coefficienti. Il rango pieno consente una soluzione OLS unica.

Richiami L'identificabilità dipende dalle relazioni fra colonne, oltre che dal numero delle osservazioni.

La stima conserva la scala di ppm per anno

La pendenza stimata è circa 1,53691 ppm per anno e il coefficiente di determinazione è circa 0,9909. Il primo valore riassume la crescita media nella specificazione lineare stagionale; il secondo descrive la quota di variabilità campionaria spiegata dal modello. Un valore elevato di R^2 è compatibile con residui fortemente correlati e con una forma della media ancora semplificata. L'interpretazione della precisione richiede quindi l'esame dell'ordine temporale e dell'autocorrelazione dei residui.

Implementazione in R

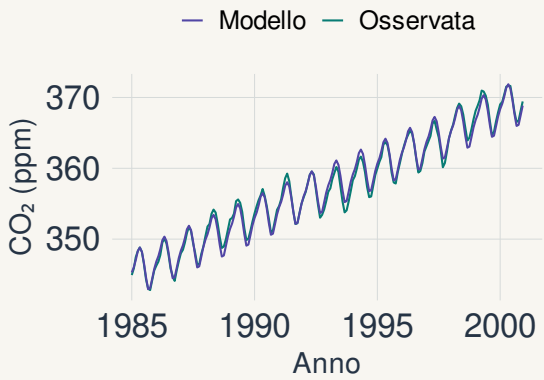
```
d <- read.csv('risultati/P05/mensile_modelli
    .csv')
d$m <- factor(d$month,levels=1:12)
f <- lm(co2_ppm~t+m,d)
stopifnot(qr(model.matrix(f))$rank==13)
coef(f)[2]
confint(f)[2,]
```

Richiami Una buona aderenza complessiva non stabilisce da sola la correttezza della covarianza degli errori.

L’adattamento viene confrontato con la serie

Le concentrazioni osservate e quelle adattate vengono sovrapposte mantenendo la sequenza temporale. Il modello segue gran parte della crescita e dell’oscillazione annuale, mentre gli scarti residui risultano poco visibili nella scala complessiva della concentrazione. Per questo la sovrapposizione viene affiancata da un grafico dedicato ai residui, che ne amplia la scala. La scelta di due rappresentazioni consente di valutare sia l’aderenza globale sia le strutture più piccole che possono influenzare l’inferenza sul trend.

Evidenza grafica



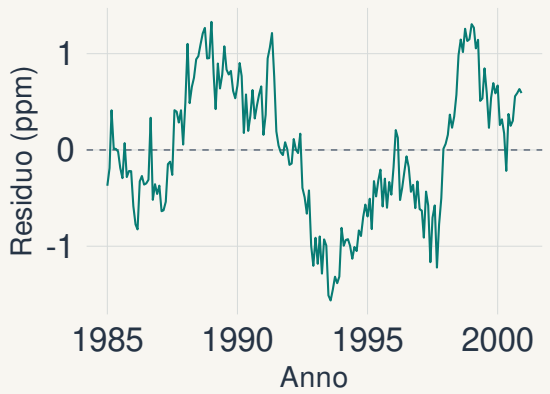
Serie osservata e adattamento lineare con effetti mensili. Stessa scala e stessa finestra temporale.

Richiami La scala del grafico determina quali scostamenti rimangano visibili nella diagnosi.

I residui conservano sequenze persistenti

Gli scarti dalla media modellata mostrano periodi prolungati sopra o sotto lo zero, suggerendo una persistenza che la sola componente stagionale fissa lascia irrisolta. Questa struttura può riflettere dipendenza degli errori, variazioni della media omesse o entrambe. La rappresentazione temporale precede quindi il calcolo della covarianza robusta, poiché una correzione dell'errore standard non modifica la forma della tendenza. L'analisi mantiene distinti il problema della dipendenza e quello della specificazione del valore atteso.

Evidenza grafica



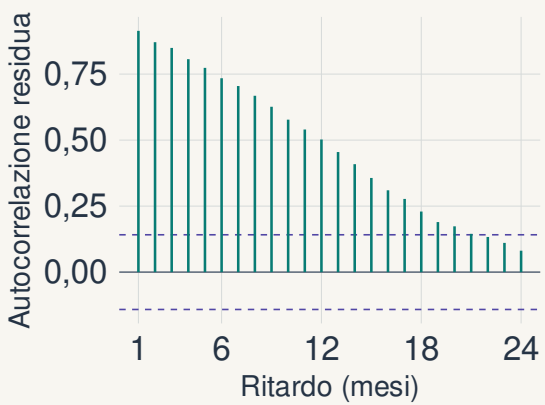
Residui in ppm del modello lineare stagionale. La scala dedicata rende riconoscibili le sequenze temporali.

Richiami La persistenza residua va interpretata insieme alla possibilità di una media ancora incompletamente specificata.

L’autocorrelazione rende esplicita la persistenza

L’ACF residua fino a ventiquattro mesi mostra una correlazione al primo ritardo di circa 0,914, che rende poco plausibile trattare gli scarti consecutivi come indipendenti. Le bande tratteggiate rappresentano il riferimento puntuale approssimativo di rumore bianco e non correggono il confronto simultaneo di tutte le barre. La persistenza sostiene l’esame di covarianze temporali e di modelli alternativi della media, mentre la sola posizione di una barra rispetto alla banda non identifica il meccanismo responsabile.

Evidenza grafica



ACF dei residui mensili. Bande puntuali approssimative pari a ±1,96 diviso la radice di 192.

Richiami Una dipendenza residua pronunciata modifica l’informazione attribuibile alla sequenza delle osservazioni.

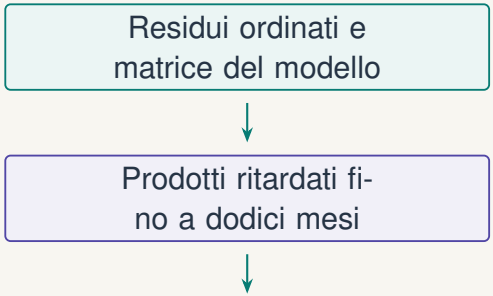
L’intervallo HAC include prodotti temporali ritardati

La covarianza HAC usa pesi di Bartlett fino a dodici mesi, senza prewhitening, e la correzione finita 192 diviso 179. La matrice interna combina prodotti fra residui e regressori, assegnando al ritardo h il peso uno meno h diviso tredici. L’errore standard deriva dalla diagonale della covarianza; l’intervallo usa il riferimento normale asintotico. La pendenza OLS resta invariata: cambia la stima dell’incertezza, sotto ipotesi di regolarità che la correzione finita non sostituisce.

$$\widehat{V}_{HAC} = \frac{192}{179}(X^T X)^{-1} S_{12} (X^T X)^{-1}$$

$$IC_{HAC} = \widehat{\beta} \pm 1{,}96\sqrt{[\widehat{V}_{HAC}]_{22}}$$

Lettura del diagramma



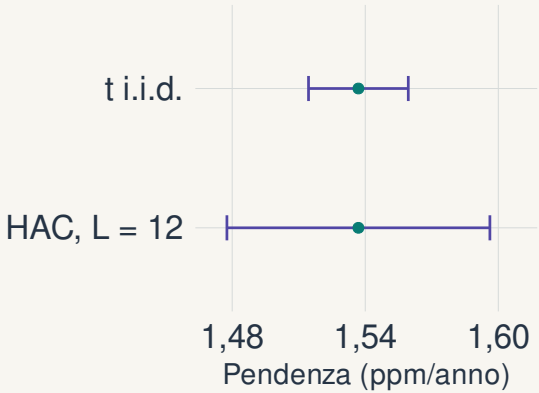
X: 192 righe, colonne intercetta, tempo e 11 mesi; S_{12}: somma dei prodotti pesati regressore × residuo. L’elemento 22 riguarda la pendenza.

Richiami La convenzione HAC comprende ritardo, pesi, correzione finita e riferimento asintotico.

La precisione cambia a stima invariata

L'intervallo t i.i.d. della pendenza va da circa 1,51442 a 1,55941 ppm per anno, mentre quello HAC con dodici mesi va da circa 1,47762 a 1,59621. La seconda costruzione restituisce un'incertezza maggiore in questa serie, coerentemente con il contributo delle covarianze residue stimate. La crescita positiva rimane sostenuta nelle due specificazioni, ma la sua precisione differisce sensibilmente. Il confronto riguarda il modello adottato e non incorpora automaticamente l'incertezza su aggregazione, finestra o forma della media.

Evidenza grafica



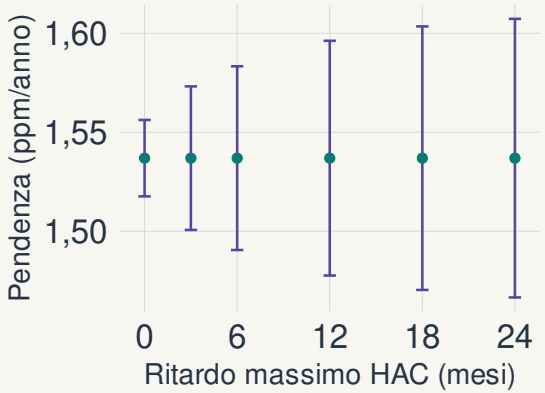
Intervalli della stessa pendenza: t i.i.d. e normale HAC con L = 12. Unità: ppm per anno.

Richiami La concordanza del segno può convivere con differenze sostanziali nella precisione dichiarata.

La griglia dei ritardi rende verificabile la scelta

Il progetto confronta ritardi massimi di zero, tre, sei, dodici, diciotto e ventiquattro mesi, mantenendo invariati osservazioni e modello. Le ampiezze degli intervalli mostrano quanto la precisione dipenda dalla memoria inclusa nella covarianza. La griglia viene presentata integralmente, evitando di selezionare soltanto la costruzione più favorevole. Con dipendenza persistente, l'adeguatezza asintotica e la scelta del ritardo richiedono comunque una discussione: il confronto numerico delle varianti non elimina i limiti della serie finita.

Evidenza grafica



Intervalli HAC lungo la griglia dichiarata di ritardi massimi; stima centrale OLS comune.

Richiami La sensibilità della precisione viene documentata senza trasformare la griglia in una selezione del risultato.

La curvatura modifica la forma della media

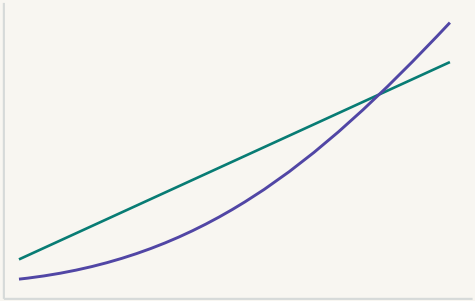
L'aggiunta del termine quadratico introduce una sensibilità descrittiva rispetto all'ipotesi di crescita lineare. Il suo coefficiente è circa 0,010174 ppm per anno quadrato, mentre il tasso locale diventa una funzione del tempo. Poiché il tempo è centrato, il coefficiente lineare del modello quadratico rappresenta il tasso al centro convenzionale e non una pendenza costante sull'intera finestra. La capacità predittiva su osservazioni future richiederebbe una valutazione ulteriore.

$$\mu(\tau, m) = \alpha + \beta_1 \tau + \beta_2 \tau^2 + \gamma_m$$

$$\frac{\partial \mu}{\partial \tau} = \beta_1 + 2\beta_2 \tau$$

Lettura del diagramma

Forme della componente temporale



Schema: pendenza costante e tasso variabile

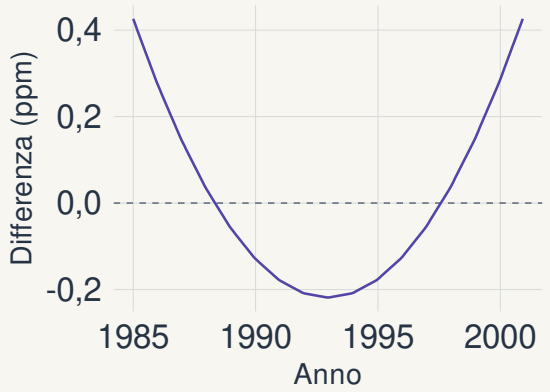
τ: anni centrati nel 1993; m: mese; μ: media in ppm; $\gamma_1 = 0$. β_1: ppm/anno; β_2: ppm/anno².

Richiami La derivata collega la forma matematica del trend all'interpretazione del tasso locale.

La scala delle differenze fra adattamenti

La figura rappresenta il modello quadratico meno quello lineare, con la stessa parametrizzazione mensile e coefficienti ristimati. Lo scarto massimo in valore assoluto è circa 0,426 ppm, una grandezza piccola rispetto alla concentrazione complessiva ma pertinente alla forma della tendenza. La scala dedicata permette di esaminare questa differenza senza confonderla con il ciclo stagionale dominante. L'analisi considera la curvatura come sensibilità della media e non sceglie il modello in base alla convenienza di una probabilità di riferimento.

Evidenza grafica



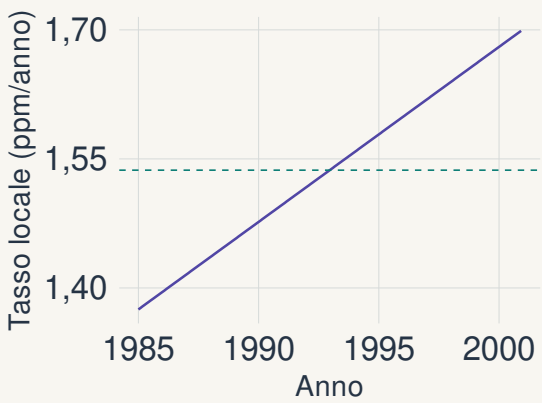
Differenza fra i valori adattati dal modello quadratico e da quello lineare, in ppm.

Richiami La rilevanza di una differenza fra modelli dipende dalla scala e dalla domanda scientifica.

Il tasso locale rende leggibile la conseguenza fisica

Nel modello quadratico, il tasso locale stimato varia da circa 1,375 a 1,699 ppm per anno lungo la finestra. Il riferimento tratteggiato riporta invece la pendenza costante del modello lineare, circa 1,537. La figura chiarisce che il coefficiente della curvatura modifica l'interpretazione della crescita nel tempo, pur lasciando il confronto entro lo stesso archivio storico. L'estrapolazione della parabola oltre il dominio osservato richiederebbe ulteriori ipotesi e una verifica su dati nuovi.

Evidenza grafica



Derivata temporale del modello quadratico. Riferimento tratteggiato: pendenza del modello lineare.

Richiami Un tasso locale viene interpretato nel dominio nel quale la funzione è stata stimata.

Consegna: collegare copertura, trend e incertezza

La relazione documenta fonte, conteggi mensili, finestra, modello stagionale, diagnosi dei residui e sensibilità della covarianza e della media. L'esercizio richiede di spiegare come un R^2 elevato possa convivere con un intervallo HAC più ampio, richiamando la differenza fra aderenza e dipendenza residua. Una seconda attività corregge un grafico che presenti le scatole stagionali come intervalli della pendenza. La conclusione riporta grandezza e unità del trend, mantenendo espliciti periodo, aggregazione e limiti dell'interpretazione fisica.

Sviluppo e interpretazione

R/P05_figure.R ricostruisce medie, controlli, figure e confronti. R/covarianze.R contiene la formula HAC condivisa con P03. Il progetto raccorda descrizione temporale, regressione e previsione dei moduli M07, M09 e M10. L'aggiornamento richiede una nuova fonte e un audit completo delle definizioni.

Richiami La sintesi finale conserva le scelte che determinano il significato della pendenza e della sua incertezza.