M02 · REVISIONE R6

R e gestione dei dati

Dall’importazione alla tabella analitica verificabile

43 slide · teoria, derivazioni, figure e applicazioni in R.
Provenienza dei dati e sorgenti nei materiali allegati.

M02

Percorso del modulo

3 Progetto e stato della sessione

7 Vettori, tipi e selezioni

11 Importazione e conversioni

15 Trasformazioni e aggregazioni

19 Chiavi e relazioni fra tabelle

23 Mancanti e censura

27 Coerenza fisica e registro delle decisioni

31 Variabili derivate e composizione chimica

35 Funzioni, parametri e controlli

39 Tabella analitica e consegna

43 Fonti e laboratori

I numeri indicano le pagine iniziali; i titoli sono cliccabili. Codice, figure e verifiche sono inclusi nel progetto.

Lo script dichiara la procedura

Un'analisi può dipendere da oggetti creati durante prove interattive e assenti dal codice consegnato. Per rendere ricostruibile la procedura, lo script deve dichiarare gli input, eseguire le trasformazioni nell'ordine necessario e salvare i risultati. La cartella del progetto fornisce il riferimento per i percorsi relativi, mentre la separazione fra dati acquisiti e prodotti dell'analisi rende riconoscibile la provenienza. Il riavvio della sessione permette di verificare se le dipendenze operative siano effettivamente esplicitate.

Sviluppo e interpretazione

Un percorso viene interpretato rispetto alla cartella di lavoro del processo. La posizione del file sorgente può essere diversa; per questo motivo il progetto viene aperto dalla sua radice prima di eseguire i laboratori. Il comando source legge ed esegue lo script, mentre getwd permette di controllare il riferimento corrente.

Richiami La procedura deve poter essere eseguita senza ricostruire manualmente lo stato della console.

Il percorso viene verificato prima dell'importazione

Quando un file risulta assente, il controllo deve riguardare la cartella corrente, il nome, l'estensione e la struttura del progetto. Modificare ripetutamente il percorso senza esaminarne la risoluzione può produrre una dipendenza dal computer utilizzato. Il codice costruisce il riferimento al CSV dalla radice del progetto, verifica che il file esista e controlla la numerosità dopo la lettura. L'ispezione dei tipi completa il controllo dell'ingresso prima delle trasformazioni.

Implementazione in R

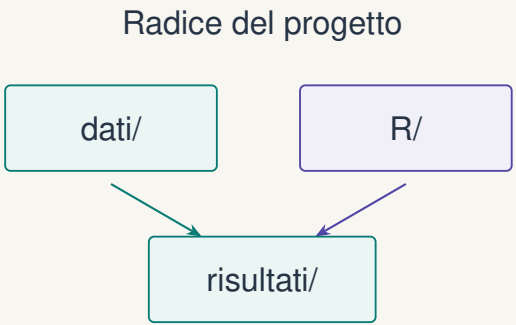
```
getwd()
f <- file.path('dati','campioni_modulo1.csv'
    )
stopifnot(file.exists(f))
d <- read.csv(f,stringsAsFactors=FALSE)
stopifnot(nrow(d)==24L)
str(d)
```

Richiami Un errore di percorso riguarda l'accesso al file; un errore di contenuto richiede controlli successivi.

Le cartelle documentano le dipendenze

Il diagramma distingue gli input acquisiti, il codice che li elabora e gli output rigenerabili. Questa organizzazione consente di individuare quali elementi debbano essere trasferiti affinché un'analisi possa essere ripetuta. Il contenuto della cartella dei risultati può essere ricostruito quando i sorgenti, gli input e l'ambiente necessario sono disponibili; il dato acquisito conserva invece il proprio ruolo di riferimento per la provenienza e per l'eventuale revisione delle decisioni.

Lettura del diagramma



Organizzazione del progetto distribuito. I nomi delle cartelle fanno parte dei percorsi utilizzati dagli script.

Richiami La struttura del progetto deve essere coerente con i percorsi dichiarati nel codice.

Ispezionare una funzione e i suoi errori

Una funzione riceve argomenti, applica una procedura e restituisce un oggetto il cui significato dipende dalla documentazione. Quando l'esecuzione si interrompe, tipo del messaggio e posizione dell'errore aiutano a ricostruire quale condizione sia stata violata. La verifica deve partire dall'ingresso effettivo della funzione: una colonna numerica attesa può contenere testo, oppure un nome può riferirsi a un oggetto creato in precedenza. Un esempio ridotto rende più semplice isolare la causa.

Sviluppo e interpretazione

Consultare la guida di read.csv e verificare gli argomenti relativi a separatori, decimali e mancanti. Riprodurre poi un errore usando un nome di file inesistente e un secondo errore usando una colonna assente. Distinguere il controllo necessario nei due casi prima di correggere lo script.

Richiami La documentazione collega gli argomenti della funzione al comportamento atteso.

Un vettore conserva tipo e posizione

Un vettore atomico di R contiene elementi di un tipo comune, ordinati secondo le loro posizioni. Se un numero viene memorizzato come testo, il suo aspetto può restare invariato mentre cambiano le operazioni ammissibili. L'indicizzazione seleziona posizioni, nomi o condizioni logiche; per una tabella, la selezione delle righe deve essere applicata a tutte le colonne, affinché le misure dello stesso provino rimangano associate. Gli identificativi consentono di verificare questa corrispondenza anche dopo un ordinamento.

Sviluppo e interpretazione

Il vettore c("5.4", "6.1", "ND") è testuale. La conversione richiede di riconoscere il codice di indisponibilità e di dichiarare come rappresentarlo. Una conversione che produca NA deve distinguere i mancanti previsti dai valori che non rispettano il formato atteso.

Richiami La conversione del tipo deve conservare il significato delle registrazioni originali.

Una condizione logica definisce un sottoinsieme

La selezione conserva i provini i appartenenti all'affioramento A e con volume V_i almeno pari a 40 cm³; A_i indica l'affioramento del provino. L'ordinamento successivo riguarda tutte le colonne della tabella selezionata. La densità viene quindi calcolata su misure che conservano la medesima corrispondenza fra righe. Poiché il filtro modifica l'insieme descritto, la sintesi dei valori selezionati dovrà indicare anche il criterio di inclusione, oltre alla provenienza dei dati.

$$\mathcal{S} = \{i : A_i = A,\ V_i \geq 40\}$$

Implementazione in R

```
d <- read.csv('dati/campioni_modulo1.csv')
sel <- d$affioramento=='A' & d$volume_cm3
    >=40
s <- d[sel,c('id','massa_g','volume_cm3')]
s <- s[order(s$volume_cm3),]
stopifnot(all(s$id %in% d$id))
s$densita <- s$massa_g / s$volume_cm3
```

Richiami La condizione usata nel filtro appartiene alla definizione del risultato.

Il riciclo richiede lunghezze compatibili

Le operazioni vettoriali combinano elementi secondo le regole del linguaggio. Quando le lunghezze differiscono, R può ripetere il vettore più corto, producendo un risultato che non coincide con l'intenzione scientifica dell'operazione. Anche quando la lunghezza maggiore è un multiplo di quella minore e manca un avvertimento, la corrispondenza deve essere giustificata. Per il rapporto massa–volume, ogni misura deve avere un denominatore riferito allo stesso provino, salvo che un denominatore comune sia esplicitamente previsto.

$$\rho_i = m_i / V_i, \qquad i = 1, \ldots, n$$

Sviluppo e interpretazione

Nella formula, n è il numero di provini, m_i la massa e V_i il volume del provino i. Una funzione dedicata può richiedere lunghezze uguali e interrompersi quando il vincolo viene violato. Il riciclo deve corrispondere a una scelta esplicita sulla trasformazione dei dati.

Richiami Le regole di riciclo devono essere controllate quando una posizione corrisponde a un'unità osservativa.

Categorie e date hanno regole proprie

I fattori conservano livelli categoriali che possono essere ordinati soltanto quando la scala di misura lo consente. Le date richiedono invece una convenzione esplicita per giorno, mese e anno, così che ordinamento e differenze temporali possano essere interpretati. Il diagramma ricorda che anche queste informazioni appartengono alle righe della tabella: separare l'ordinamento della data da quello delle misure altererebbe la successione del fenomeno, pur lasciando intatti i valori nelle singole colonne.

Lettura del diagramma

Righe ordinate per data

ID	Alterazione	Data
C02	bassa	2026-04-02
C01	alta	2026-04-08
C03	media	2026-04-12

Ordine delle categorie

bassa $<$ media $<$ alta

Esempio illustrativo ordinato per data. L'alterazione conserva l'ordine bassa, media, alta indipendentemente dalla successione temporale.

Richiami Ordinamenti e filtri devono conservare la relazione fra identificativi, categorie, date e misure.

Il formato del file richiede convenzioni

L'estensione CSV identifica una famiglia di file testuali, ma non stabilisce in modo univoco separatore di campo, simbolo decimale e codici dei mancanti. Un'importazione corretta deve dichiarare tali convenzioni e confrontare la struttura ottenuta con quella attesa. Nel file dei fossili da controllare, il separatore è il punto e virgola e alcune misure usano la virgola decimale. Leggere inizialmente le colonne come testo permette di conservare le registrazioni prima della conversione.

Sviluppo e interpretazione

Un foglio elettronico richiede inoltre la scelta di foglio, intervallo e riga delle intestazioni. Celle formattate, formule e note possono appartenere a livelli diversi dal dato tabellare. Il rapporto di importazione deve indicare quali elementi siano stati letti e come siano stati riconosciuti i tipi delle colonne.

Richiami Le convenzioni di importazione fanno parte della procedura scientifica.

La prima lettura conserva il testo

L'importazione conservativa evita che un codice speciale venga trasformato prima che ne sia stato verificato il significato. La colonna aggiunta con il numero della riga di origine permette di rintracciare una registrazione anche quando gli identificativi contengono duplicati. Il controllo della numerosità conferma la forma iniziale del file, mentre la lettura delle prime righe consente di esaminare separatori e convenzioni. La conversione viene eseguita in una tabella derivata, mantenendo accessibile questa rappresentazione iniziale.

Implementazione in R

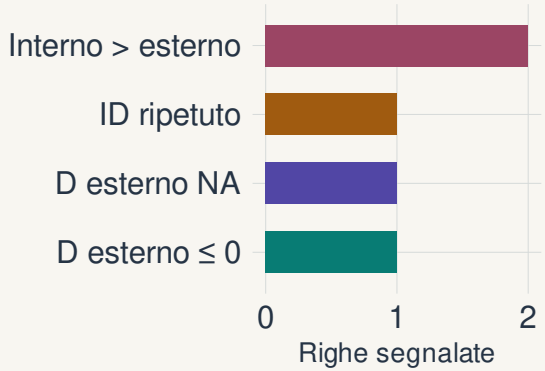
```
raw <- read.csv(
 'dati/fossili_da_controllare.csv',
 sep=';',colClasses='character',
 na.strings=character())
raw$riga_origine <- seq_len(nrow(raw))
stopifnot(nrow(raw)==25L)
head(raw)
```

Richiami Il testo originale permette di distinguere un dato mancante da una conversione fallita.

Quantificare le segnalazioni dell’audit

Il riepilogo mostra quante righe presentino alcune condizioni da esaminare: identificativi ripetuti, misura esterna assente, valore non positivo o diametro interno maggiore di quello esterno. Le categorie descrivono controlli distinti e possono sovrapporsi nella stessa riga; la loro somma non rappresenta quindi automaticamente il numero di osservazioni da escludere. La decisione analitica viene formulata soltanto dopo avere ricostruito quali condizioni siano presenti e quale evidenza permetta di correggerle.

Evidenza grafica



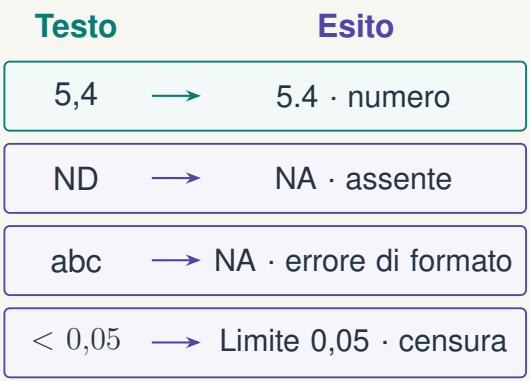
File didattico: 25 righe. «ID ripetuto» conta le ricorrenze successive alla prima. Gli altri controlli possono sovrapporsi.

Richiami Il numero delle segnalazioni e il numero delle righe coinvolte sono quantità differenti.

Una conversione deve avere un esito

La conversione distingue almeno tre situazioni: un numero riconosciuto, un codice di indisponibilità previsto e una stringa che non rispetta il formato atteso. Sebbene le ultime due possano essere rappresentate numericamente da NA, la loro provenienza deve rimanere distinguibile nel registro. Un valore con simbolo di censura richiede un trattamento specifico, poiché contiene un limite quantitativo. Il diagramma esplicita perché la sola presenza di NA nella colonna finale sia insufficiente a ricostruire la conversione.

Lettura del diagramma



La classificazione degli esiti accompagna la colonna numerica derivata.

Richiami Ogni conversione fallita deve essere rintracciabile nel testo da cui proviene.

La sintesi cambia il livello della tabella

Il raggruppamento riunisce osservazioni che condividono una chiave e applica una sintesi alle loro misure. Una tabella con una riga per provino può così diventare una tabella con una riga per stazione. La trasformazione modifica il significato della riga e richiede nuove definizioni per numerosità, media e disponibilità. Il numero dei valori effettivamente utilizzati deve essere riportato insieme alla sintesi, poiché può differire fra variabili o gruppi.

$$\bar{x}_g = \frac{1}{n_g} \sum_{i \in g} x_i$$

Sviluppo e interpretazione

Il simbolo g identifica il gruppo, x_i il valore dell'osservazione i e n_g il numero dei valori utilizzati; $\bar{x}_g$ è la loro media. Se alcune misure sono assenti, il denominatore deve contare soltanto i valori disponibili, mentre la numerosità totale documenta la copertura del gruppo.

Richiami Una riga aggregata rappresenta un gruppo, con proprietà e limiti diversi da quelli delle righe originarie.

Associare la sintesi al suo denominatore

La funzione restituisce il numero dei valori, quello delle osservazioni disponibili, la media e la deviazione standard. Applicandola per stazione, si ottengono sintesi la cui interpretazione rimane collegata alla quantità di dati utilizzata. In un caso con tutti i valori mancanti, media e dispersione richiederebbero una gestione esplicita; nel dataset dei provini questa condizione viene esclusa dai controlli di ingresso. L'esempio mostra come una funzione possa rendere uniforme la definizione della sintesi fra gruppi.

Implementazione in R

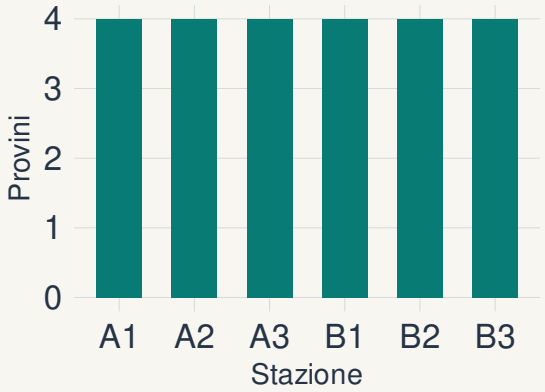
```
d <- read.csv('dati/campioni_modulo1.csv')
d$densita <- d$massa_g/d$volume_cm3
sintesi <- function(x) c(
 n=length(x), disponibili=sum(!is.na(x)),
 media=mean(x,na.rm=TRUE), sd=sd(x,na.rm=
    TRUE))
aggregate(densita ~ stazione,d,sintesi,
          na.action=na.pass)
```

Richiami L'esclusione dei mancanti dal calcolo deve essere accompagnata dal conteggio dei valori disponibili.

Confrontare i conteggi con il disegno

Le sei stazioni contengono ciascuna quattro provini, come previsto nel disegno del caso guida. La figura rende immediato il controllo dell'equilibrio della raccolta, mentre una tabella degli identificativi permette di verificare che i conteggi derivino da unità distinte. Se una stazione avesse meno osservazioni, occorrerebbe stabilire se la differenza dipenda dalla raccolta, dall'indisponibilità di misure o da un filtro applicato successivamente.

Evidenza grafica



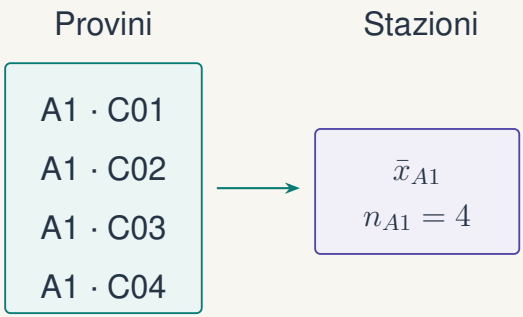
Numero dei provini per stazione nel dataset sintetico. Il grafico descrive la raccolta e non la numerosità effettiva di un modello inferenziale.

Richiami Le differenze di numerosità devono essere ricondotte al processo che le ha prodotte.

L’aggregazione deve conservare la chiave

La media di stazione riassume quattro provini, ma deve rimanere associata al codice del sito affinché possa essere collegata a coordinate, quota e altre caratteristiche locali. Il diagramma rappresenta la riduzione delle righe, accompagnata dal cambiamento della loro unità. Se la chiave fosse eliminata, la posizione della sintesi nella tabella diventerebbe l’unico riferimento, esponendo i collegamenti successivi a errori di ordinamento.

Lettura del diagramma



Una riga di sintesi conserva una chiave di gruppo.

Aggregazione dei quattro provini della stazione A1; il risultato conserva media, numerosità e identificativo del gruppo.

Richiami La chiave del gruppo deve accompagnare ogni sintesi destinata a un collegamento successivo.

Una chiave identifica l'unità dichiarata

Una chiave deve essere univoca rispetto all'unità rappresentata dalla tabella. Il codice del provino può identificare una riga nella tabella dei campioni, mentre il codice della stazione si ripete quando più provini provengono dallo stesso sito. Prima di collegare tabelle occorre quindi stabilire quale relazione sia attesa: uno-a-uno, molti-a-uno oppure molti-a-molti. Il significato della chiave determina quali controlli di unicità siano appropriati su ciascun lato.

$$k : \mathcal{U} \to \mathcal{K}, \qquad k(u) = k(v) \Rightarrow u = v$$

Sviluppo e interpretazione

La funzione k associa ogni unità u dell'insieme $\mathcal{U}$ a un codice nell'insieme $\mathcal{K}$. L'implicazione esprime l'univocità: due unità con lo stesso codice devono coincidere. Una chiave esterna, come la stazione nella tabella dei provini, può invece ripetersi perché indica l'appartenenza a un gruppo.

Richiami L'unicità deve essere valutata al livello dell'unità rappresentata dalla tabella.

Controllare un collegamento molti-a-uno

La tabella delle stazioni contiene una sola quota per sito, mentre quella dei campioni può contenere più provini dello stesso sito. Il collegamento trasferisce la quota a ogni provino corrispondente, conservando tutte le righe della tabella dei campioni. Il controllo di unicità sul lato delle stazioni previene la moltiplicazione delle righe; il controllo dei valori mancanti dopo l'unione segnala invece eventuali chiavi prive di corrispondenza.

Implementazione in R

```
campioni <- data.frame(id=c('p1','p2','p3'),
 sito=c('A','A','B'))
siti <- data.frame(sito=c('A','B'),quota=c
    (10,20))
stopifnot(!anyDuplicated(siti$sito))
j <- merge(campioni,siti,by='sito',all.x=
    TRUE)
stopifnot(nrow(j)==nrow(campioni))
stopifnot(!anyNA(j$quota))
```

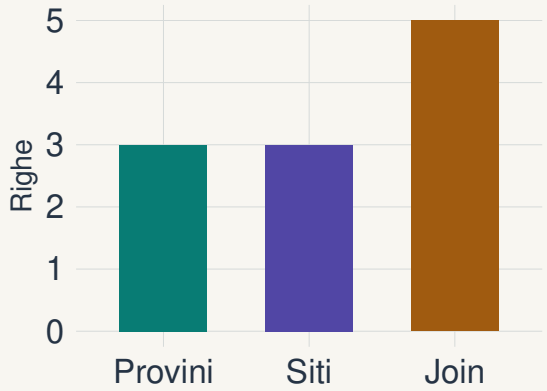
Richiami La cardinalità attesa del collegamento deve essere dichiarata prima di eseguire l'unione.

Le molteplicità determinano il numero di righe

Se una chiave compare due volte in ciascuna delle tabelle, il collegamento produce quattro combinazioni per quella chiave. Indicando con $n_L(k)$ e $n_R(k)$ le ricorrenze della chiave k nelle tabelle sinistra e destra, l'inner join ne somma i prodotti. La figura mostra un esempio nel quale tre provini e tre registrazioni di sito producono cinque righe. Il risultato può essere formalmente corretto rispetto all'operazione, pur violando la relazione scientifica attesa fra provino e stazione.

$$n_{\text{join}} = \sum_{k} n_L(k) n_R(k)$$

Evidenza grafica



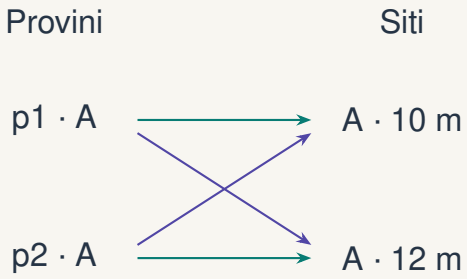
La chiave A compare due volte su entrambi i lati; B compare una volta. Il join contiene 2×2 + 1×1 = 5 righe.

Richiami Un aumento delle righe può rivelare una molteplicità della chiave incompatibile con il collegamento previsto.

Duplicati e misure ripetute vanno distinti

Due registrazioni dello stesso sito possono rappresentare un duplicato accidentale oppure misure eseguite in tempi o condizioni differenti. Nel secondo caso, la chiave deve includere le informazioni che distinguono le osservazioni, come data e protocollo. Il diagramma mostra perché eliminare o conservare tutte le righe senza esaminarne il significato possa alterare il collegamento. La struttura lunga della tabella rende esplicite le ripetizioni quando a ogni riga vengono associate unità, occasione e misura.

Lettura del diagramma



Due provini × due registrazioni = quattro righe

Combinazioni prodotte dalla chiave A ripetuta su entrambi i lati. Le quote sono illustrative.

Richiami La scelta della chiave deve distinguere le ripetizioni reali dai duplicati del processo di registrazione.

La disponibilità va definita per ogni analisi

Un valore NA rappresenta l'indisponibilità della misura, mentre una data assente da una serie può costituire un mancante implicito che emerge soltanto ricostruendo la griglia temporale attesa. Se un modello utilizza più variabili, il sottoinsieme delle righe complete dipende da tutte le colonne richieste. La popolazione descritta dopo questa selezione può differire da quella iniziale, soprattutto quando la disponibilità è associata al fenomeno osservato. Il numero delle esclusioni deve quindi essere accompagnato da una descrizione dei loro motivi.

Sviluppo e interpretazione

Una registrazione inferiore al limite di rilevabilità mantiene invece un vincolo quantitativo. Nel file di esempio, valore osservato, limite e stato sono conservati in colonne distinte, così che la successiva analisi possa utilizzare l'informazione disponibile senza attribuire un valore puntuale arbitrario.

Richiami Disponibilità e censura richiedono rappresentazioni capaci di conservarne il significato.

L’imputazione media modifica la dispersione

Se i valori mancanti vengono sostituiti con la media dei disponibili, la media finale rimane invariata, mentre i nuovi scarti dalla media sono tutti nulli. La somma dei quadrati degli scarti conserva quindi il valore precedente, ma viene divisa per un denominatore maggiore nel calcolo della varianza campionaria. La riduzione della dispersione deriva dall’operazione stessa. Per valutare l’incertezza dopo un’imputazione occorre considerare anche l’informazione assente e le ipotesi utilizzate per ricostruirla.

$$s^2_{\text{imp}} = \frac{n_o - 1}{n - 1} s^2_o, \qquad n \geq n_o > 1$$

Sviluppo e interpretazione

Qui n indica il numero totale delle righe e n_o quello dei valori osservati. L’identità vale quando ogni valore aggiunto coincide con la media dei disponibili e si usa il denominatore campionario n–1.

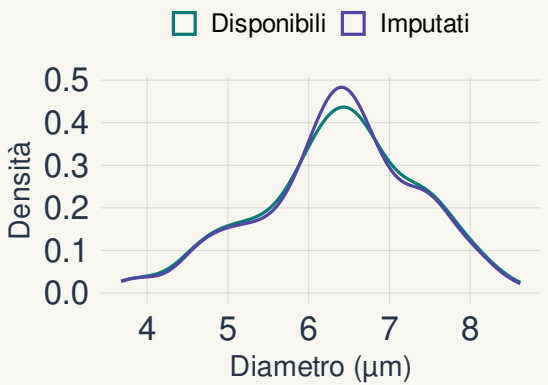
Richiami La dispersione introdotta dall’imputazione non rappresenta nuove misure.

La distribuzione conserva il segno dell'intervento

Nel confronto grafico, sei diametri sono resi indisponibili e sostituiti con la media dei 154 rimanenti. La media resta invariata, mentre la concentrazione dei valori aggiunti modifica la forma della distribuzione. La stima di densità dipende dal lisciamento; il rapporto fra varianza dopo imputazione, s^2_{imp}, e varianza dei disponibili, s^2_o, documenta invece una riduzione esatta di circa il 3,8%. L'esempio esamina l'effetto della trasformazione senza proporla come trattamento generale dei mancanti.

$$\frac{s^2_{\text{imp}}}{s^2_o} = \frac{154-1}{160-1} = \frac{153}{159} \simeq 0{,}9623$$

Evidenza grafica



Esempio sui fossili sintetici: 154 valori disponibili e sei imputazioni con la loro media.

Richiami Una trasformazione deve essere valutata attraverso proprietà numeriche e conseguenze interpretative.

Conservare limite e stato della registrazione

Il dato censurato viene rappresentato senza attribuirgli una misura esatta. La colonna del valore rimane indisponibile, il limite registra la soglia applicabile e lo stato identifica la natura dell'informazione. In questo modo, una procedura successiva può distinguere la censura dalla semplice assenza di dati. Se i limiti cambiano fra strumenti o campioni, il valore specifico deve essere conservato per ogni osservazione, affinché il modello possa utilizzarlo correttamente.

Lettura del diagramma

Registrazione della concentrazione

Valore	Limite	Stato
0,12	NA	misurato
NA	0,05	censurato

Il simbolo < viene conservato nello stato.

Struttura del file censura_esempio.csv; le due righe rappresentano una misura e una registrazione inferiore al limite.

Richiami Il limite è una proprietà dell'osservazione e del metodo con cui è stata ottenuta.

I vincoli possono coinvolgere più colonne

Un valore può essere plausibile isolatamente e incompatibile con un'altra misura dello stesso oggetto. Per un fossile, un diametro interno maggiore di quello esterno viola la geometria adottata, anche quando entrambi i numeri rientrano in un intervallo ordinario. Il controllo congiunto deve quindi precedere il calcolo dello spessore. Altri criteri, come una fascia attorno al totale degli ossidi, hanno invece un carattere diagnostico che richiede informazioni sul materiale e sul metodo analitico.

$$0 \le D_{\text{int}} \le D_{\text{est}}, \qquad D_{\text{est}} > 0$$

Sviluppo e interpretazione

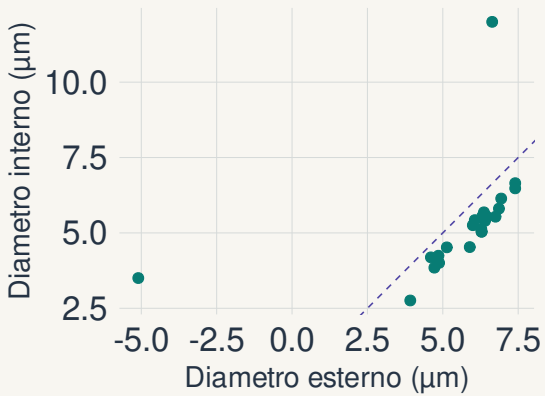
Il controllo segnala le righe incompatibili con il modello geometrico. La correzione di una misura richiede il confronto con il dato originale; una soglia statistica non identifica da sola la causa di un'anomalia.

Richiami Vincoli definitori e criteri empirici devono essere documentati separatamente.

La bisettrice rappresenta un limite geometrico

Nel piano dei due diametri, la bisettrice corrisponde all'uguaglianza fra misura interna ed esterna. I punti al di sopra sono incompatibili con la definizione geometrica utilizzata, mentre valori esterni non positivi impediscono di interpretare il rapporto fra diametri. La figura permette di identificare queste condizioni e di collegarle alle righe del registro. I punti lontani dal gruppo principale ma compatibili con i vincoli richiedono invece una valutazione della loro origine.

Evidenza grafica



Fossili del file da controllare. Il tratteggio indica D interno = D esterno; le misure assenti non vengono rappresentate.

Richiami Un grafico di controllo deve rendere riconoscibile la condizione che viene verificata.

Le condizioni devono avere un esito definito

Un confronto che coinvolge un valore mancante può produrre NA, anziché TRUE o FALSE. Prima di usare una condizione per filtrare la tabella, occorre quindi definirne il comportamento sui valori indisponibili. Il codice distingue la disponibilità dalla compatibilità geometrica e assegna un esito esplicito alla selezione. La distinzione rimane utile nel registro, perché una misura assente e una misura incompatibile richiedono verifiche differenti sulla fonte.

Implementazione in R

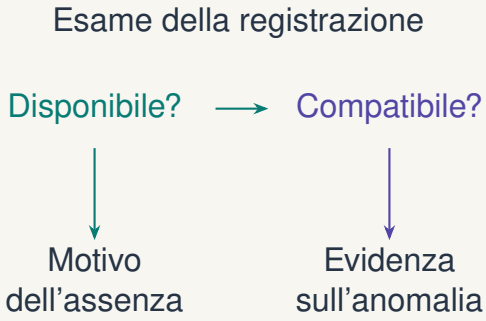
```
esterno <- c(8,5,NA,7)
interno <- c(6,6,4,5)
disponibile <- is.finite(esterno) & is.
    finite(interno)
valido <- disponibile & esterno>0 &
          interno>=0 & interno<=esterno
valido[is.na(valido)] <- FALSE
data.frame(esterno,interno,disponibile,
    valido)
```

Richiami Una condizione di inclusione deve essere interpretabile anche quando alcuni ingressi sono mancanti.

Il registro consente di rivedere una scelta

Ogni intervento viene associato alla riga di origine, al controllo che l'ha segnalata, all'evidenza utilizzata e alla decisione finale. Se nuove informazioni chiariscono che un valore insolito è valido, la procedura può essere rieseguita modificando la regola pertinente. Questa tracciabilità è particolarmente utile quando un filtro influenza numerose analisi successive. Il diagramma distingue l'esame della disponibilità da quello della compatibilità, così che le ragioni dell'intervento restino identificabili.

Lettura del diagramma



Schema di organizzazione del registro; gli esiti del controllo non implicano una correzione automatica.

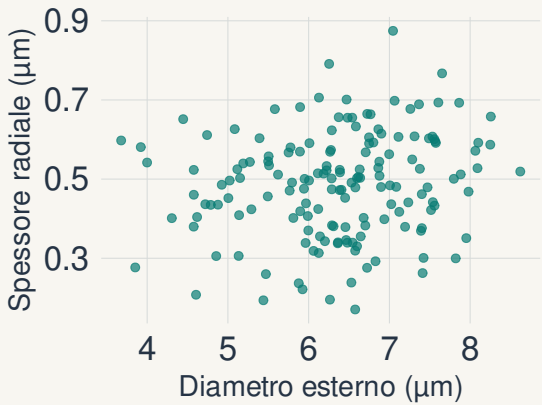
Richiami Una decisione riproducibile deve poter essere ricondotta all'evidenza che la sostiene.

La formula introduce relazioni fra colonne

Lo spessore radiale del modello adottato è metà della differenza fra diametro esterno e interno. Una volta aggiunto alla tabella, esso conserva una relazione algebrica esatta con le due misure originarie. Usare tutte e tre le colonne come informazioni indipendenti introdurrebbe una ridondanza che può alterare l'interpretazione di correlazioni, distanze e modelli. La formula deve quindi essere riportata nel dizionario insieme alle condizioni geometriche che ne permettono l'uso.

$$s = \frac{D_{\text{est}} - D_{\text{int}}}{2}, \qquad D_{\text{est}} - D_{\text{int}} - 2s = 0$$

Evidenza grafica



Diametro esterno e spessore radiale nei fossili sintetici; lo spessore è una grandezza derivata.

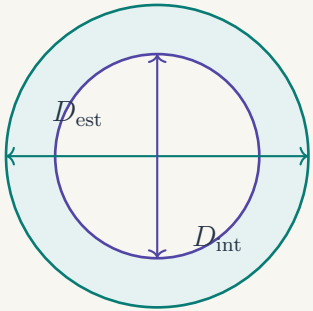
Richiami Le variabili derivate conservano le dipendenze determinate dalle loro definizioni.

Lo spessore richiede un modello geometrico

Il diagramma rappresenta una sezione circolare ideale nella quale la differenza fra i diametri comprende due tratti di parete. La divisione per due deriva da questa simmetria. Per un oggetto irregolare, la medesima formula può definire un indicatore convenzionale, ma il rapporto con lo spessore locale deve essere motivato dal protocollo. L'esplicitazione del modello geometrico permette di distinguere il calcolo corretto dell'indicatore dalla sua interpretazione morfologica.

Lettura del diagramma

Sezione ideale della parete



$$s = (D_{\text{est}} - D_{\text{int}})/2$$

Sezione ideale concentrica. Le frecce indicano i diametri utilizzati nella formula.

Richiami Una definizione geometrica deve essere coerente con il protocollo di misura.

Le masse degli ossidi vanno convertite in moli

Il rapporto molare fra magnesio e ferro richiede di convertire le percentuali in massa degli ossidi usando le rispettive masse molari e la stechiometria. Assumendo una base di cento grammi e trattando il ferro riportato come FeO, ogni mole di MgO e FeO contribuisce con una mole del rispettivo catione. Il rapporto ottenuto differisce da quello calcolato direttamente sulle masse. La convenzione sullo stato del ferro e sulla forma del rapporto deve essere dichiarata.

$$n_{\mathrm{Mg}} = \frac{w_{\mathrm{MgO}}}{40{,}304}, \qquad n_{\mathrm{Fe}} = \frac{w_{\mathrm{FeO}}}{71{,}844},$$
$$X_{\mathrm{Mg}} = \frac{n_{\mathrm{Mg}}}{n_{\mathrm{Mg}} + n_{\mathrm{Fe}}}$$

Sviluppo e interpretazione

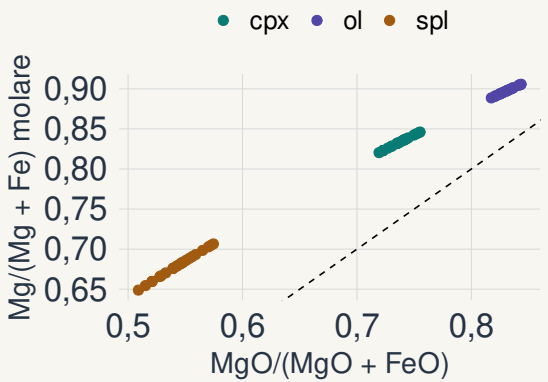
I simboli w_{MgO} e w_{FeO} indicano grammi di ossido su una base di 100 g; i divisori sono masse molari in g/mol. La frazione X_{Mg} varia fra zero e uno; la convenzione Mg# usa $100X_{\mathrm{Mg}}$. La presenza di ferro ferrico richiede un trattamento coerente con l’obiettivo mineralogico.

Richiami Una convenzione chimica deve essere definita prima dell’interpretazione del rapporto.

Rapporto in massa e rapporto molare

La figura confronta i due rapporti per le analisi sintetiche di microsonda. Lo scostamento dalla bisettrice deriva dalle differenti masse molari degli ossidi, che modificano i pesi dei cationi nel denominatore. L'associazione fra i due indici non li rende intercambiabili: una soglia mineralogica definita per il rapporto molare deve essere applicata alla quantità corrispondente. Le fasi del dataset identificano la costruzione didattica e non costituiscono classificazioni validate su campioni reali.

Evidenza grafica



Fasi simulate: cpx, clinopirosseno; ol, olivina; spl, spinello. Ascissa: rapporto in massa; ordinata: rapporto molare.

Richiami La definizione del rapporto determina quali confronti mineralogici siano ammissibili.

Una funzione delimita ingressi e risultati

Una funzione riunisce una trasformazione definita, rendendo espliciti gli argomenti necessari e la struttura del risultato. I controlli iniziali verificano le condizioni nelle quali la formula ha significato; i parametri permettono di modificare una scelta senza cercarla in più punti dello script. Questa organizzazione facilita il confronto fra gruppi e l'esecuzione ripetuta, purché la funzione conservi un compito circoscritto e il chiamante possa riconoscere eventuali modifiche agli oggetti o ai file.

Sviluppo e interpretazione

Nel laboratorio, una funzione di sintesi riceve un vettore e restituisce numerosità, media e dispersione. Una funzione per la densità richiede invece masse e volumi coerenti. Le due procedure possono essere composte nello script, mantenendo visibili i controlli di ingresso e il significato delle quantità restituite.

Richiami Le condizioni di applicabilità appartengono alla definizione della funzione.

Un caso stechiometrico verifica la funzione

Quando le masse dei due ossidi corrispondono a una mole ciascuna, il rapporto dei cationi deve essere un mezzo. Questo caso fornisce una risposta nota indipendente dal dataset di microsonda e permette di verificare che la funzione utilizzi la conversione molare. I controlli escludono lunghezze incompatibili, valori non finiti, masse negative e denominatori nulli. Il risultato rimane una quantità convenzionale, la cui interpretazione mineralogica presuppone che tutto il ferro considerato sia rappresentato come FeO.

Implementazione in R

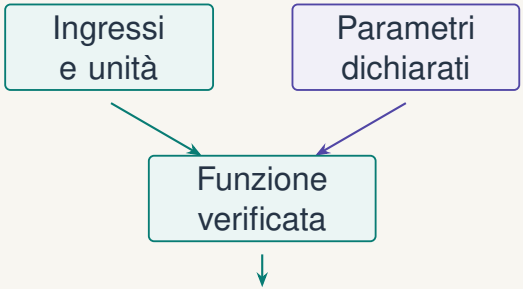
```
frazione_Mg <- function(MgO,FeO) {
 stopifnot(length(MgO)==length(FeO))
 stopifnot(all(is.finite(MgO)),all(is.finite
    (FeO)))
 stopifnot(all(MgO>=0),all(FeO>=0))
 a <- MgO/40.304; b <- FeO/71.844
 stopifnot(all(a+b>0))
 a/(a+b)
}
stopifnot(frazione_Mg(40.304,71.844)==0.5)
```

Richiami Il controllo su un caso noto verifica la definizione implementata, oltre alla sola esecuzione del codice.

Parametri e stato casuale sono dipendenze

Soglie, convenzioni e semi casuali determinano il risultato insieme ai dati e al codice. Riunirli in una sezione identificabile facilita la ricostruzione di un'esecuzione e il confronto fra scenari. Il seme inizializza un generatore specifico; versioni e algoritmi devono essere registrati quando si richiede una riproduzione numerica. I commenti spiegano il motivo delle scelte meno evidenti, mentre le istruzioni esprimono le operazioni necessarie a realizzarle.

Lettura del diagramma



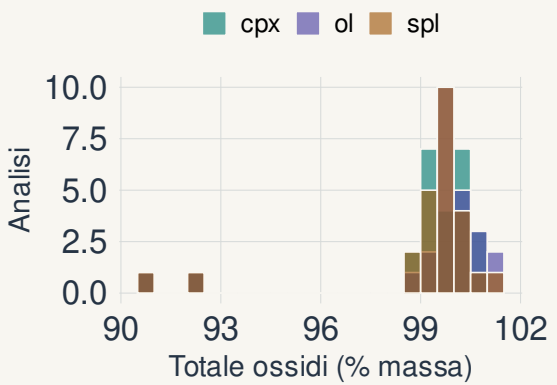
Dipendenze della procedura. Per le simulazioni, il registro comprende generatore, seme e ambiente.

Richiami La riproducibilità richiede di conservare le scelte che influenzano l'esecuzione.

Una soglia analitica richiede una motivazione

Il totale degli ossidi può segnalare un problema di analisi, una componente non misurata o una caratteristica del materiale. Una fascia attorno al cento per cento può essere utile come controllo preliminare, purché sia coerente con il metodo e con la composizione attesa. La figura descrive i totali delle analisi sintetiche prima dell'applicazione di un filtro. Il loro confronto deve considerare la natura delle fasi e le convenzioni con cui sono stati ottenuti i valori.

Evidenza grafica



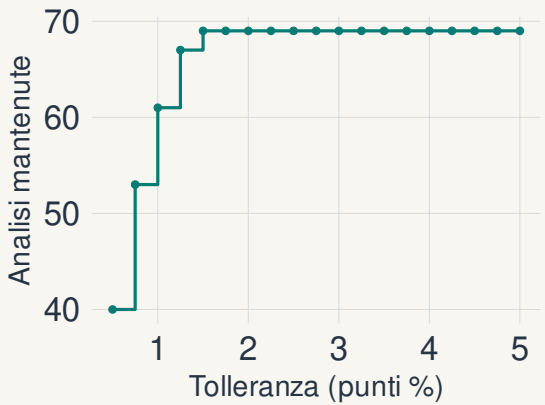
Fasi simulate: cpx, clinopirosseno; ol, olivina; spl, spinello. Classi di 0,5 punti percentuali di massa.

Richiami Il totale degli ossidi è un indicatore da interpretare rispetto al protocollo analitico.

La soglia determina la copertura finale

Allargando la tolleranza attorno al cento per cento aumenta il numero delle analisi mantenute. Il grafico descrive questa relazione operativa, senza identificare una soglia ottimale. La scelta deve essere motivata da caratteristiche del metodo e dell'applicazione, mentre l'analisi di sensibilità permette di documentarne le conseguenze. Se un risultato scientifico dipende fortemente da una fascia ristretta di soglie, tale dipendenza deve essere riportata insieme alla conclusione.

Evidenza grafica



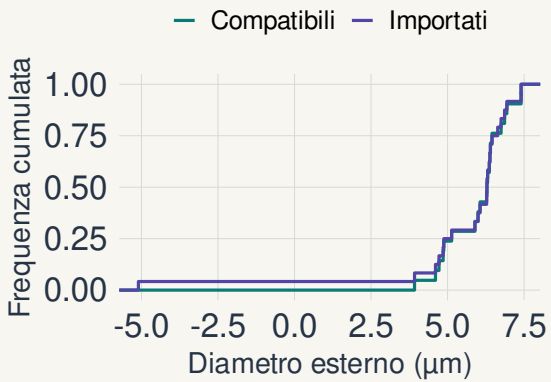
Numero delle analisi sintetiche con totale degli ossidi compreso entro la tolleranza indicata rispetto a 100.

Richiami La sensibilità documenta l'effetto di una scelta; la sua giustificazione richiede informazioni sul metodo.

Confrontare le distribuzioni prima e dopo i controlli

La distribuzione empirica dei diametri viene confrontata prima e dopo alcuni controlli dichiarati su identificativi e geometria. Lo scarto fra le curve rende visibile come il sottoinsieme analitico differisca dalle registrazioni importate. Ogni curva riporta la quota di valori non superiori al diametro in ascissa; i denominatori sono 24 misure importate disponibili e 21 compatibili. Questa rappresentazione consente di esaminare l'effetto delle decisioni senza nascondere i valori esclusi dalla procedura.

Evidenza grafica



Diametri disponibili prima e dopo i controlli su duplicati e geometria. I denominatori delle curve sono rispettivamente 24 e 21.

Richiami Il confronto fra input e tabella analitica rende valutabili le conseguenze dei filtri.

La consegna viene riletta e rieseguita

La rilettura verifica che il file esportato conservi identificativi e misure entro la precisione prevista. La riesecuzione da una sessione pulita verifica invece che il progetto contenga tutti gli input e che lo script ricostruisca le trasformazioni. I due controlli riguardano aspetti diversi della consegna e devono essere interpretati insieme. Il rapporto finale descrive inoltre quali valori rimangano incerti o incompatibili, così che la tabella derivata possa essere utilizzata conoscendone i limiti.

Implementazione in R

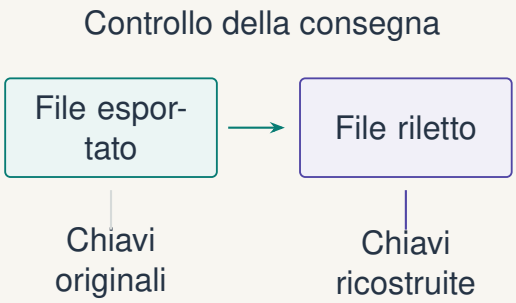
```
d <- read.csv('dati/campioni_modulo1.csv')
dir.create('risultati',showWarnings=FALSE)
f <- 'risultati/controllo_esportazione.csv'
write.csv(d,f,row.names=FALSE,na='')
r <- read.csv(f,stringsAsFactors=FALSE)
stopifnot(identical(d$id,r$id))
stopifnot(isTRUE(all.equal(d$massa_g,r$massa
    _g)))
```

Richiami Un file leggibile e una procedura ricostruibile sono entrambe condizioni della consegna.

Valutare il risultato della preparazione

La tabella analitica viene consegnata insieme al dizionario aggiornato, al registro degli interventi e al codice che la produce. Per valutarla, un lettore deve poter ricostruire quali unità siano presenti, quali misure siano disponibili e come siano state definite le variabili derivate. La verifica finale consiste nel descrivere queste proprietà e nel riconoscere quali decisioni possano influenzare le analisi successive. La pulizia del dato rimane quindi parte dell'argomentazione scientifica.

Lettura del diagramma



Il confronto fra file esportato e riletto viene applicato alle chiavi e alle colonne rilevanti.

Richiami La preparazione dei dati produce un insieme documentato di osservazioni e trasformazioni.

Documentazione delle operazioni utilizzate

I venti laboratori del modulo sviluppano importazione, conversione, indicizzazione, raggruppamento, collegamento, censura e variabili chimiche derivate. Gli script sono eseguibili dalla radice del progetto e conservano nei risultati le verifiche pertinenti. Le figure delle slide vengono prodotte da un sorgente R separato, che usa la medesima palette e registra i controlli numerici degli esempi. Le funzioni standard possono essere approfondite attraverso la documentazione distribuita con R.

Sviluppo e interpretazione

R Core Team, An Introduction to R: vettori, fattori, liste e data frame.

Manuale R Data Import/Export: convenzioni dei file e importazione.

Documentazione di read.csv, merge, aggregate, complete.cases e write.csv.

Wickham, Çetinkaya-Rundel e Grolemund, R for Data Science, seconda edizione: importazione, trasformazioni e relazioni.

Richiami La versione dell'ambiente effettivamente collaudato è riportata nei registri del progetto.