M07 · REVISIONE R6

Relazioni tra variabili e regressione

Dalla geometria dei minimi quadrati alla valutazione predittiva

33 slide · teoria, derivazioni, figure e applicazioni in R.
Provenienza dei dati e sorgenti nei materiali allegati.

M07

Percorso del modulo

3 Risposta, predittori e dominio

6 Correlazione e forma della relazione

9 Modello lineare e minimi quadrati

14 Incertezza e previsione

17 Diagnostica e osservazioni influenti

22 Predittori multipli e interazioni

26 Risposte binarie e probabilità

29 Valutazione su nuovi dati

32 Laboratorio e riferimenti

I numeri indicano le pagine iniziali; i titoli sono cliccabili. Codice, figure e verifiche sono inclusi nel progetto.

La regressione descrive una risposta condizionata

Un modello di regressione collega una risposta a informazioni disponibili sui predittori. Nel caso guida, il diametro interno del fossile viene descritto in funzione del diametro totale, mantenendo una coppia di misure per individuo. La domanda riguarda la risposta media a una data dimensione esterna e la variabilità dei singoli individui intorno a tale media. Il dominio osservato delimita l'evidenza empirica, mentre l'interpretazione fuori da quel dominio richiede ipotesi ulteriori sul processo.

$$E[Y \mid X = x] = m(x)$$

Sviluppo e interpretazione

X è il diametro totale e Y quello interno; m(x) è la risposta media a X = x. Il file contiene 160 fossili sintetici. I diametri sono in µm: la pendenza ha unità µm/µm, mentre intercetta, risposta prevista e residui hanno unità µm.

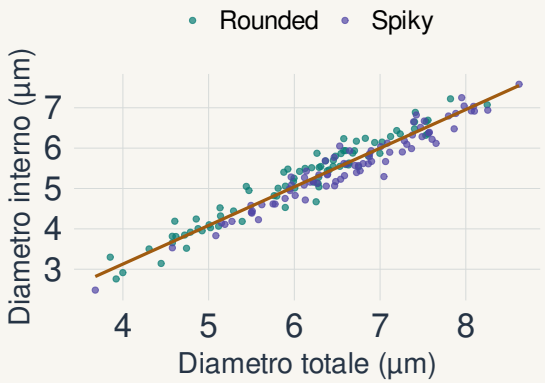
Richiami La risposta condizionata, il dominio dei predittori e le unità definiscono il significato del modello.

La nuvola conserva gruppi e relazioni geometriche

Lo scatterplot permette di esaminare direzione, curvatura, dispersione e osservazioni isolate prima della stima. Il colore identifica i morfotipi, rendendo visibile la possibilità che un'associazione complessiva combini strutture interne differenti. Nel dataset, diametro totale, interno e spessore sono inoltre legati da una definizione geometrica: una parte dell'associazione deriva quindi dalla costruzione delle variabili. Tale dipendenza deve essere riconosciuta prima di attribuire alla retta un'interpretazione sul processo biologico.

$$D_{\text{int}} = D_{\text{tot}} - 2s$$

Evidenza grafica



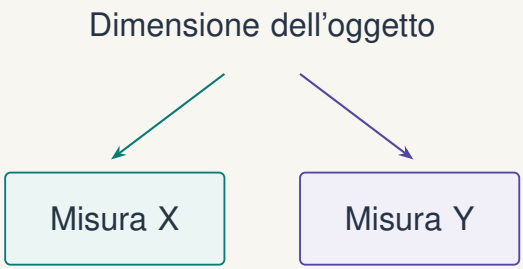
Diametri totale D_{tot} e interno D_{int} nei fossili sintetici; s è lo spessore. La retta è stimata sull'insieme delle coppie.

Richiami Le dipendenze introdotte dalle definizioni devono essere distinte dalle associazioni empiriche.

Una causa comune può generare associazione

Due misure possono variare insieme perché dipendono da una grandezza condivisa, come la dimensione complessiva dell'oggetto. Il diagramma rappresenta questa possibilità mediante una variabile che influenza entrambe le misure. La presenza di una correlazione è compatibile con tale struttura e con altre spiegazioni, per cui l'interpretazione causale richiede informazioni sul disegno e sul meccanismo. La regressione descrittiva rimane utile purché la conclusione venga riferita alla relazione effettivamente stimata.

Lettura del diagramma



Struttura causale ipotetica da motivare.

Richiami La relazione statistica deve essere interpretata alla luce dei meccanismi compatibili con il disegno.

La correlazione lineare è priva di unità

Il coefficiente di Pearson standardizza la covarianza attraverso le deviazioni standard e assume valori fra –1 e 1 quando entrambe le variabili hanno dispersione positiva. Il segno descrive la direzione della covariazione lineare, mentre il valore assoluto ne misura l'intensità rispetto alla dispersione marginale. La pendenza della regressione dipende invece anche dal rapporto fra le scale delle variabili, per cui una conversione delle unità può modificarla lasciando invariata la correlazione.

$$r = \frac{s_{XY}}{s_X s_Y}, \qquad \widehat{\beta}_1 = r\frac{s_Y}{s_X}$$

Sviluppo e interpretazione

s_{XY} è la covarianza campionaria; s_X e s_Y sono le deviazioni standard. $\widehat{\beta}_1$ è la pendenza della retta di Y su X con intercetta. Una correlazione elevata può accompagnare scarti individuali rilevanti; dominio ristretto e osservazioni lontane possono modificarla sensibilmente.

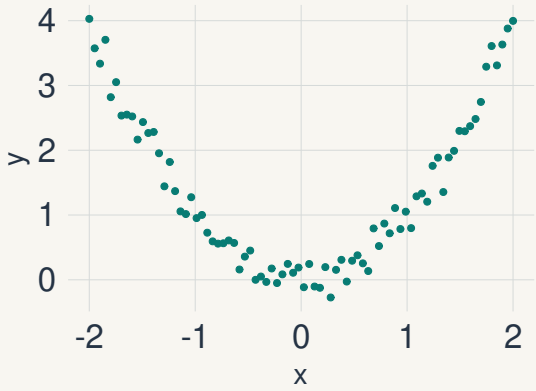
Richiami Correlazione e pendenza rispondono a definizioni differenti, anche quando condividono il segno.

Monotonia e linearità sono proprietà differenti

Spearman applica la correlazione ai ranghi e descrive l'associazione monotona, mantenendo la direzione degli ordinamenti. Una trasformazione strettamente crescente conserva tali ranghi, mentre può modificare la relazione lineare e il coefficiente di Pearson. La figura mostra una relazione a U, nella quale nessuno dei due riassunti monotoni descrive adeguatamente la struttura complessiva. L'esame grafico permette quindi di riconoscere quali proprietà rimangano escluse dalla sintesi numerica.

$$r_S = \mathrm{cor}\{\mathrm{rank}(X), \mathrm{rank}(Y)\}$$

Evidenza grafica



Risposta $y = x^2 + \varepsilon$, con errori normali indipendenti di deviazione 0,2. rank ordina i valori; cor calcola Pearson sui ranghi.

Richiami Una correlazione prossima a zero lascia aperta la presenza di relazioni non lineari.

Un’identità collega due sintesi della stessa nuvola

Il codice confronta Pearson e Spearman e verifica l’identità fra pendenza dei minimi quadrati e correlazione moltiplicata per il rapporto delle deviazioni standard. La relazione vale per una regressione semplice con intercetta e osservazioni utilizzate in modo coerente nei calcoli. Se una procedura escludesse righe differenti per valori mancanti, le quantità potrebbero riferirsi a campioni diversi e l’identità perderebbe il proprio riferimento comune.

Implementazione in R

```
d <- read.csv('dati/fossili_simulati.csv')
x <- d$diametro_tot_um
y <- d$diametro_int_um
c(Pearson=cor(x,y),
  Spearman=cor(x,y,method='spearman'))
fit <- lm(y~x)
stopifnot(abs(coef(fit)[2]-
 cor(x,y)*sd(y)/sd(x))<1e-12)
```

Richiami I confronti fra statistiche richiedono lo stesso insieme di osservazioni e le stesse convenzioni.

Interpretare i coefficienti della retta

La regressione lineare semplice assume che la risposta media cambi linearmente con il predittore. La pendenza rappresenta la variazione attesa per un incremento unitario di X, mentre l'intercetta individua il valore della retta a X uguale a zero. Quando lo zero si trova lontano dai dati, l'intercetta mantiene un ruolo algebrico ma richiede cautela interpretativa. Centrare il predittore in un valore pertinente rende l'intercetta una risposta media riferita a quel valore, senza modificare le previsioni.

$$Y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \qquad E[\varepsilon_i \mid X] = 0$$
$$x_i^c = x_i - x_0, \quad \beta_0^c = \beta_0 + \beta_1 x_0$$

Sviluppo e interpretazione

β_0 è l'intercetta, β_1 la pendenza ed ε_i l'errore individuale; x_0 è il centro scelto per il predittore. Il modello condiziona sui valori di X osservati. L'inferenza classica aggiunge condizioni su varianza, dipendenza e distribuzione degli errori, da valutare mediante disegno e diagnostica.

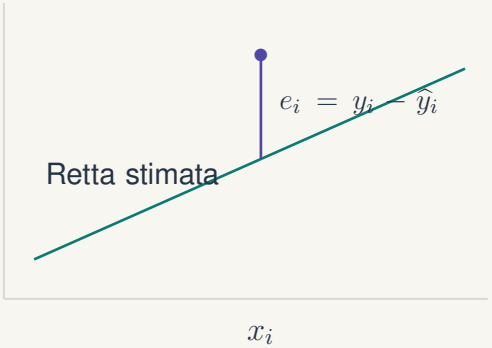
Richiami Centrare il predittore cambia l'interpretazione dell'intercetta e conserva la retta stimata.

Il criterio dei minimi quadrati

I coefficienti vengono stimati minimizzando la somma degli scarti quadratici fra risposte osservate e valori sulla retta. La soluzione esplicita della regressione semplice collega la pendenza alla covariazione e l'intercetta alle medie. Il residuo conserva segno e unità della risposta; il suo contenuto può includere eterogeneità naturale, predittori omessi, errori di misura e inadeguatezza della forma media. Il diagramma distingue la distanza verticale dalla posizione del punto lungo il predittore.

$$\widehat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}, \quad \widehat{\beta}_0 = \bar{y} - \widehat{\beta}_1 \bar{x}$$

Lettura del diagramma



x_i, y_i: coppia osservata; $\bar{x}, \bar{y}$: medie. Il residuo $e_i = y_i - \widehat{y}_i$ è verticale. Occorre variabilità positiva del predittore.

Richiami Il residuo misura lo scostamento della risposta osservata dalla risposta stimata.

La formula di R identifica risposta e predittore

Nella chiamata lm, la risposta compare a sinistra del simbolo di formula e i predittori a destra. L'oggetto stimato conserva coefficienti, residui e informazioni necessarie alle previsioni. Il codice valuta la risposta media per un diametro totale di sei micrometri e confronta tale valore con il dominio osservato. La previsione va interpretata entro il modello dichiarato, mantenendo distinte la stima della media e la variabilità di un nuovo individuo.

Implementazione in R

```
d <- read.csv('dati/fossili_simulati.csv')
fit <- lm(diametro_int_um~diametro_tot_um,d)
coef(fit)
summary(fit)
nuovo <- data.frame(diametro_tot_um=6)
predict(fit,nuovo,interval='confidence')
range(d$diametro_tot_um)
```

Richiami La previsione deve riportare il valore del predittore e il tipo di quantità prevista.

La formulazione matriciale estende la regressione

Disponendo i predittori nelle colonne della matrice del disegno, la regressione multipla assume la stessa struttura della retta semplice. La prima colonna contiene uno quando si include l'intercetta. Se le colonne sono linearmente indipendenti, le equazioni normali determinano una soluzione unica; in pratica, R usa una decomposizione numericamente più stabile dell'inversione esplicita. La matrice consente di rappresentare nello stesso linguaggio predittori continui, indicatori categoriali e interazioni.

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$$
$$\widehat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$$

Sviluppo e interpretazione

X ha n righe e p colonne, dove p comprende l'intercetta. L'espressione inversa richiede rango pieno; quando esistono dipendenze esatte fra colonne, alcuni coefficienti non sono identificabili separatamente.

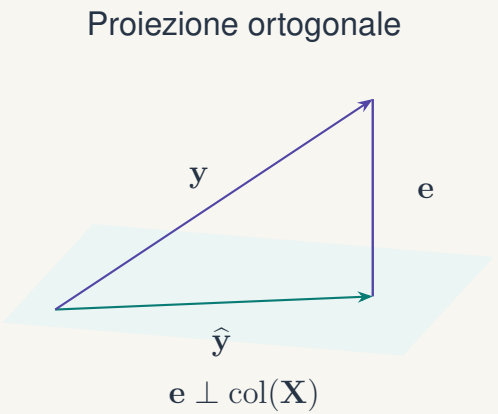
Richiami Il rango della matrice del disegno determina quali coefficienti possano essere stimati.

I residui sono ortogonali allo spazio del modello

Le equazioni normali impongono che il vettore dei residui sia ortogonale alle colonne della matrice del disegno. Se l'intercetta è inclusa, i residui sommano pertanto a zero; risultano inoltre ortogonali ai valori stimati. Si tratta di proprietà algebriche della soluzione dei minimi quadrati, che possono verificarsi anche quando la forma media è inadeguata o la varianza cambia con il predittore. Il diagramma rappresenta la proiezione della risposta nello spazio generato dalle colonne.

$$\mathbf{X}^\top \mathbf{e} = \mathbf{0}, \qquad \mathbf{y} = \hat{\mathbf{y}} + \mathbf{e}$$

Lettura del diagramma



y: risposte osservate; $\widehat{y}$: valori stimati; e: residui.

col(X) è lo spazio delle colonne del disegno.

Schema distinto dallo scatterplot.

Richiami Le identità dei minimi quadrati verificano il calcolo, mentre l'adeguatezza richiede diagnostica e disegno.

La dispersione residua stima una scala condizionale

Se la forma media è corretta e gli errori sono centrati, indipendenti e omoscedastici, la somma quadratica residua divisa per n−p stima la varianza condizionale della risposta. Il coefficiente R² confronta invece tale somma con quella del modello che usa soltanto la media, quando entrambi sono stimati sulle stesse osservazioni e con intercetta. Il suo valore descrive il miglioramento dell'adattamento nel campione; la capacità di prevedere nuovi casi richiede una valutazione separata, coerente con l'uso previsto.

$$s^2 = \frac{SSE}{n-p}, \qquad R^2 = 1 - \frac{SSE}{\sum_i (y_i - \bar{y})^2}$$

Sviluppo e interpretazione

$SSE = \sum_i (y_i - \widehat{y}_i)^2$; n conta le osservazioni e p i coefficienti stimabili, inclusa l'intercetta, con n > p. Una maggiore flessibilità può ridurre SSE adattando oscillazioni del campione. Confronti fra risposte trasformate richiedono una scala coerente per errori e denominatori.

Richiami Adattamento campionario e prestazione su nuovi dati devono essere valutati con quantità appropriate.

Intervalli per media e individuo

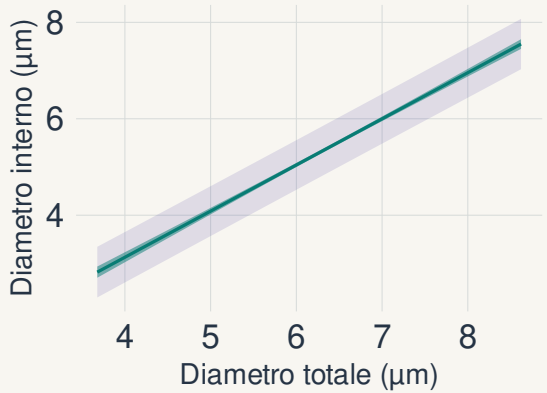
Per un nuovo vettore di predittori, la varianza della risposta media stimata dipende dalla sua posizione rispetto al disegno osservato. La previsione di un nuovo individuo aggiunge la variabilità residua della risposta, producendo un intervallo più ampio. Le formule classiche sono esatte sotto errori normali, indipendenti e omoscedastici, con un nuovo errore indipendente dal campione. La loro validità richiede inoltre che il modello resti pertinente nel punto in cui si prevede.

$$h_0 = \mathbf{x}_0^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_0$$

$$IC_{\text{media}} : \ \hat{y}_0 \pm t_{n-p,1-\alpha/2} s \sqrt{h_0}$$

$$IP_{\text{individuo}} : \ \hat{y}_0 \pm t_{n-p,1-\alpha/2} s \sqrt{1 + h_0}$$

Evidenza grafica



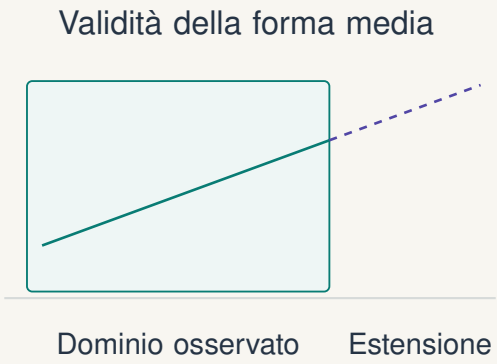
$\mathbf{x}_0$: nuovo disegno; n: osservazioni; p: coefficienti; s: deviazione residua; t: quantile di Student. Intervalli 95%: media verde, individuo viola.

Richiami Il tipo di intervallo deve corrispondere alla quantità richiesta dalla previsione.

Estrapolazione e validità del modello

La formula dell'intervallo può essere valutata anche lontano dai predittori osservati, dove il termine di leva tende ad aumentare. Tale ampliamento quantifica però l'incertezza entro la forma assunta; una curvatura o un cambiamento di regime fuori dal campione può restare escluso dal modello. Il diagramma separa il dominio sostenuto dai dati dalla continuazione della retta, rendendo esplicito il passaggio dall'interpolazione a un'ipotesi di trasferimento.

Lettura del diagramma

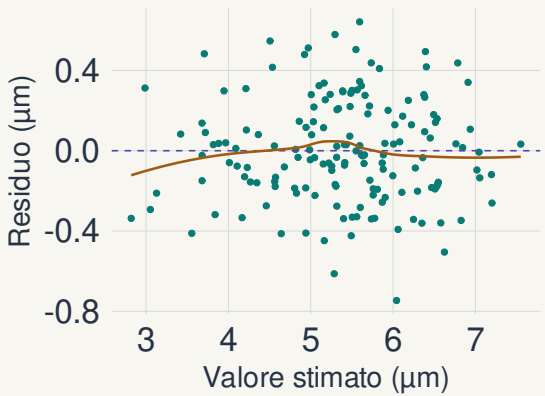


Richiami L'incertezza parametrica dell'intervallo lascia da valutare la validità della forma fuori dal campione.

La struttura dei residui orienta la revisione

Nel grafico residui–valori stimati, una curvatura sistematica suggerisce che la forma media lineare lasci una componente prevedibile. Una dispersione a ventaglio indica invece che la variabilità condizionale potrebbe cambiare lungo il dominio. La distinzione orienta interventi diversi, come una diversa specificazione della media o una modellazione della varianza. Il confronto con una curva locale può aiutare l'esplorazione, purché la flessibilità introdotta venga interpretata rispetto alla numerosità e al disegno.

Evidenza grafica



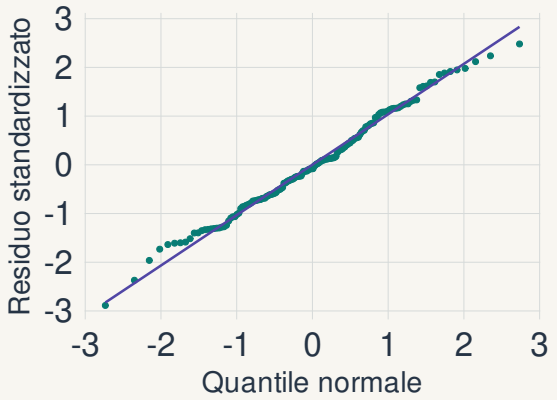
Residui del modello lineare sui fossili sintetici; la curva LOESS serve come riferimento esplorativo.

Richiami Forma media e struttura della varianza richiedono controlli distinti.

Il QQ plot confronta quantili e code

Il QQ plot dei residui standardizzati confronta l'ordinamento osservato con quantili normali di riferimento. Scostamenti sistematici nelle code possono segnalare una forma differente da quella assunta nell'inferenza classica. I residui stimati condividono tuttavia vincoli e dipendenze introdotti dall'adattamento, per cui la figura va interpretata come diagnostica del modello. Una deviazione grafica richiede di considerarne la rilevanza per intervalli, osservazioni influenti e obiettivo dell'analisi.

Evidenza grafica



QQ plot dei residui standardizzati; la linea di riferimento collega i quartili secondo la convenzione di ggplot2.

Richiami La diagnostica deve valutare le conseguenze dello scostamento per la conclusione richiesta.

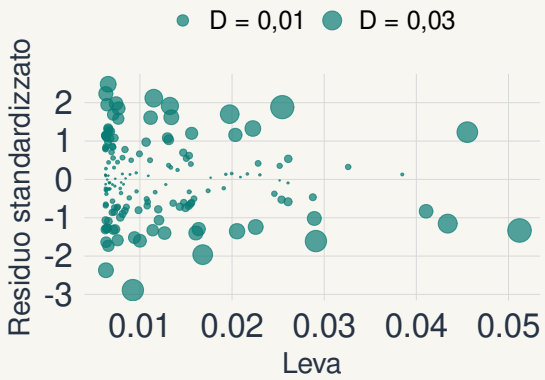
Leva e residuo contribuiscono all'influenza

La leva misura quanto la posizione di un'osservazione nei predittori sia distante rispetto al disegno. Un residuo elevato segnala invece uno scostamento nella risposta. La distanza di Cook combina questi contributi per riassumere quanto l'eliminazione di un caso modifichi l'adattamento. La segnalazione richiede un esame della provenienza e un'analisi di sensibilità; l'esclusione deve essere motivata da evidenza sulla misura o sull'ambito del modello.

$$h_{ii} = \mathbf{x}_i^\top (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{x}_i$$

$$D_i = \frac{e_i^2}{p\, s^2} \frac{h_{ii}}{(1 - h_{ii})^2}$$

Evidenza grafica



e_i: residuo; s: deviazione residua; p: coefficienti; h_{ii}: leva. Area dei punti proporzionale a D_i, distanza di Cook.

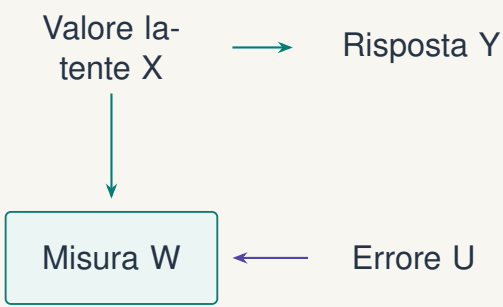
Richiami Un punto lontano nel predittore e un punto lontano nella risposta esercitano ruoli differenti.

L’errore nel predittore modifica il riferimento

La regressione ordinaria tratta i predittori come noti nel modello condizionale. Se una misura osservata è la somma di un valore latente e di un errore indipendente, il rapporto fra variabilità del segnale e variabilità totale può attenuare la pendenza stimata. La formula descrive il modello classico con errore additivo, centrato e indipendente dal valore latente e dall’errore della risposta. Altri meccanismi di misura possono produrre effetti differenti e richiedono una formulazione specifica.

$$W = X + U, \qquad \operatorname{plim} \widehat{\beta}_W = \beta_X \frac{\operatorname{Var}(X)}{\operatorname{Var}(X) + \operatorname{Var}(U)}$$

Lettura del diagramma



W contiene segnale ed errore di misura.

plim indica il limite in probabilità. X è il segnale, U l’errore, W la misura. Se Var(X) = Var(U), la pendenza limite è $\beta_X/2$.

Richiami Il modello della misura del predittore appartiene alle ipotesi della regressione.

Interpretare la scala trasformata

Una relazione moltiplicativa può essere rappresentata mediante logaritmi, così che una pendenza descriva variazioni relative. Nel modello log–log, un incremento relativo piccolo del predittore corrisponde approssimativamente a una variazione relativa della risposta pari alla pendenza moltiplicata per tale incremento. Riportando una previsione alla scala originaria, l'esponenziale della media logaritmica non coincide in generale con la media aritmetica della risposta: la dispersione residua entra nella ritrasformazione.

$$\log Y = \beta_0 + \beta_1 \log X + \varepsilon$$

$$E[Y \mid X] = e^{\beta_0} X^{\beta_1} e^{\sigma^2/2} \quad \text{se } \varepsilon \sim N(0, \sigma^2)$$

Sviluppo e interpretazione

La trasformazione richiede dati positivi e un'interpretazione coerente del meccanismo. Il fattore esponenziale della varianza vale per errori logaritmici normali omoscedastici; con altre distribuzioni occorre una correzione pertinente.

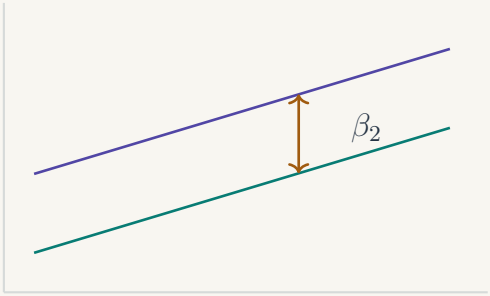
Richiami Il ritorno alla scala fisica deve identificare quale misura di posizione venga prevista.

Un indicatore confronta gruppi a pari predittore

Aggiungendo un indicatore di morfotipo al modello del diametro interno, il coefficiente del gruppo descrive una differenza media a parità di diametro totale, sotto l'ipotesi di pendenza comune. Tale confronto richiede un dominio di sovrapposizione adeguato fra gruppi, poiché un aggiustamento in assenza di valori comparabili dipenderebbe fortemente dall'estrapolazione. Il diagramma mostra due rette parallele, la cui distanza verticale rappresenta il contrasto condizionato.

$$E[Y \mid x, G] = \beta_0 + \beta_1 x + \beta_2 G, \qquad G \in \{0,1\}$$

Lettura del diagramma



G = 0 per Rounded, G = 1 per Spiky; X è il diametro totale, Y quello interno. Schema illustrativo con pendenza comune.

Richiami Il coefficiente del gruppo è condizionato ai predittori e alla forma del modello.

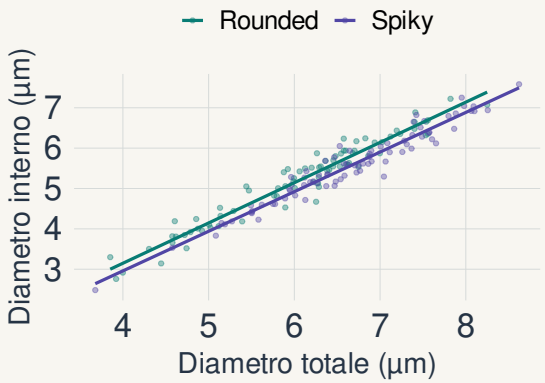
L’interazione rende il contrasto dipendente da x

Un termine di interazione fra diametro totale e morfotipo permette pendenze differenti. In questo modello, la differenza fra gruppi è la somma di un contributo costante e di un contributo proporzionale al predittore, per cui un unico numero non descrive il contrasto sull’intero dominio. Centrare X in una dimensione pertinente rende il coefficiente del gruppo interpretabile in quel punto, mentre la figura permette di leggere come il confronto cambi lungo la scala.

$$E[Y \mid x, G] = \beta_0 + \beta_1 x + \beta_2 G + \beta_3 x G$$

$$\Delta(x) = \beta_2 + \beta_3 x$$

Evidenza grafica



G = 0: Rounded; G = 1: Spiky. $\Delta(x)$ è Spiky meno Rounded a diametro totale x. Rette nei rispettivi domini osservati.

Richiami In presenza di interazione, il contrasto deve essere riferito a valori espliciti dei predittori.

La ridondanza esatta impedisce l'identificazione

Diametro totale, interno e spessore sono collegati per definizione, salvo arrotondamenti nel file. Quando l'identità è esatta, inserirli tutti come predittori produce colonne dipendenti nella matrice del disegno, per cui coefficienti differenti possono descrivere la stessa risposta prevista. Anche dipendenze molto forti, senza uguaglianza esatta, possono rendere instabili i coefficienti. La scelta delle variabili deve quindi riflettere le definizioni, la domanda e l'informazione disponibile, mantenendo una complessità sostenibile rispetto alla numerosità.

$$D_{\text{tot}} - D_{\text{int}} - 2s = 0 \quad \Rightarrow \quad \operatorname{rank}(X) < p$$

Lettura del diagramma

Tre colonne collegate da una definizione

$$X\mathbf{v} = \mathbf{0}, \quad \mathbf{v} \neq \mathbf{0}$$

$$X(\boldsymbol{\beta} + c\mathbf{v}) = X\boldsymbol{\beta}$$

s è lo spessore; X è la matrice del disegno con p colonne. rank(X) conta le colonne linearmente indipendenti.

Richiami La stessa previsione può corrispondere a coefficienti non univoci quando il disegno è privo di rango pieno.

La matrice del disegno rende esplicita la codifica

La funzione model.matrix permette di ispezionare le colonne effettivamente utilizzate dalla formula, inclusi gli indicatori e i prodotti dell'interazione. Il codice fissa Rounded come riferimento, così che il coefficiente del morfotipo corrisponda a Spiky rispetto a Rounded nella parametrizzazione scelta. La codifica influenza il significato dei singoli coefficienti, mentre formulazioni equivalenti conservano i valori previsti. La relazione deve riportare il riferimento categoriale e i termini inclusi.

Implementazione in R

```
d <- read.csv('dati/fossili_simulati.csv')
d$morfotipo <- relevel(factor(d$morfotipo),'
    Rounded')
a <- lm(diametro_int_um~diametro_tot_um+
    morfotipo,d)
b <- lm(diametro_int_um~diametro_tot_um*
    morfotipo,d)
coef(a)
coef(b)
colnames(model.matrix(b))
```

Richiami La formula statistica e la codifica dei fattori devono essere riconoscibili nella matrice del disegno.

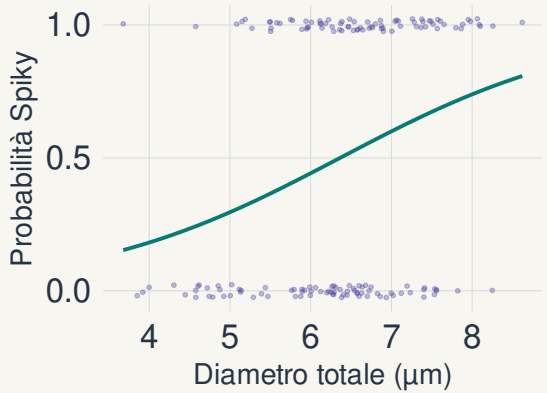
La logistica modella una probabilità condizionata

Per una risposta binaria, il modello associa a ciascun insieme di predittori una probabilità compresa fra zero e uno. Il predittore lineare opera sui log-odds, mentre la funzione logistica lo riporta alla scala probabilistica. Nel caso didattico, l'etichetta Spiky viene descritta in funzione del diametro totale, senza attribuire alla relazione una regola tassonomica validata. I coefficienti vengono stimati massimizzando la verosimiglianza Bernoulli delle osservazioni.

$$Y_i \mid x_i \sim \mathrm{Bern}(p_i), \qquad \log \frac{p_i}{1-p_i} = \eta_i$$

$$p_i = \frac{1}{1+e^{-\eta_i}}, \qquad \eta_i = \beta_0 + \beta_1 x_i$$

Evidenza grafica



Y = 1 per Spiky e 0 per Rounded; x è il diametro totale. Probabilità stimata sui dati sintetici; jitter verticale solo per la lettura.

Richiami La probabilità stimata dipende da definizione della risposta, predittori e campione di addestramento.

Un coefficiente agisce sugli odds e sulla probabilità

Nel modello logistico senza interazione, un incremento unitario del predittore moltiplica gli odds per l'esponenziale del coefficiente, a parità degli altri predittori. La variazione della probabilità dipende invece dal valore iniziale, perché la derivata contiene il prodotto p(1−p). Lo stesso coefficiente può quindi produrre variazioni probabilistiche diverse lungo il dominio. Una comunicazione interpretabile può affiancare all'odds ratio probabilità previste per valori scientificamente pertinenti.

$$OR = e^{\beta_1}, \qquad \frac{dp}{dx} = \beta_1 p(1-p)$$

Lettura del diagramma

Un passo in x: odds $\times 2$

p = 0,20 $\longrightarrow$ $p' = 1/3$

Odds: $0{,}25 \longrightarrow 0{,}50$

p = 0,80 $\longrightarrow$ $p' = 8/9$

Odds: $4 \longrightarrow 8$

Esempio con $\beta_1 = \log 2$: un incremento unitario di x raddoppia gli odds. Le probabilità passano da 0,20 a 1/3 e da 0,80 a 8/9.

Richiami Un effetto costante sui log-odds produce variazioni non costanti della probabilità.

La soglia traduce una probabilità in una decisione

La trasformazione delle probabilità in etichette richiede una soglia, scelta secondo i costi degli errori e l'uso previsto. Assumendo costo zero per le decisioni corrette e probabilità calibrate sulla popolazione d'uso, il confronto dei costi attesi determina la soglia ottima. Un modello può ordinare bene i casi e sovrastimare le probabilità: discriminazione e calibrazione richiedono quindi controlli distinti su nuovi dati. Il codice restituisce probabilità sulla scala della risposta.

Implementazione in R

$C_{FP} > 0$: costo del falso positivo;
$C_{FN} > 0$: costo del falso negativo.
Soglia ottima: $C_{FP}/(C_{FP} + C_{FN})$.

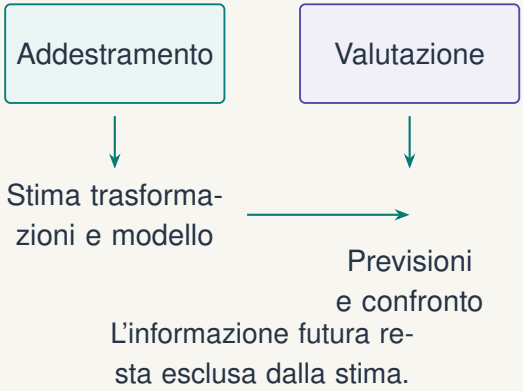
```
d <- read.csv('dati/fossili_simulati.csv')
d$spiky <- as.integer(d$morfotipo=='Spiky')
g <- glm(spiky~diametro_tot_um,d,family=
    binomial())
nuovi <- data.frame(diametro_tot_um=c(5,6,7)
    )
predict(g,nuovi,type='response')
exp(coef(g))
stopifnot(all(fitted(g)>0 & fitted(g)<1))
```

Richiami La soglia appartiene alla regola decisionale, mentre la calibrazione riguarda la corrispondenza delle probabilità.

Separare addestramento e valutazione

Un insieme di valutazione deve rappresentare l'uso futuro del modello e rimanere escluso dalla stima delle sue componenti. Per individui indipendenti può essere appropriata una partizione casuale; per stazioni o serie temporali occorre invece rispettare gruppi e ordine. Medie, scale, imputazioni e scelte di variabili vengono apprese all'interno dell'addestramento. Il diagramma mostra questa dipendenza, nella quale la trasformazione stimata viene applicata al test senza utilizzare la sua risposta.

Lettura del diagramma



Richiami La partizione deve simulare la disponibilità di informazione nell'applicazione futura.

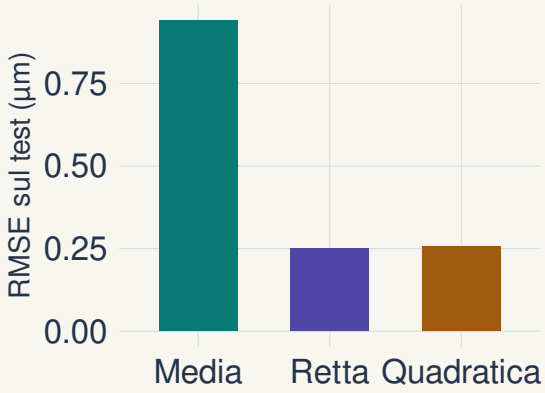
Il riferimento semplice rende interpretabile l'errore

La previsione costante basata sulla media del campione di addestramento fornisce un riferimento per valutare l'utilità dei predittori. Il confronto usa gli stessi casi di test, conservando gli identificativi. L'errore assoluto medio riassume scostamenti nelle unità della risposta, mentre la radice dell'errore quadratico medio attribuisce maggiore peso agli scarti grandi. La metrica deve riflettere le conseguenze scientifiche degli errori.

$$MAE = \frac{1}{m}\sum_{i=1}^{m}|y_i - \widehat{y}_i|$$

$$RMSE = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(y_i - \widehat{y}_i)^2}$$

Evidenza grafica



m = 40 casi di test; y_i è l'osservato e $\widehat{y}_i$ la previsione. RMSE per media di addestramento, retta e quadratica sulla stessa partizione.

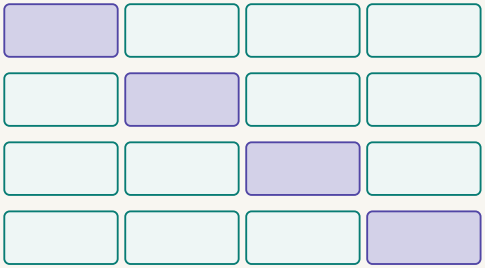
Richiami I modelli devono essere confrontati sullo stesso insieme di valutazione e sulla stessa scala.

La validazione ripete l’intera procedura di stima

La validazione incrociata ripete l’addestramento su porzioni del campione e valuta ogni volta osservazioni escluse. Se vengono confrontate specificazioni o iperparametri, le scelte dipendono da tali risultati e richiedono una valutazione finale capace di tener conto della selezione. Ogni trasformazione appresa dai dati deve essere ricalcolata nel campione di addestramento della singola partizione. Il diagramma rappresenta la rotazione del blocco escluso, mantenendo distinta la sua funzione dalle righe usate per stimare.

Lettura del diagramma

Quattro partizioni illustrative



Viola: blocco escluso dalla stima del giro.

Richiami La valutazione riguarda la procedura completa, comprese le trasformazioni e la selezione del modello.

La consegna collega stima, diagnostica e previsione

Il laboratorio costruisce il modello del diametro interno a partire da una partizione dichiarata dei fossili. La relazione presenta unità e formula, interpreta i coefficienti, esamina residui e influenza e confronta le previsioni con un riferimento costante stimato sul solo addestramento. La tabella finale conserva identificativo, osservato, previsto ed errore per ogni caso di test. L'analisi per morfotipo permette inoltre di verificare se la prestazione aggregata nasconda differenze fra gruppi.

Sviluppo e interpretazione

Consegna: script eseguibile, grafico della relazione, diagnostica, tabella delle previsioni e confronto delle metriche. La conclusione deve identificare dominio, popolazione rappresentata e limiti della simulazione. I venti laboratori approfondiscono regressione semplice, multipla, logistica e valutazione.

Richiami La valutazione del modello deve permettere di risalire dagli errori ai casi cui si riferiscono.

Riferimenti per stima e diagnostica

Le funzioni lm e model.matrix documentano la formulazione del modello e la codifica dei predittori, mentre predict.lm distingue intervalli per media e individuo. Le funzioni di influenza rendono disponibili leva e distanza di Cook; glm e predict.glm descrivono il modello binomiale e le scale della previsione. I sorgenti del corso verificano identità dei minimi quadrati e intervalli attraverso calcoli matriciali, collegando le formule ai risultati del software.

Sviluppo e interpretazione

R Core Team: lm, model.matrix, predict.lm, influence.measures, glm e predict.glm.
Le convenzioni impiegate sono riferite alla versione R registrata nel collaudo. Fonti online e file dei risultati sono inclusi nel progetto.

Richiami Le impostazioni del software devono essere associate alle ipotesi e alle quantità definite nel modello.