P10 · REVISIONE R6

Un’analisi ricostruibile e verificabile

Dati immutati, funzioni, controlli numerici e storia delle modifiche

16 slide · teoria, derivazioni, figure e applicazioni in R.
Provenienza dei dati e sorgenti nei materiali allegati.

P10

Percorso del modulo

3 Dati e trasformazioni dichiarate

8 Prove del codice e integrità dei file

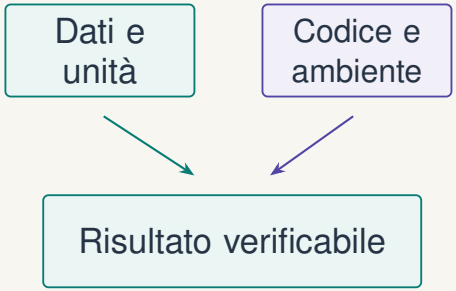
13 Piani casuali, versioni e consegna

I numeri indicano le pagine iniziali; i titoli sono cliccabili. Codice, figure e verifiche sono inclusi nel progetto.

La riproducibilità riguarda l'intero procedimento

Il progetto ricostruisce la densità di ventiquattro provini e ne calcola la media nelle sei stazioni di provenienza. La quantità fisica è semplice, così che l'attenzione possa concentrarsi su provenienza dei dati, funzioni, verifiche ed esportazione dei risultati. Ogni passaggio viene conservato in forma eseguibile e accompagnato dalle condizioni che ne determinano il significato. Ottenere nuovamente lo stesso numero dimostra la stabilità del procedimento dichiarato, mentre la validità della misura e della conclusione geologica richiede anche un'adeguata definizione del problema.

Lettura del diagramma



La conclusione conserva anche le ipotesi scientifiche.

Richiami La ricostruzione del calcolo deve conservare dati, trasformazioni, ambiente e significato della quantità stimata.

Il contratto dei dati precede il calcolo

La funzione di validazione richiede identificativi unici, stazioni presenti, masse e volumi numerici, finiti e strettamente positivi. Tali condizioni definiscono il dominio ammissibile dell'operazione, poiché una divisione formalmente eseguibile potrebbe altrimenti produrre risultati fisicamente incoerenti. La validazione restituisce la tabella controllata, che passa alla trasformazione successiva. Il dato originario rimane conservato e ogni correzione sostanziale dovrebbe essere documentata nella fonte, evitando sostituzioni implicite durante il calcolo.

$$m_i, V_i \in \mathbb{R}_{>0} \quad \forall i, \qquad id_i \neq id_j \quad (i \neq j)$$

Sviluppo e interpretazione

m_i: massa in g; V_i: volume in cm³; id_i: identificativo del provino. Si richiedono anche schema valido e stazione presente. Finitezza e positività escludono NA, NaN e infiniti. Gli identificativi sono unici; la stazione si ripete perché raggruppa provini distinti.

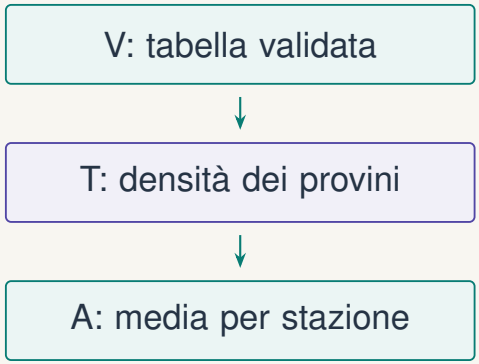
Richiami Un contratto esplicito permette di distinguere un input inammissibile da un risultato inatteso ma valido.

La funzione compone operazioni con un significato

Il procedimento applica dapprima la validazione, quindi aggiunge la densità come rapporto fra massa e volume e infine aggrega per stazione. La composizione conserva la relazione fra unità fisica e unità della tabella: il rapporto è espresso in grammi per centimetro cubo, mentre la sintesi restituisce una riga per stazione. La funzione restituisce sempre un risultato ordinato per identificativo della stazione, rendendo confrontabili esecuzioni che ricevono le stesse righe in un ordine differente.

$$F = A \circ T \circ V, \qquad \rho_i = \frac{m_i}{V_i}$$

Lettura del diagramma



V: validazione; T: trasformazione; A: aggregazione. Si applica prima V. m_i: massa in g; V_i: volume in cm³; ρ_i: densità.

Richiami La composizione è definita anche dai tipi di oggetto restituiti e dall'unità rappresentata in ogni passaggio.

Un valore manuale controlla il risultato

Il primo provino ha massa 107,2 grammi e volume quaranta centimetri cubi, da cui deriva una densità di 2,68. Per la stazione A1 la media delle quattro densità è 2,685. Questi valori vengono calcolati indipendentemente dalla funzione generale e inseriti nei controlli. Il confronto verifica così un risultato fisico elementare, anziché limitarsi a ripetere la medesima istruzione del programma. La tabella originale viene inoltre controllata per accertare che l'aggiunta della densità riguardi soltanto l'oggetto restituito.

Implementazione in R

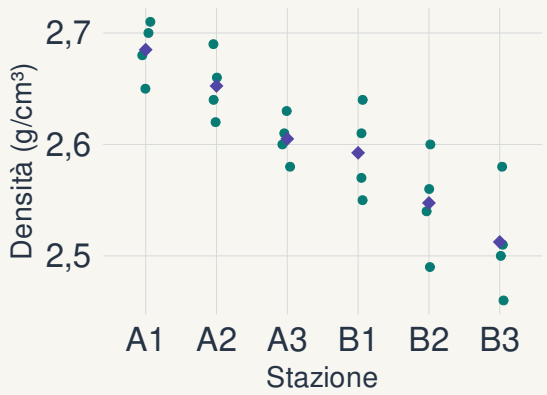
```
source('R/P10_funzioni.R')
d <- read.csv('dati/campioni_modulo1.csv')
s <- sintesi_campioni(d)
stopifnot(nrow(s)==6,
 !('densita'%in%names(d)),
 abs(s$densita[s$stazione=='A1']-2.685)<1e
     -12)
s
```

Richiami Un controllo numerico è più informativo quando il valore atteso deriva da un ragionamento indipendente.

La sintesi conserva la variabilità entro stazione

La figura affianca le densità dei singoli provini alle medie delle sei stazioni, così che il risultato aggregato rimanga leggibile rispetto ai dati che lo determinano. Le medie vanno da 2,5125 a 2,685 grammi per centimetro cubo, mentre la media dei ventiquattro provini è circa 2,59917. I rombi indicano valori descrittivi e non intervalli inferenziali. Il controllo della procedura rimane quindi distinto da un confronto statistico fra stazioni, che richiederebbe un disegno e un modello della variabilità appropriati.

Evidenza grafica



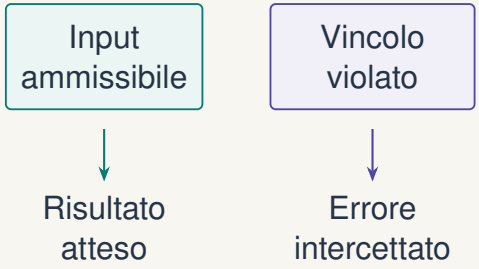
Provini in verde e medie delle stazioni in viola.

Richiami La ricostruibilità della sintesi non sostituisce la giustificazione inferenziale di un confronto territoriale.

I controlli comprendono errori deliberati

La verifica costruisce cinque input inammissibili: volume nullo, massa negativa, volume mancante, massa convertita in testo e identificativi duplicati. Per ciascuno si controlla che la funzione interrompa l'elaborazione, evitando la produzione di una sintesi apparentemente valida. Una seconda proprietà confronta il risultato dopo l'inversione dell'ordine delle righe, che dovrebbe lasciare immutate le medie. Queste prove collegano il contratto dei dati a comportamenti osservabili, includendo sia casi corretti sia violazioni intenzionali delle condizioni d'ingresso.

Lettura del diagramma



Richiami Una prova del codice deve rendere riconoscibile anche il comportamento previsto quando le ipotesi d'ingresso falliscono.

Il fallimento atteso è un esito del test

Il frammento intercetta l'errore provocato dal volume nullo e lo trasforma in un indicatore verificabile. La gestione dell'eccezione appartiene al test, mentre la funzione scientifica continua a rifiutare il dato inammissibile. La prova successiva controlla l'invarianza della sintesi all'ordine delle righe. Questo approccio evita che l'assenza di un arresto del programma venga confusa con la correttezza del risultato e consente di individuare regressioni del comportamento quando il codice viene modificato.

Implementazione in R

```
source('R/P10_funzioni.R')
d <- read.csv('dati/campioni_modulo1.csv')
x <- transform(d,volume_cm3=0)
respinto <- tryCatch({
 sintesi_campioni(x); FALSE
},error=function(e) TRUE)
stopifnot(respinto,
 isTRUE(all.equal(sintesi_campioni(d),
 sintesi_campioni(d[nrow(d):1,]))))
```

Richiami Il codice di verifica osserva il comportamento della funzione senza alterarne le condizioni di validità.

L’impronta descrive i byte del file

Due file possono contenere rispettivamente le scritture uno e uno virgola zero, producendo lo stesso valore numerico dopo la lettura e impronte differenti sui byte. L’esperimento conserva entrambe le rappresentazioni e ne confronta l’impronta MD5 mediante gli strumenti di R. Il confronto è utilizzato come dimostrazione di integrità materiale, senza attribuire a MD5 una garanzia crittografica. Il manifesto della consegna utilizza SHA-256, mentre la correttezza scientifica dei contenuti rimane oggetto di controlli distinti.

Lettura del diagramma



Byte differenti; impronte differenti.

Dopo la lettura: stesso valore numerico.

Richiami Integrità del file, equivalenza numerica e validità scientifica sono verifiche con oggetti differenti.

La tolleranza rende esplicito il confronto numerico

L'esportazione in CSV viene verificata rileggendo identificativi e densità e confrontandoli con gli oggetti prima della scrittura. Per quantità in virgola mobile, una regola generale combina tolleranza assoluta e relativa; il controllo del CSV usa qui soltanto quella assoluta. L'uguaglianza dei byte sarebbe una richiesta diversa e potrebbe fallire per convenzioni di formattazione innocue. La tolleranza non deve tuttavia assorbire errori scientificamente rilevanti, per cui la sua grandezza deve essere dichiarata insieme alle unità e alla precisione attesa.

$$|x - y| \leq \varepsilon_{ass} + \varepsilon_{rel}|x|$$

Sviluppo e interpretazione

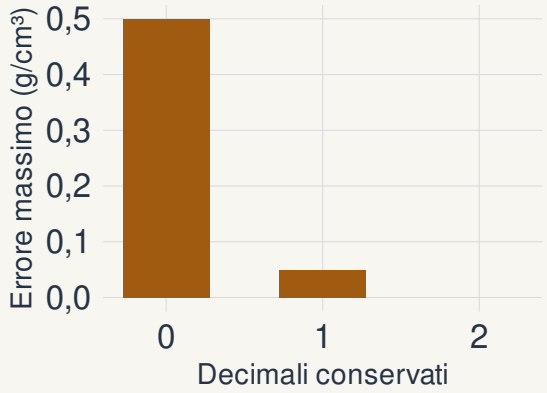
x: valore prima della scrittura; y: valore riletto. Si impone $\varepsilon_{\mathrm{ass}} = 10^{-12}$ g/cm³ e $\varepsilon_{\mathrm{rel}} = 0$. La componente assoluta ha le unità della densità, quella relativa è adimensionale. Gli identificativi richiedono identità esatta, perché una modifica altererebbe il collegamento fra provino e misura.

Richiami La tolleranza viene motivata dalla scala numerica e non sostituisce una verifica degli identificativi e delle unità.

Arrotondare modifica l’informazione conservata

Arrotondando le densità a zero, una e due cifre decimali, lo scarto massimo dai valori calcolati è rispettivamente circa 0,5, 0,05 e un residuo dell’ordine della precisione numerica. Il risultato dipende dalla particolare tabella dell’esercizio, nella quale le densità sono costruite con due decimali. La rappresentazione destinata alla lettura può adottare una precisione limitata, mentre gli oggetti utilizzati nei calcoli successivi devono conservare quella necessaria. Una nuova scrittura dei dati arrotondati modificherebbe anche l’impronta del file.

Evidenza grafica



Errore massimo introdotto dall’arrotondamento delle densità.

Richiami La precisione di presentazione e quella conservata nei calcoli devono essere definite separatamente.

Gli indici condivisi definiscono la stessa replica

Il progetto conserva dieci piani di ricampionamento, ciascuno composto da ventiquattro indici, e calcola la media delle densità selezionate. L'esempio serve a confrontare implementazioni in R e Python sulle stesse estrazioni, senza assegnare a dieci repliche un ruolo inferenziale. Uno stesso seme numerico non garantirebbe identiche sequenze fra linguaggi o generatori differenti. Il piano esplicito permette invece di separare l'identità del campione ricostruito dalle differenze di implementazione e di confrontare le medie entro una tolleranza dichiarata.

Evidenza grafica



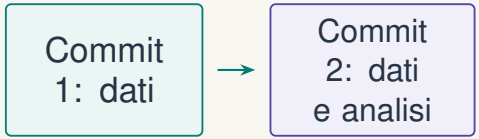
Dieci medie su indici condivisi; riferimento: media dei provini.

Richiami Per un confronto fra linguaggi, l'identità degli indici è un vincolo più preciso dell'uguaglianza del seme.

La storia Git conserva modifiche ricostruibili

L'esperimento crea un repository temporaneo isolato, registra un primo commit con i dati del provino e un secondo con il calcolo della densità. La storia conserva quindi due stati e il collegamento della modifica al proprio antecedente. La verifica accerta che gli identificativi dei commit siano differenti e che l'albero di lavoro finale sia pulito. La configurazione dell'autore resta locale al repository didattico, mentre nel progetto consegnato vengono conservati lo script riproducibile e il resoconto della storia.

Lettura del diagramma



Ogni stato conserva il proprio antecedente.

La storia non incorpora automaticamente i dati esterni.

Richiami Versionare il codice richiede anche riferimenti verificabili alle versioni dei dati e dell'ambiente utilizzati.

La consegna rende ricostruibili le dipendenze

Il pacchetto riunisce dati, funzioni, script principale, estratti delle slide, risultati, informazioni della sessione e resoconto dei controlli. La riesecuzione parte dalla radice del progetto e utilizza percorsi relativi, evitando dipendenze dalla cartella personale dell'autore. Le librerie necessarie vengono dichiarate e controllate prima dell'analisi, senza installazioni implicite durante il calcolo. L'ambiente registrato consente di interpretare differenze dovute alle versioni, mentre le verifiche numeriche aiutano a distinguere una variazione di formattazione da un cambiamento sostanziale del risultato.

Sviluppo e interpretazione

R/P10_funzioni.R definisce il contratto e le trasformazioni. R/P10_figure.R esegue le prove e produce le figure. La cartella risultati/P10 conserva sintesi, piani, impronte dimostrative e sessione; gli strumenti di verifica ricostruiscono anche il confronto con Python.

Richiami Una consegna riproducibile esplicita il punto d'ingresso, le dipendenze e i risultati attesi.

Consegna: dimostrare il procedimento completo

La relazione ricostruisce la densità del primo provino, le medie per stazione e le prove sui dati inammissibili. L'esercizio richiede di spiegare perché file numericamente equivalenti possano avere impronte differenti e perché lo stesso seme non garantisca le medesime estrazioni fra linguaggi. Una modifica controllata introduce un volume nullo e verifica che la procedura si arresti prima della sintesi. La discussione finale collega stabilità del calcolo, integrità dei materiali e condizioni scientifiche dell'analisi, indicando per ciascuna le evidenze disponibili.

Sviluppo e interpretazione

La densità del primo provino è 2,68 g/cm^3. Il volume nullo deve provocare un errore. Il confronto fra R e Python deve utilizzare gli stessi indici e una tolleranza esplicita: questi tre esiti costituiscono riscontri distinti della consegna.

Richiami L'analisi è ricostruibile quando il lettore può eseguire il procedimento e riconoscere le condizioni dei suoi risultati.