P11 · REVISIONE R6

Classificare nuove stazioni sintetiche

Separazione dei dati, standardizzazione e classificatore dei centroidi

17 slide · teoria, derivazioni, figure e applicazioni in R.
Provenienza dei dati e sorgenti nei materiali allegati.

P11

Percorso del modulo

3 Bersaglio e protocollo di valutazione

7 Geometria standardizzata e centroidi

12 Prestazione e limiti dell’interpretazione

16 Scheda del modello e consegna

I numeri indicano le pagine iniziali; i titoli sono cliccabili. Codice, figure e verifiche sono inclusi nel progetto.

La classe viene prevista da cinque caratteristiche

Il progetto assegna ciascun campione a una delle tre litologie sintetiche, Arenaria, Basalto e Calcare, utilizzando quattro composizioni in ossidi e la densità. Il campione comprende centottanta provini raccolti in diciotto stazioni simulate. La domanda riguarda il trasferimento a stazioni escluse dall'adattamento, per cui la separazione segue l'identità territoriale anziché i singoli provini. Il caso riutilizza dati già incontrati nel percorso didattico e applica una procedura prefissata; il risultato non costituisce una valutazione finale inedita di un modello scelto dopo ripetuti confronti.

Lettura del diagramma



Tre classi note del generatore sintetico.

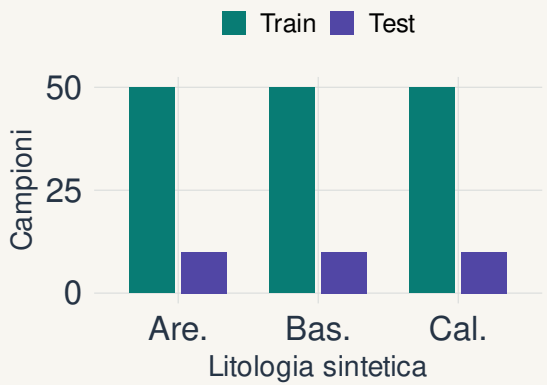
Richiami Il protocollo di valutazione deve corrispondere al tipo di nuova unità sulla quale si intende applicare il modello.

La stazione resta interamente in un insieme

Quindici stazioni, con centocinquanta campioni, appartengono all'adattamento; le tre restanti, con trenta campioni, costituiscono il test. Nessuna stazione compare in entrambi gli insiemi. La divisione conserva dieci provini per stazione e, nel test, una stazione per ciascuna classe. Il controllo dell'intersezione degli identificativi territoriali verifica quindi una condizione più forte della semplice assenza di righe duplicate, evitando che provini dello stesso gruppo forniscano informazione sia alla costruzione sia alla valutazione della regola.

$$\mathcal{S}_{train} \cap \mathcal{S}_{test} = \varnothing$$

Evidenza grafica



$\mathcal{S}$: insieme delle stazioni, distinto fra train e test.

Are.: Arenaria; Bas.: Basalto; Cal.: Calcare.

Richiami La separazione per gruppi conserva il livello al quale si vuole valutare la generalizzazione.

Il controllo conserva la struttura della divisione

Il frammento ricostruisce i due insiemi dalla variabile di appartenenza già presente nei dati e ne verifica numerosità e disgiunzione delle stazioni. La tabella per litologia rende inoltre esplicito il bilanciamento delle classi. Il controllo precede standardizzazione e calcolo dei centroidi, affinché nessuna statistica della risposta o dei predittori del test entri nella costruzione della regola. Le etichette del test verranno utilizzate soltanto dopo aver prodotto le classificazioni con il procedimento definito.

Implementazione in R

```
d <- read.csv('dati/ml_v3.csv')
tr <- d$split=='train'
te <- d$split=='test'
stopifnot(sum(tr)==150,sum(te)==30,
 length(intersect(d$stazione[tr],
 d$stazione[te]))==0)
table(d$litologia,d$split)
```

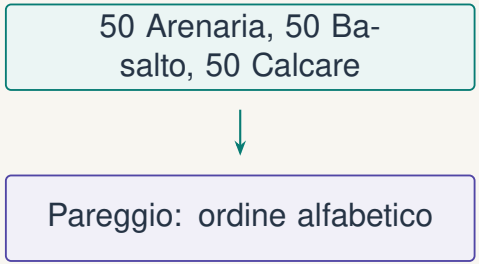
Richiami La divisione deve precedere ogni trasformazione che apprende parametri dai dati.

Il riferimento risolve un pareggio dichiarato

La procedura elementare assegna a tutti i nuovi campioni la classe più frequente nell'adattamento. Poiché le tre classi hanno cinquanta osservazioni ciascuna, il pareggio viene risolto secondo l'ordine alfabetico e la previsione costante diventa Arenaria. Nel test bilanciato questa regola classifica correttamente dieci campioni su trenta, con accuratezza pari a un terzo. Il riferimento quantifica così la prestazione ottenibile senza usare le caratteristiche e rende interpretabile il contributo del classificatore successivo.

$$\widehat{c}_0 = \arg\max_c n_{c,train}, \qquad Acc_0 = \frac{10}{30}$$

Lettura del diagramma



Previsione costante: Arenaria.

$n_{c,train}$: campioni train della classe c; $\widehat{c}_0$: classe assegnata. Acc_0: quota corretta nel test. Il pareggio segue l'ordine alfabetico.

Richiami Anche la procedura di riferimento deve essere definita usando esclusivamente l'insieme di adattamento.

La standardizzazione apprende soltanto dal train

Le composizioni e la densità hanno scale numeriche differenti, che influenzerebbero direttamente una distanza euclidea. Ogni variabile viene quindi centrata sulla propria media nell'adattamento e divisa per la deviazione standard dello stesso insieme, calcolata con denominatore n meno uno. Questi parametri vengono conservati e applicati senza ricalcolo ai trenta campioni di test. La trasformazione stabilisce la metrica del classificatore; includere il test nel calcolo delle scale introdurrebbe informazione del campione di verifica nella procedura da valutare.

$$z_{ij} = \frac{x_{ij} - \overline{x}_{j,train}}{s_{j,train}}$$

Sviluppo e interpretazione

i: campione; j: una delle cinque variabili; x_{ij}: valore originario; z_{ij}: valore standardizzato. $\overline{x}_{j,train}$ e $s_{j,train}$ sono media e deviazione standard nei 150 campioni train, con denominatore 149 per la varianza. Le medie standardizzate sono nulle e le deviazioni unitarie entro la tolleranza numerica; tali proprietà non sono richieste nel test.

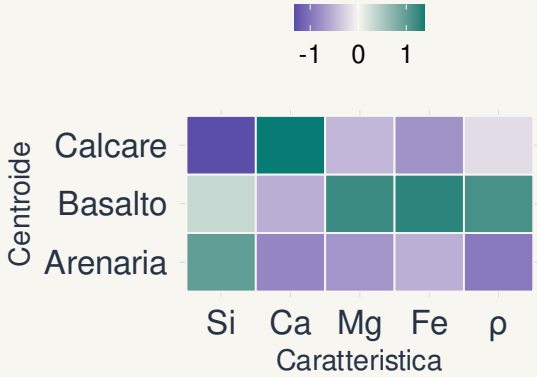
Richiami I parametri della trasformazione fanno parte del modello appreso e devono essere conservati insieme al classificatore.

Il centroide rappresenta la media di una classe

Per ciascuna litologia si calcola il vettore medio delle cinque caratteristiche standardizzate nei soli campioni di adattamento. La carta cromatica mostra i tre centroidi, consentendo di riconoscere quali variabili caratterizzino la posizione media dei gruppi nel generatore sintetico. Il colore esprime deviazioni standard rispetto alla media complessiva del train. Un centroide riassume la posizione della classe e lascia esclusa la sua dispersione interna, che potrebbe diventare rilevante quando gruppi differenti mostrano forme o varianze molto diverse.

$$\mathbf{c}_k = \frac{1}{n_{k,train}} \sum_{i \in train : Y_i = k} \mathbf{z}_i$$

Evidenza grafica



Y_i: classe di i; $n_{k,train}$: numerosità della classe k; $\mathbf{z}_i$: vettore standardizzato; $\mathbf{c}_k$: sua media. Si, Ca, Mg, Fe: ossidi; ρ: densità.

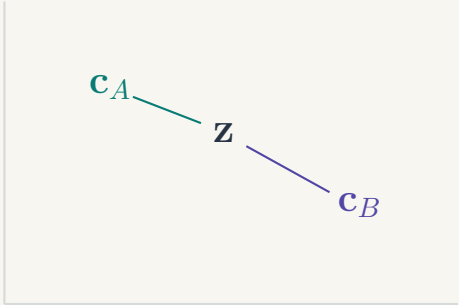
Richiami La geometria del centroide riassume la posizione media, senza modellare l'intera distribuzione della classe.

La regola minimizza una distanza quadratica

Un nuovo vettore standardizzato viene assegnato al centroide più vicino nella metrica euclidea a cinque dimensioni. Poiché la radice quadrata conserva l'ordine, il codice confronta direttamente le somme dei quadrati degli scarti. L'eventuale pareggio segue l'ordine alfabetico dichiarato delle classi. La decisione dipende quindi da scale, centroidi e convenzione di assegnazione, che devono essere tutti disponibili per riprodurre la previsione su un nuovo campione.

$$\widehat{y}(\mathbf{z}) = \arg\min_{k} \sum_{j=1}^{5} (z_j - c_{kj})^2$$

Lettura del diagramma



Schema in due dimensioni; calcolo effettivo in cinque.

z_j: caratteristica standardizzata j; c_{kj}: coordinata j del centroide k; $\widehat{y}$: classe assegnata. Si confrontano cinque coordinate e tre classi.

Richiami La regola di classificazione è definita nello spazio trasformato, la cui metrica dipende dalle scale apprese.

Il confine fra due centroidi è un iperpiano

Le osservazioni equidistanti da due centroidi soddisfano l'uguaglianza fra le due distanze quadratiche. Espandendo i quadrati, il termine comune nella norma dell'osservazione si elimina e rimane un'equazione lineare nel vettore standardizzato. Il confine è quindi un iperpiano, che diventa una retta in una rappresentazione bidimensionale. Con tre classi, ciascuna regione è determinata dal confronto simultaneo con gli altri centroidi; la struttura risultante dipende dalla metrica scelta e dalle posizioni delle medie di classe.

$$2\mathbf{z}^T(\mathbf{c}_b - \mathbf{c}_a) = \|\mathbf{c}_b\|^2 - \|\mathbf{c}_a\|^2$$

Sviluppo e interpretazione

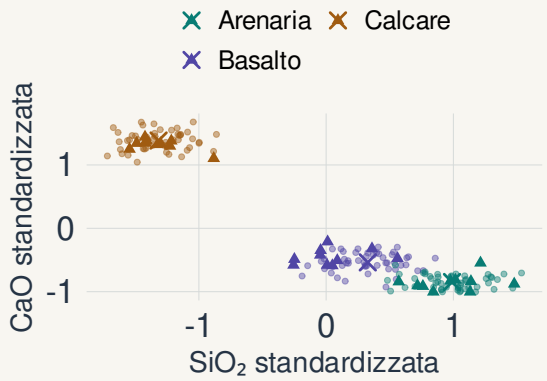
$\mathbf{z} \in \mathbb{R}^5$: osservazione standardizzata; $\mathbf{c}_a, \mathbf{c}_b$: centroidi di due classi. T indica la trasposta e $\|\mathbf{v}\|^2 = \sum_{j=1}^{5} v_j^2$ la norma euclidea al quadrato. Se i centroidi sono distinti, l'equazione definisce un iperpiano. Trasformare le scale può modificare il confine nelle variabili originarie.

Richiami La forma del confine deriva dalla regola matematica di distanza e non deve essere dedotta soltanto da una proiezione grafica.

La proiezione conserva soltanto due coordinate

Il diagramma rappresenta silice e ossido di calcio standardizzati, con punti per il train, triangoli per il test e croci per i centroidi. La separazione visibile aiuta a comprendere la struttura del campione sintetico, ma il classificatore utilizza anche magnesio, ferro e densità. La figura è dunque una proiezione del problema e non rappresenta tutte le distanze né i confini effettivi della decisione. Una sovrapposizione in questa vista potrebbe scomparire nello spazio completo, mentre una separazione apparente richiede comunque verifica numerica.

Evidenza grafica



Proiezione SiO_2–CaO: train, test e centroidi; decisione in cinque dimensioni.

Richiami Una proiezione grafica illustra la geometria senza sostituire il calcolo nello spazio completo dei predittori.

Il modello conservato ricostruisce le decisioni

Il file del modello contiene nomi e ordine delle variabili, medie, scale, centroidi e classi. Il frammento rilegge questi oggetti e calcola le previsioni senza stimare nuovi parametri, rendendo esplicito il passaggio dall'adattamento all'applicazione. Le classi osservate entrano soltanto nella tabella finale di confronto. La rilettura viene verificata rispetto all'oggetto salvato, poiché una ricostruzione parziale che omettesse l'ordine delle colonne potrebbe produrre distanze errate anche usando gli stessi valori numerici.

Implementazione in R

```
d <- read.csv('dati/ml_v3.csv')
m <- readRDS('risultati/P11/centroidi_
    modello.rds')
te <- d$split=='test'
Z <- scale(d[te,m$variabili],
 center=m$centro,scale=m$scala)
D <- sapply(m$classi,function(k)
 rowSums(sweep(Z,2,m$centroidi[k,],'-')^2))
p <- m$classi[max.col(-D,ties.method='first'
    )]
table(osservata=d$litologia[te],prevista=p)
```

Richiami Riprodurre una decisione richiede l'intera trasformazione e l'ordine delle caratteristiche, oltre ai soli centroidi.

La matrice di confusione conserva i conteggi

Tutti i trenta campioni di test vengono assegnati alla classe osservata, con dieci casi sulla diagonale per ciascuna litologia. L'accuratezza risulta quindi pari a uno in questo campione. La matrice conserva i denominatori e rende controllabile l'assenza di errori fra coppie di classi, senza trasformare l'esito in una garanzia universale. I trenta provini provengono soltanto da tre stazioni e dallo stesso generatore sintetico, condizioni che limitano l'interpretazione rispetto a un'applicazione su rocce reali.

$$Acc = \frac{1}{30} \sum_{i \in test} \mathbf{1}\{\widehat{y}_i = y_i\} = 1$$

Evidenza grafica



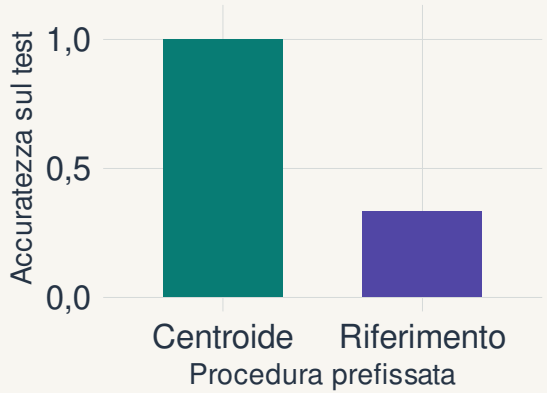
y_i: classe osservata; $\widehat{y}_i$: prevista; $\mathbf{1}$: vale 1 se coincidono, 0 altrimenti. Are.: Arenaria; Bas.: Basalto; Cal.: Calcare.

Richiami Un'accuratezza perfetta nel campione disponibile non dimostra assenza di errore nella popolazione di applicazione.

Il confronto quantifica il contributo delle variabili

L'accuratezza passa da un terzo per la previsione costante a uno per il classificatore dei centroidi. Entrambe le procedure sono valutate sugli stessi trenta campioni, così che il confronto conservi il medesimo denominatore. Il guadagno è coerente con la separazione costruita nel generatore sintetico e dimostra il funzionamento del procedimento didattico. L'impiego su nuove stazioni reali richiederebbe dati indipendenti, verifiche delle unità e valutazione delle differenze fra distribuzione di adattamento e contesto operativo.

Evidenza grafica



Accuratezze sullo stesso test: riferimento costante e centroidi.

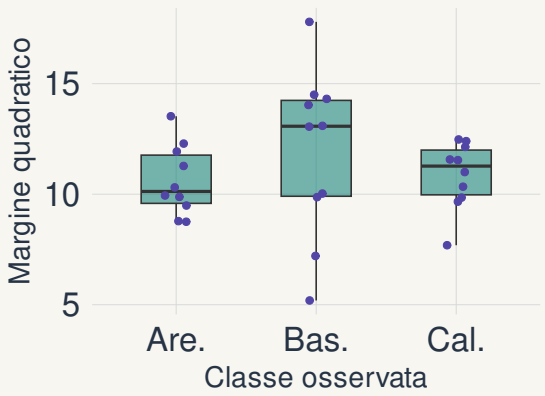
Richiami La prestazione viene attribuita alla procedura e alla distribuzione effettivamente valutate.

Il margine misura una separazione geometrica

La differenza fra la seconda distanza quadratica più piccola e la prima misura quanto la decisione sia separata dalla classe concorrente più vicina. Nel campione tutti i margini sono positivi, coerentemente con assegnazioni senza pareggio. La distribuzione per classe descrive la geometria del classificatore e può aiutare a individuare decisioni più prossime al confine. Il margine non è una probabilità calibrata di correttezza e potrebbe essere ampio anche per un campione esterno al dominio rappresentato dalle tre classi note.

$$\Delta_i = d^2_{i,(2)} - d^2_{i,(1)}$$

Evidenza grafica



$d^2_{i,(1)}, d^2_{i,(2)}$: prima e seconda distanza quadratica in ordine crescente. Δ_i: margine per il campione i, adimensionale.

Richiami La distanza dal concorrente misura una proprietà geometrica; la probabilità di errore richiede una valutazione ulteriore.

La scheda conserva dominio e condizioni d’uso

La scheda del modello registra bersaglio, origine sintetica, variabili e unità, numerosità per insieme, regola di standardizzazione, metrica, accuratezza e limiti. Il file JSON accompagna l’oggetto RDS e permette di interpretarlo senza ricostruire tutte le operazioni del laboratorio. La scheda dichiara inoltre il riuso didattico del test, l’assenza di validazione su rocce reali e l’impossibilità di riconoscere automaticamente classi non incluse nell’adattamento. Un campione nuovo richiede quindi anche una verifica di pertinenza al dominio.

Lettura del diagramma

Variabili, unità e trasformazione

Dati di valutazione e prestazione

Dominio, limiti e versioni

Richiami Il modello conservato deve essere accompagnato dalle condizioni entro le quali la sua prestazione è stata osservata.

Consegna: collegare geometria e validazione

La relazione presenta separazione delle stazioni, riferimento costante, standardizzazione, centroidi, matrice di confusione e scheda del modello. L'esercizio richiede di derivare il confine fra due centroidi e di spiegare perché medie e scale debbano essere stimate soltanto sul train. La discussione finale chiarisce perché trenta classificazioni corrette, provenienti da tre stazioni sintetiche, non siano sufficienti a dimostrare affidabilità generale. La conclusione distingue il risultato del caso didattico dalle evidenze ancora necessarie per un'applicazione geologica reale.

Sviluppo e interpretazione

R/P11_figure.R integra separazione, riferimento, classificatore e scheda. Il modello serializzato, i parametri di standardizzazione e le previsioni per identificativo sono conservati in risultati/P11. Il raccordo con M16 permette di approfondire validazione a gruppi, scelta dei modelli e calibrazione.

Richiami La generalizzazione viene sostenuta dal disegno della verifica e dalla pertinenza dei dati al contesto di applicazione.